

Skript Bio Data Science

Prof. Dr. Jochen Kruppa

13. September 2022

Inhaltsverzeichnis

Willkommen

Auf den folgenden Seiten wirst du eine Menge über Statistik oder Data Science lernen. Du musst dafür nicht meine Veranstaltungen besuchen. Gerne kannst du hier und dort einmal schauen, ob etwas für dich dabei ist. Das Skript wird fortlaufend von mir ergänzt. Neben dem Skript gibt es auch noch die erklärenden YouTube Videos. Ich freue mich, dass du Lust hast hier etwas zu lernen... oder aber du *musst* – da bald eine Klausur ansteht. Wie auch immer – schau dich einfach mal um. Im Anhang findest du auch einen kleinen Leitfaden für das Schreiben einer Abschlussarbeit. Vielleicht hilft dir die Anleitung ja beim Schreiben.

Gesammelte Klausurfragen Bio Data Science

Du findest die gesammelten Klausurfragen auf GitHub. Die Klausurfragen zu den einzelnen Vorlesungen in einem Modul werden in den entsprechenden Übungen besprochen. Bitte komme in die Übungen.

Lernen...

Du liest hier gerade das Skript für meine Vorlesungen an der Hochschule Osnabrück an der Fakultät Agrarwissenschaften und Landschaftsarchitektur (AuL). Wie immer Leben kannst du auf verschiedene Arten und Weisen den Stoff, den ich vermitteln will, lernen. Daher gibt es noch zwei andere Möglichkeiten. Zum einen Lernen auf YouTube, mit meinen Lernvideos oder du schaust dir das Material auf GitHub an. Auf GitHub habe ich auch Informationen, die du vielleicht brauchen kannst. Ebenso findest du im Kapitel ?? noch andere Literaturempfehlungen.

Inhaltsverzeichnis

... auf YouTube



Wenn du möchtest kannst du auf YouTube unter <https://www.youtube.com/c/JochenKruppa> noch einige Lehrvideos als Ergänzung schauen. In den Videos wiederhole ich Inhalte und du kannst auf Pause drücken um nochmal Programmierschritte nachzuverfolgen zu können.

... auf GitHub



Alle Materialien von mir findest du immer auf GitHub unter <https://github.com/jkruppa/teaching>. Selbst wenn du nicht mehr in einem meiner Kurse bist, kannst du so auf die Lehrinhalte immer nochmal zugreifen und die aktuellen Versionen haben. Auf GitHub liegt auch immer eine semesteraktuelle Version der gesammelten Klausurfragen für meine Module.

Kontakt

Wie erreichst du mich? Am einfachsten über die gute, alte E-Mail. Bitte beachte, dass gerade kurz vor den Prüfungen ich mehr E-Mails kriege. Leider kann es dann einen Tick dauern.



Einfach an j.krappa@hs-osnabrueck.de schreiben. Du findest hier auch eine kurze Formulierungshilfe. Einfach auf den Ausklappfeil klicken.

Bitte gib immer in deiner E-Mail dein Modul - was du belegst - mit an. Pro Semester unterrichte ich immer *drei* sehr ähnlich klingende Module. Daher schau nochmal hier in der Liste, wenn du unsicher bist.

💡 E-Mailvorlage mit beispielhafter Anrede

Hallo Herr Kruppa,
... ich belege gerade Ihr Modul **Modulname** und hätte eine
Bitte/Frage/Anregung...
... ich benötige Hilfe bei der Planung/Auswertung meiner
Bachelorarbeit...
Mit freundlichen Grüßen
M. Muster

1 Organisation

Version vom September 14, 2022 um 08:44:28

Den Teil kannst du hier überspringen, wenn es dich nicht so richtig interessiert, was ich alles an Vorlesungen an der Hochschule Osnabrück anbiete. Wenn es dir um *statistische* Inhalte geht, dann gehe einfach weiter in die nächsten Kapitel. In diesem Kapitel geht es nochmal Orientierung über meine Vorlesungen zu geben, wenn dich noch mehr als nur der Pflichtkurs interessiert.

1.1 Statistische Beratung

Neben der klassischen Vorlesung biete ich auch Termine für die statistische Beratung von Abschlussarbeiten sowie Projekten an. Dieses Angebot gilt es für alle Mitglieder der Hochschule Osnabrück. Primär für Fakultät Agrarwissenschaften und Landschaftsarchitektur (AuL), aber natürlich auch für alle anderen Fakultäten. Dafür musst du mir einfach nur eine E-Mail schreiben und dann erhältst du einen Termin innerhalb der nächsten zwei Wochen.

Die Beratung ist grundsätzlich anonym und vertraulich. Wenn du willst kannst du gerne noch dein:e Betreuer:in mitbringen. Das ist aber keine Voraussetzung oder Notwendigkeit. Meistens finden mehrere Besprechungen statt, wir versuchen aber natürlich zusammen zügig dein Problem zu lösen. Ziel ist der Beratung ist es dich in die Lage zu versetzen selbstständig deine Analyse zu rechnen.

1 Organisation

1.2 R Tutorium

Zusätzlich zu der statistischen Beratung bieten wir auch ein R Tutorium für alle Mitglieder der Fakultät Agrarwissenschaften und Landschaftsarchitektur (AuL) an. Theoretisch können auch hier andere Mitglieder der anderen Fakultäten vorbeischauen, der Ort ist aber aktuell ein Raum auf dem Gelände in Haste. Die aktuellen Termine findest du in Tabelle ??.

Im R Tutorium besprechen wir aktuelle Themen der Teilnehmer:innen. Meist sind dies aktuelle Fragen zu den Bachelorarbeiten. Auch wenn du kein dringendes Problem hast, kannst du gerne kommen und dir die Fragestellungen anhören. Meistens ist es auch interessant mal die Fragestellungen der anderen Studierenden sich anzuhören oder aber schon mal zu Üben ein anderes Experiment zu verstehen.

Bitte beachte folgende Hinweise zu den Terminen.

i Hinweise zu dem R Tutorium

Das R Tutorium findet **nicht** im Prüfungszeitraum der Fakultät Agrarwissenschaften und Landschaftsarchitektur (AuL) statt.

Das R Tutorium findet **nicht** im *Februar* und *März* statt.

Das R Tutorium findet **nicht** im *August* und *September* statt.

Tabelle 1.1: Aktuelle Termine des R Tutoriums im Semester

Termin	Uhrzeit	Raum	Anmerkung
<i>nächste Termine</i>	<i>ab</i>		<i>Oktober 2022</i>

1.3 Vorlesungen an der Hochschule Osnabrück

Von mir angebotene Vorlesungen werden an der Hochschule Osnabrück an der Fakultät Agrarwissenschaften und Landschaftsarchitektur (AuL) in ILIAS verwaltet. Alle notwendigen Infor-

1.3 Vorlesungen an der Hochschule Osnabrück

mationen und Materialien sind auf ILIAS unter <https://lms.hs-osnabrueck.de/> zu finden. Wenn du in dem Kurs nicht angemeldet bist, dann kontaktiere mich bitte per Mail. Auch die Kommunikation erfolgt von meiner Seite aus über ILIAS.

Wenn du nicht in der Fakultät Agrarwissenschaften und Landschaftsarchitektur (AuL) studierst oder aber in einem Studiengang, der meine Module nicht anbietet, steht es dir natürlich frei, sich in meine Vorlesungen zu setzen. Du findest in Tabelle ?? eine Übersicht der angebotenen Module und auch die inhaltliche Ordnung nach Lernstufe. Bitte informiere dich in deinem Studierendensekretariat über die Modalitäten zur Prüfungsteilnahme.

Eine inhaltliche Übersicht findet sich auf dem Google Spreadsheet. Die Planung ist aktuell (Stand Herbst/Winter 2022) noch nicht abgeschlossen. Im Zweifel einfach bei mir einmal per Mail anfragen.

Auf ILIAS findest du alle aktuellen Kursinformationen und erhältst auch die Mails, wenn Änderungen im Kursablauf stattfinden.

1 Organisation

Tabelle 1.2: Angebotene Statistik Module an der Fakultät Agrarwissenschaften und Landschaftsarchitektur (AUA). Die Stufe gibt das Lernniveau an.

	Landwirtschaft; Angewandte Pflanzenbiologie – Gartenbau, Pflanzen- Stufetechnologie	Wirtschafts- ingenieur- wesen Agrar / Lebensmittel	Angewandte Bioverfahrenstechnik in Agrar- und Lebensmit- telwirtschaft	Angewandte Nutztier- Pflanzenwis- sen- schaften
1	Mathematik und Statistik	Statistik	Angewandte Statistik für Bioverfahrenstechnik	
2	Angewandte Statistik und Versuchswesen	Angewandte Statistik und Versuchswesen		
3	Spezielle Statistik und Versuchswesen			Biostatistik

2 Literatur

Version vom September 14, 2022 um 08:44:32

Was ist gute Literatur? Immer schwer zu beurteilen. Im Folgenden liste ich einige Literaturquellen auf. Zum einen basiert eine Menge von dem R Code auf Wickham (2016) zum Anderen möchtest du dich vielleicht nochmal rechts oder links weiter bilden. Du musst aber nicht um die Klausur bestehen zu können. Siehe es eher als ein Angebot.

i Die Frage nach der Klausur...

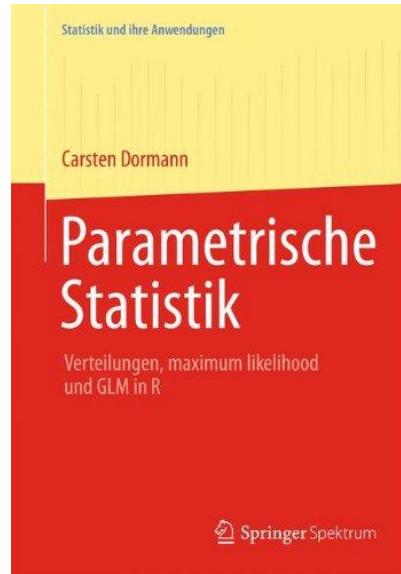
Und daher hier nochmal gleich zu Anfang, es ist nicht notwendig mehr als das Skript durchzuarbeiten und bei den Übungen zu sein um die Klausur zu bestehen. Für deine Bachelorarbeit wirst du aber Programmieren in R können müssen.

Neben diesem Modul musst du vermutlich noch andere Module belegen. Deshalb hier eine Auswahl Literatur, die dir helfen mag. Zum einen ist die Literatur anders geschrieben und zum anderen sind dort andere Inhalte.

2.1 Parametrische Statistik

Dormann (2013) liefert ein tolles deutsches Buch für die Vertiefung in die Statistik. Insbesondere wenn du wissenschaftlich Arbeiten willst weit über die Bachelorarbeit hinaus. Dormann baut in seinem Buch eine hervorragende Grundlage auf. Das Buch ist an der Hochschule Osnabrück kostenlos über den Link zu erhalten.

2 Literatur



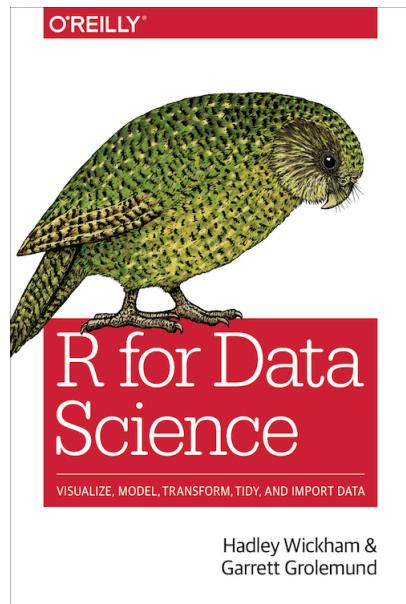
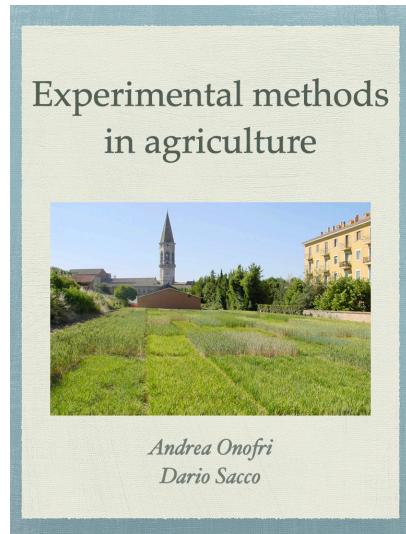
2.2 Experimental methods in agriculture

Onofri und Sacco (2021) haben das Buch Experimental methods in agriculture geschrieben. Wir werden auf dieses englische Buch ab und zu mal verweisen. Insbesondere der Einleitungstext zur Wissenschaft und dem Design von Experimenten ist immer wieder lesenswert. Spätere Teile des Buches sind etwas mathematischer und nicht für den Einstieg unbedingt geeignet. Aber schaue es dir selber an.

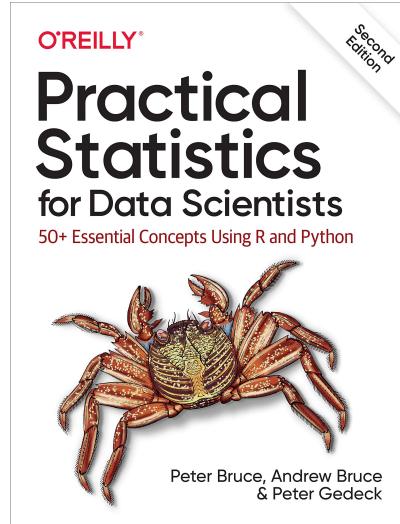
2.3 R for Data Science

Wickham (2016) ist die Grundlage für die R Programmierung. Das Material von Wickham findet sich kostenlos online unter <https://r4ds.had.co.nz/> und <https://www.tidyverse.org/>. Wir werden uns hauptsächlich mit R wie es Wickham lehrt beschäftigen. Somit ist Wickham unsere Grundlage für R.

2.3 R for Data Science



2 Literatur



2.4 Practical Statistics for Data Scientists

Bruce (2020) schreibt ein Buch für den Anwender. Ohne Vorkenntnisse ist das Buch vermutlich etwas schwer zu lesen. Dafür bietet das Buch aber *nach* einem Statistikkurs sehr gute Anknüpfungspunkte Richtung maschinelles Lernen und somit der Klassifikation. Das Buch ist auch hier in der englischen Version und hier in der deutschen Version zu erhalten. *Beide Links benötigen den Zugang über die Hochschule Osnabrück.*

2.5 Data Science for Agriculture in R

Schmidt liefert auf der Webseite <https://schmidtpaul.github.io/DSFAIR/index.html> eine tolle Sammlung an experimentellen Designs bzw. Versuchsanlagen samt der Auswertung in R. Ohne Vorkenntnisse schwer zu verstehen. Sollte aber nach einem Kurs Statistik dann möglich sein. Gerne hier auch mich fragen, dann können wir gemeinsam das passende Design raussuchen und besprechen.



Odds & Ends

Introducing Probability & Decision with a Visual Emphasis

2.6 Odds & Ends

Am Ende dann noch eine Mathebuch von Weisberg zu finden unter <https://jonathanweisberg.org/vip/>. Eigentlich eher ein Buch über Wahrscheinlichkeiten und wenn ein Buch am Ende stehen muss, dann ist es dieses Buch. Ich finde es sehr spannend zu lesen, aber das ist dann vermutlich *special intrest*.

Referenzen

3 Einführung

Version vom September 14, 2022 um 08:44:40

In diesem Kapitel nenne ich die wichtigsten Lernziele, die nach dem Lesen des Skriptes im Rahmen deiner Lehrveranstaltung von dir erreicht worden sein sollten. Je nach besuchten Kurs kann natürlich nicht *alles* geschafft worden sein. Viele Kapitel haben noch eine Abschnitt in dem du mehr über die Klausur erfährst. So sehe diese Übersicht als Einführung für das was später an Lehrinhalten kommt. Wenn du die Lernziele hier verstehst, dann hast du eine gute und solide Grundlage in Statistik und Bio Data Science. Damit solltest du dann auch gut durch die Anfänge deiner Bachelorarbeit kommen.

Ein Wort der Warnung...

Wenn du dieses Bild eines niedergeschlagenen *Engels der Statistik* siehst...



... dann bedeutet der niedergeschlagene Engel der Statistik:

- 1) Wir opfern Genauigkeit für Anwendbarkeit. Ja, manchmal ist es eben statistisch nicht richtig was hier steht, aber aus Gründen der Anwendung fahren wir mal über den Engel drüber. *Schade*.
- 2) Wir sind hier Anfänger und Anwender. Später kannst du noch tiefer ins Detail gehen. Hier wollen wir die Grundlagen lernen. Das hat dann einen Preis an *Richtigkeit*.

3 Einführung

- 3) Wir wollen fertig werden. Durch geschicktes Manövrieren können wir an einen Punkt kommen, wo kein statistischer Test mehr passt. Das wollen wir nicht. Deshalb zahlen wir hier auch einen Preis. Passt aber.

Deshalb konzentrieren wir uns auf einige wichtige Lernziele, die wir jetzt einmal nacheinander durchgehen.

3.1 Lernziel 1: Eine explorative Datenanalyse durchführen

Gleich zu Beginn R Code zu zeigen und eine entsprechende Abbildung ist vielleicht ungewöhnlich, aber wir wollen zu dieser Abbildung ?? hin. In Abbildung ?? siehst du einen Boxplot. Und wie wir aus den Daten `flea_dog_cat.xlsx` einen Boxplot erstellen, das soll uns in den nächsten Kapitel beschäftigen. Dafür müssen wir nämlich eine Menge in dem Codeblock verstehen und dann auch Anwenden können. Und natürlich lernen was eigentlich ein Boxplot ist und was in einem Boxplot eigentlich dargestellt ist.

Hier ist der Codeblock der in R die Abbildung ?? erstellt.

```
## Einlesen von Daten aus Excel
data_tbl <- read_excel("data/flea_dog_cat.xlsx")

## Umformen der <chr> Spalte in einen Factor <fct>
data_tbl <- data_tbl %>%
  mutate(animal = as_factor(animal))

## Auswählen der wichtigen Spalten für den Boxplot
data_tbl <- data_tbl %>%
  select(animal, jump_length)

## Generieren des Boxplots in ggplot()
ggplot(data_tbl, aes(x = animal, y = jump_length,
                      fill = animal)) +
  geom_boxplot() +
  geom_jitter()
```

3.1 Lernziel 1: Eine explorative Datenanalyse durchführen

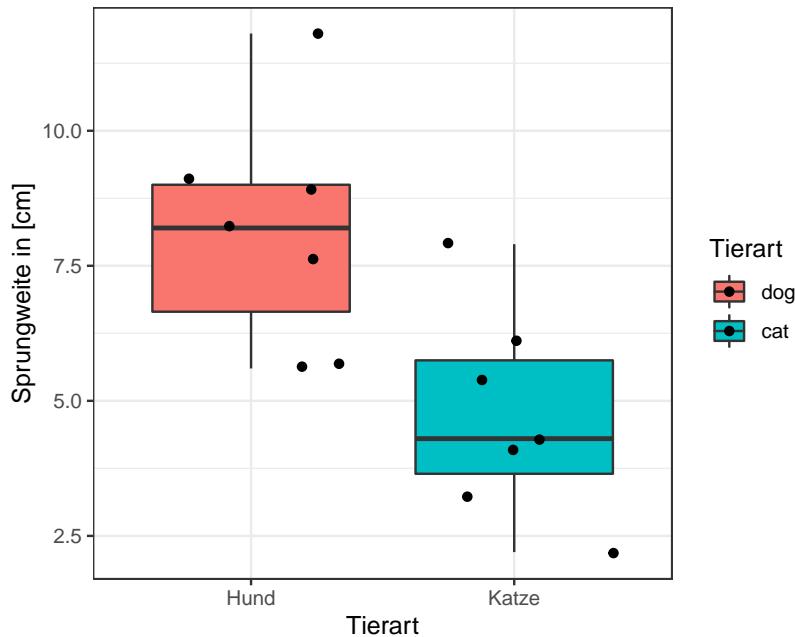


Abbildung 3.1: Boxplot der Sprungweiten [cm] von Hunden und Katzen.

```
labs(x = "Tierart", y = "Sprungweite in [cm]",
     fill = "Tierart") +
  scale_x_discrete(labels = c("Hund", "Katze")) +
  theme_bw()
```

Wir müssen nun folgende Dinge lernen um den Codeblock zu verstehen:

- Wir müssen das Datenbeispiel verstehen. Was sind das eigentlich für Daten, die wir da abbilden? Was sind überhaupt Daten im Sinne der Statistik bzw. für R.
- Wir müssen den R Code verstehen. Von einzelnen wichtigen Operatoren wie `->` und `%\>%` zu dem den Unterschieden von Wörtern und Objekten.
- Wie kriegen wir Daten aus Excel in R hinein? Wir können die Daten ja nicht einfach in R eintragen sondern haben die Daten ja meist in einer (Excel) Datei wie `flea_dog_cat.xlsx`.
- Was ist eigentlich ein Boxplot und welche statistischen

3 Einführung

Maßzahlen werden hier eigentlich abgebildet?

- Wie funktioniert eigentlich die Funktionalen `ggplot()` mit der wir den Boxplot erstellt haben?

All diese Fragen und weitere Fragen, die sich diesen Fragen anschließen, wollen wir uns in den nächsten Kapitel anschauen. Leider kann ich hier nur *linear* schreiben. Deshalb musst du eventuell mal ein Kapitel wiederholen oder etwas quer lesen. Du kannst dir ja auch nicht immer alles auf einmal merken.

3.2 Lernziel 2: RStudio und R

💡 Was ist eigentlich RStudio und woher kriege ich das?

Du findest auf YouTube Einführung in R - Teil 01 - Installation von RStudio und R als Video. Ich gehe in dem Video einmal alle wichtigen Schritte durch und so kannst du dir Rstudio und R installieren.

Um Data Science durchführen zu können musst du etwas Programmieren können. Wir programmieren in R und nutzen die Software um Abbildungen zu erstellen und Analysen zu rechnen.

Wir arbeiten in R und nutzen dafür das RStudio. Führe einfach folgende Schritte aus um erst R zu installieren und dann das RStudio.

1. R installieren unter <https://cran.rstudio.com/>
2. RStudio installieren unter <https://www.rstudio.com/products/rstudio/download/#download>

Bitte die Reihenfolge beachten. Beide Schritte kannst du dir auch nochmals im Video anschauen oder aber du kommst in das R Tutorium was regelmäßig an der Hochschule Osnabrück von mir angeboten wird. Die Termine findest du im Kapitel ??.

3.3 Lernziel 3: Falsifikationsprinzip



Grundlagen der Wissenschaft und Falsifikationsprinzip

Du findest auf YouTube Grundlagen der Wissenschaft und Falsifikationsprinzip als Video Reihe.

Wie funktioniert ein *statistischer Versuch*? Ich könnte auch wissenschaftliches Experiment schreiben, aber ein wissenschaftliches Experiment ist sehr abstrakt. Wir wollen ja einen Versuch durchführen und danach - ja was eigentlich? Was wollen wir nach dem Versuch haben? Meistens eine neue Erkenntnis. Um diese Erkenntnis zu validieren oder aber abzusichern nutzen wir Statistik. Dazu musst du noch wissen, dass wir eine spezielle Form der Statistik nutzen: die *frequentistische Statistik*.

Die *frequentistische Statistik* basiert - wie der Name andeutet - auf Wiederholungen in einem Versuch. Daher der Name frequentistisch. Also eine Frequenz von Beobachtungen. Ist ein wenig gewollt, aber daran gewöhnen wir uns schon mal. Konkret, ein Experiment welches wir frequentistisch Auswerten wollen besteht immer aus biologischen Wiederholungen. Wir müssen also ein Experiment planen in dem wir wiederholt ein Outcome an vielen Tieren, Pflanzen oder Menschen messen. Auf das Outcome gehen wir noch später ein. Im Weiteren konzentrieren wir uns hier auf die *parametrische Statistik*. Die parametrische Statistik beschäftigt sich mit Parametern von Verteilungen.



Wie gehen wir nun vor, wenn wir ein Experiment durchführen wollen?

- 1) Wir müssen auf jeden Fall wiederholt ein Outcome an verschiedenen Tieren, Pflanzen oder Menschen messen.
- 2) Wir überlegen uns aus welcher Verteilungsfamilie unser Outcome stammt, damit wir dann die entsprechende Verfahren zur Analyse nehmen können.

Wenn wir nun ein Experiment durchführen dann erheben wir einmalig Daten D_1 . Wir könnten das Experiment wiederholen und erneut Daten D_2 erheben. Wir können das Experiment

Wiederholung
Endpunkt einer Responsefunktion y.
oder Mensch. Eine **technische**
Wiederholung ist die gleiche
Messung an dem gleichen Tier,
Pflanze oder Mensch.

3 Einführung

j -mal wiederholen und haben dann Daten von D_1, \dots, D_j . Dennoch werden wir nie *alle* Daten erheben können, die mit einem Experiment verbunden sind.

Strukturgleichheit erreichen wir

durch **Randomisierung**: Nehmen wir das Beispiel, dass wir die Sprungweite von Hunde- und Katzenflöhen vergleichen wollen. Wir können nicht *alle* Hunde- und Katzenflöhe messen. Wir können nur eine Stichprobe an Daten D_1 erheben. Über diese Daten D_1 können wir dann später durch statistische Algorithmen eine Aussage treffen. Wichtig ist hier sich zu merken, dass wir eine Grundgesamtheit haben aus der wir eine Stichprobe ziehen. Wir müssen darauf achten, dass die Stichprobe *repräsentativ* ist und damit *strukturgleich* zur Grundgesamtheit ist. Die Strukturgleichheit erreichen wir durch Randomisierung. Wir veranschaulichen diesen Zusammenhang in Abbildung ???. Ein Rückschluß von der Stichprobe ist nur möglich, wenn die Stichprobe die Grundgesamtheit repräsentiert. Auch eine Randomisierung mag dieses Ziel nicht immer erreichen. Im Beispiel der Hundeflöhe könnte wir eine Art an Flöhen übersehen und diese Flohart nicht mit in die Stichprobe aufnehmen. Ein Rückschluß auf diese Flohart wäre dann mit unserem Experiment nicht möglich.

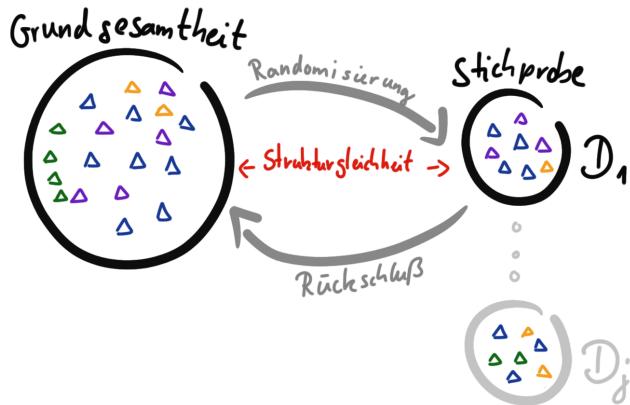


Abbildung 3.2: Abbildung über die Grundgesamtheit und die Stichprobe(n) D_1 bis D_j . Durch Randomisierung wird Strukturgleichheit erreicht, die dann einen Rückschluß von der Stichprobe auf die Grundgesamtheit erlaubt. Jede Stichprobe ist anders und nicht jede Randomisierung ist erfolgreich was die Strukturgleichheit betrifft.

3.3 Lernziel 3: Falsifikationsprinzip

Tabelle ?? zeigt nochmal die Zusammenfassung von der Grundgesamtheit un der Stichprobe im Vergleich. Wichtig ist zu merken, dass wir mit unserem kleinen Experiment Daten D generieren mit denen wir einen Rückschluß und somit eine Verallgemeinerung erreichen wollen.

Tabelle 3.1: Vergleich von Grundgesamtheit und Stichprobe.

Grundgesamtheit	Stichprobe
... n ist riesig bis unfassbar.	... n von D ist klein.
... der Mittelwert wird mit μ_y beschrieben.	... der Mittelwert wird mit \bar{y} beschrieben.
... die Varianz wird mit σ^2 beschrieben.	... die Varianz wird mit s^2 beschrieben.
... die Standardabweichung wird mit σ beschrieben.	... die Standardabweichung wird mit s beschrieben.

Teil I

Datenbeispiele

Version vom September 14, 2022 um 08:44:50

Wir brauchen am Anfang erstmal ein simples Beispiel. Konkrete Zahlen mit denen wir arbeiten können und Grundlagen aufbauen können. Was liegt da näher als sich einmal am Kopf zu kratzen und zu fragen, was juckt den da? Genau! Flöhe. Wir schauen uns einmal Flöhe auf Hunden und Katzen an. Daran können wir viel über Zahlen und Buchstaben in der Statistik und dann im Programmieren lernen.

i Zahlen, Buchstaben und Wörter

Mir ist bewusst, dass du die Unterschiede kennst. Nur leider ist eine Zahl nicht nur eine Zahl und ein Wort nicht immer ein Wort. Das hat mit der eingeschränkten Kommunikationsfähigkeit von Computerprogrammen zu tun. R braucht da deine Mithilfe und dein *neues* Verständnis von Buchstaben und Zahlen. Eben wie ein Computer denkt.

Von Flöhen und Hunden

In unserem ersten Beispiel in Kapitel ?? geht es darum einmal ein Gefühl für Daten zu kriegen. Also was sind diese Zahlen und Buchstaben eigentlich? Wie sind Daten aufgebaut und wie musst du Daten bauen, so dass wir auch mit den Daten arbeiten können? Wir schauen uns dafür einmal Flöhe auf Hunden an und fragen uns welche Typen von Zahlen können wir erheben?

Von Flöhen, Hunden und Katzen

In unserem zweiten Beispiel in Kapitel ?? erweitern wir unserer erstes Beispiel um die Katzen. Das heist, dass eigentlich alles gleich bleibt. Wir schauen usn *zusätzlich* noch als zweite Gruppe die Katzen an. Nun können wir die Frage stellen, unterscheiden sich Flöhe auf Hunden und Katzen gegeben von gemessenen Eigenschaften?

Von Flöhen auf Tieren

In unserem dritten Beispiel in Kapitel ?? erweitern wir das Beispiel um den Fuchs mit einem weiteren Tier. Dadurch haben wir nicht mehr einen Faktor mit zwei Leveln vorliegen sondern einen mit drei Leveln. Die Fragestellung erweitert sich jetzt auf einen *multiplen* Gruppenvergleich. Wir vergleichen nicht mehr nur noch zwei Gruppen miteinander sondern drei.

Von Flöhen auf Tieren in Habitaten

In unserem vierten Beispiel in Kapitel ?? schauen wir uns zusätzlich zu dem dritten Beispiel noch verschiedene Habitate (eng. *site*) an. Wir haben nämlich die Hunde-, Katzen-, und Fuchsflöhe nicht nur an einem Ort sondern an verschiedenen Orten gesammelt und gemessen. Wir haben einen zweiten Faktor vorliegen.

Von vielen Flöhen auf Hunden und Katzen

Im fünften Beispiel in Kapitel ?? schauen wir uns wiederum nur noch zwei Tierarten an: Hunde und Katzen. Dafür aber eine große Anzahl an Tieren. Wir schauen uns hier die Daten von 400 Tiere an. Auf diesen Tierarten messen wir mehrere Variablen und wollen uns diese Daten später in der Regression anschauen.

Gummibärchen

Im Beispiel mit den Gummibärchen in Kapitel ?? geht es um die Darstellung verschiedener Verteilungen. Wir brauchen den Datensatz um zu verstehen, wie Daten verteilt sind. Sonst können wir den Datensatz auch gut nutzen um einmal in R zu filtern und zu selektieren. Auch für die Erstellung von Abbildungen eignet sich der Datensatz sehr gut.

4 Von Flöhen und Hunden

Version vom September 14, 2022 um 08:44:58

In unserem ersten Beispiel wollen wir uns verschiedene Daten D von Hunden und Hundeflöhen anschauen. Unter anderem sind dies die Sprungweite, die Anzahl an Flöhen, die Boniturnoten auf einer Hundemesse sowie der Infektionsstatus. Hier nochmal detailliert, was wir uns im folgenden im Kapitel einmal anschauen wollen.

- **Sprungweite** in [cm] von verschiedenen Flöhen

$$Y_{jump} = \{5.7, 8.9, 11.8, 8.2, 5.6, 9.1, 7.6\}.$$

- **Anzahl an Flöhen** auf verschiedenen Hunden

$$Y_{count} = \{18, 22, 17, 12, 23, 18, 21\}.$$

- **Boniturnoten** [1 = schlechteste bis 9 = beste Note] von verschiedenen Hunden

$$Y_{grade} = \{8, 8, 6, 8, 7, 7, 9\}.$$

- **Infektionsstatus** [0 = gesund, 1 = infiziert] mit Flöhen von verschiedenen Hunden

$$Y_{infected} = \{0, 1, 1, 0, 1, 0, 0\}.$$

Je nachdem was wir messen, nimmt Y andere Zahlenräume an. Wir sagen, Y folgt einer Verteilung. Die Sprungweite ist normalverteilt, die Anzahl an Flöhen folgt einer Poisson Verteilung, die Boniturnoten sind multinomial/ordinal bzw. kategorial verteilt. Der Infektionsstatus ist binomial verteilt. Wir werden uns später die Verteilungen anschauen und visualisieren. Das können wir hier aber noch nicht. Wichtig ist, dass du schon

4 Von Flöhen und Hunden

mal gehört hast, dass Y unterschiedlich *verteilt* ist, je nachdem welche Dinge wir messen.

Tabelle ?? zeigt dir die Darstellung der Daten von oben in einer einzigen Tabelle. Bitte beachte, dass genau eine Zeile für eine Beobachtung, in diesem Fall einem Hund, vorgesehen ist.

Tabelle 4.1: Sprunglängen [cm] für Hundeflöhe. Die Tabelle ist im Long-Format dargestellt.

animal	jump_length	flea_count	grade	infected
dog	5.7	18	8	0
dog	8.9	22	8	1
dog	11.8	17	6	1
dog	8.2	12	8	0
dog	5.6	23	7	1
dog	9.1	18	7	0
dog	7.6	21	9	0



Datei für von Flöhen und Hunden

Du findest die Datei `flea_dog.xlsx` auf GitHub [jkruppa.github.io/data/](https://github.com/jkruppa/github.io/tree/main/data/) als Excel oder auch als CSV.

5 Von Flöhen, Hunden und Katzen

Version vom September 14, 2022 um 08:45:07

Wir wollen jetzt das Beispiel von den Hunden und Flöhen um eine Spezies erweitern. Wir nehmen noch die Katzen mit dazu und fragen uns, wie sieht es mit der Sprungfähigkeit von Katzen und Hundeflöhen aus? Konzentrieren wir uns hier einmal auf die Sprungweite. Wir können wie in dem vorherigen Beispiel mit den Hundeflöhen die Sprungweiten [cm] der Katzenflöhe wieder in der gleichen Weise aufschreiben:

$$Y_{jump} = \{3.2, 2.2, 5.4, 4.1, 4.3, 7.9, 6.1\}.$$

Wenn wir jetzt die Sprungweiten der Hundeflöhe mit den Katzenflöhen vergleichen wollen haben wir ein Problem. Beide Zahlenvektoren heißen gleich, nämlich Y_{jump} . Wir könnten jeweils in die Indizes noch *dog* und *cat* schreiben als $Y_{jump, dog}$ und $Y_{jump, cat}$ und erhalten folgende Vektoren.

$$Y_{jump, dog} = \{5.7, 8.9, 11.8, 8.2, 5.6, 9.1, 7.6\}$$

$$Y_{jump, cat} = \{3.2, 2.2, 5.4, 4.1, 4.3, 7.9, 6.1\}$$

Dadurch werden die Indizes immer länger und unübersichtlicher. Auch das Y einfach Y_{dog} oder Y_{cat} zu nennen ist keine Lösung - wir wollen uns vielleicht später nicht nur die Sprungweite vergleichen, sondern vielleicht auch die Anzahl an Flöhen oder den Infektionsstatus. Dann ständen wir wieder vor dem Problem die Y für die verschiedenen Outcomes zu unterscheiden. Daher erstellen wir uns die Tabelle **??**. Wir haben jetzt eine *Datentabelle*.

5 Von Flöhen, Hunden und Katzen

Tabelle 5.1: Sprunglängen [cm] für Hunde- und Katzenflöhe.
Die Tabelle ist im Wide-Format dargestellt.

dog	cat
5.7	3.2
8.9	2.2
11.8	5.4
8.2	4.1
5.6	4.3
9.1	7.9
7.6	6.1

Intuitiv ist die Tabelle ?? übersichtlich und beinhaltet die Informationen die wir wollten. Dennoch haben wir das Problem, das wir in dieser Tabelle ?? nicht noch weitere Outcomes angeben können. Wir können die Anzahl an Flöhen auf den Hunde und Katzen nicht darstellen. Als Lösung ändern wir die Tabelle ?? in das Long-Format. Dargestellt in Tabelle ???. Jede Beobachtung belegt nun eine Zeile. Dies ist sehr wichtig im Kopf zu behalten, wenn du eigene Daten in z.B. Excel eingibts.

Tabelle 5.2: Tabelle der Sprunglängen [cm], Anzahl an Flöhen, Boniturnote sowie der Infektionsstatus von Hunde- und Katzenflöhe. Die Tabelle ist im Long-Format dargestellt.

animal	jump_length	flea_count	grade	infected
dog	5.7	18	8	0
dog	8.9	22	8	1
dog	11.8	17	6	1
dog	8.2	12	8	0
dog	5.6	23	7	1
dog	9.1	18	7	0
dog	7.6	21	9	0
cat	3.2	12	7	1
cat	2.2	13	5	0
cat	5.4	11	7	0
cat	4.1	12	6	0
cat	4.3	16	6	1
cat	7.9	9	6	0

animal	jump_length	flea_count	grade	infected
cat	6.1	7	5	0

💡 Datei für von Flöhen, Hunden und Katzen

Du findest die Datei `flea_dog_cat.xlsx` auf GitHub jkruppa.github.io/data/ als Excel oder auch als CSV.

6 Von Flöhen auf Tieren

Version vom September 14, 2022 um 08:45:16

Wir wollen jetzt das Beispiel von den Hunde- und Katzenflöhen um eine *weitere* Spezies erweitern. Wir nehmen noch die Füchse mit dazu und fragen uns, wie sieht es mit der Sprungfähigkeit von Hunde-, Katzen- und Fuchsflöhen aus?

Tabelle 6.1: Sprunglängen [cm] für Hunde-, Katzen- und Fuchsflöhe.

animal	jump_length	flea_count	grade	infected
dog	5.7	18	8	0
dog	8.9	22	8	1
dog	11.8	17	6	1
dog	8.2	12	8	0
dog	5.6	23	7	1
dog	9.1	18	7	0
dog	7.6	21	9	0
cat	3.2	12	7	1
cat	2.2	13	5	0
cat	5.4	11	7	0
cat	4.1	12	6	0
cat	4.3	16	6	1
cat	7.9	9	6	0
cat	6.1	7	5	0
fox	7.7	21	5	1
fox	8.1	25	4	1
fox	9.1	31	4	1
fox	9.7	12	5	1
fox	10.6	28	4	0
fox	8.6	18	4	1
fox	10.3	19	3	0

6 Von Flöhen auf Tieren

 Datei für von Flöhen auf Tieren

Du findest die Datei `flea_dog_cat_fox.xlsx` auf GitHub jkruppa.github.io/data/ als Excel oder auch als CSV.

7 Von Flöhen auf Tieren in Habitaten

Version vom September 14, 2022 um 08:45:27

Wir schauen uns in diesem Beispiel wiederum drei Tierarten an: Hunde, Katzen und Füchse. Auf diesen Tierarten messen wir die Sprunglänge von jeweils zehn Tieren. Im Vergleich zu dem vorherigen Beispiel erweitern wir die Daten um eine Spalte `site` in der wir vier verschiedene Messorte protokollieren. Es ergibt sich folgende Tabelle ?? und die dazugehörige Abbildung ??.

Tabelle 7.1: Sprunglängen [cm] für Hunde-, Katzen- und Fuchsflöhe in verschiedenen Habitaten.

animal	site	rep	jump_length
cat	city	1	12.04
cat	city	2	11.98
cat	city	3	16.10
cat	city	4	13.42
cat	city	5	12.37
cat	city	6	16.36
cat	city	7	14.91
cat	city	8	11.17
cat	city	9	12.38
cat	city	10	15.06
cat	smalltown	1	15.24
cat	smalltown	2	13.36
cat	smalltown	3	15.08
cat	smalltown	4	12.83
cat	smalltown	5	14.68
cat	smalltown	6	10.73
cat	smalltown	7	13.35
cat	smalltown	8	14.54

7 Von Flöhen auf Tieren in Habitaten

animal	site	rep	jump_length
cat	smalltown	9	12.99
cat	smalltown	10	14.51
cat	village	1	17.59
cat	village	2	11.24
cat	village	3	12.44
cat	village	4	13.63
cat	village	5	14.92
cat	village	6	17.43
cat	village	7	18.30
cat	village	8	16.35
cat	village	9	16.34
cat	village	10	14.23
cat	field	1	13.70
cat	field	2	15.13
cat	field	3	17.99
cat	field	4	14.60
cat	field	5	16.16
cat	field	6	14.26
cat	field	7	15.39
cat	field	8	16.85
cat	field	9	19.02
cat	field	10	18.76
dog	city	1	19.35
dog	city	2	17.10
dog	city	3	19.85
dog	city	4	15.33
dog	city	5	15.15
dog	city	6	19.57
dog	city	7	15.44
dog	city	8	16.09
dog	city	9	15.91
dog	city	10	13.01
dog	smalltown	1	17.72
dog	smalltown	2	17.11
dog	smalltown	3	17.57
dog	smalltown	4	17.12
dog	smalltown	5	16.02
dog	smalltown	6	22.61
dog	smalltown	7	16.49

animal	site	rep	jump_length
dog	smalltown	8	18.64
dog	smalltown	9	17.21
dog	smalltown	10	19.90
dog	village	1	16.60
dog	village	2	15.28
dog	village	3	16.91
dog	village	4	15.08
dog	village	5	18.56
dog	village	6	16.34
dog	village	7	17.61
dog	village	8	14.80
dog	village	9	17.52
dog	village	10	16.93
dog	field	1	15.78
dog	field	2	17.02
dog	field	3	15.41
dog	field	4	15.61
dog	field	5	19.87
dog	field	6	19.24
dog	field	7	17.65
dog	field	8	18.83
dog	field	9	17.60
dog	field	10	14.67
fox	city	1	19.50
fox	city	2	18.49
fox	city	3	19.78
fox	city	4	19.45
fox	city	5	21.56
fox	city	6	21.37
fox	city	7	18.64
fox	city	8	20.08
fox	city	9	21.62
fox	city	10	20.68
fox	smalltown	1	19.81
fox	smalltown	2	17.78
fox	smalltown	3	19.65
fox	smalltown	4	16.38
fox	smalltown	5	17.46
fox	smalltown	6	17.02

7 Von Flöhen auf Tieren in Habitaten

animal	site	rep	jump_length
fox	smalltown	7	19.38
fox	smalltown	8	15.89
fox	smalltown	9	17.15
fox	smalltown	10	17.43
fox	village	1	15.32
fox	village	2	17.59
fox	village	3	15.70
fox	village	4	18.58
fox	village	5	16.85
fox	village	6	18.25
fox	village	7	18.75
fox	village	8	16.96
fox	village	9	13.38
fox	village	10	18.38
fox	field	1	16.85
fox	field	2	13.55
fox	field	3	13.89
fox	field	4	15.67
fox	field	5	16.38
fox	field	6	14.59
fox	field	7	14.03
fox	field	8	13.63
fox	field	9	14.09
fox	field	10	15.52

Über die explorative Datenanalyse

Die Datentabelle ist in dieser Form schon fast nicht mehr überschaubar. Daher hilft hier die explorative Datenanalyse weiter.

Wir schauen uns daher die Daten einmal als einen Boxplot in Abbildung ?? an. Wir sehen hier, dass wir drei Tierarten an vier Orten die Sprungweite in [cm] gemessen haben.



Datei für von Flöhen auf Tieren in Habitaten

Du findest die Datei `flea_dog_cat_fox_site.xlsx` auf GitHub jkruppa.github.io/data/ als Excel oder auch als CSV.

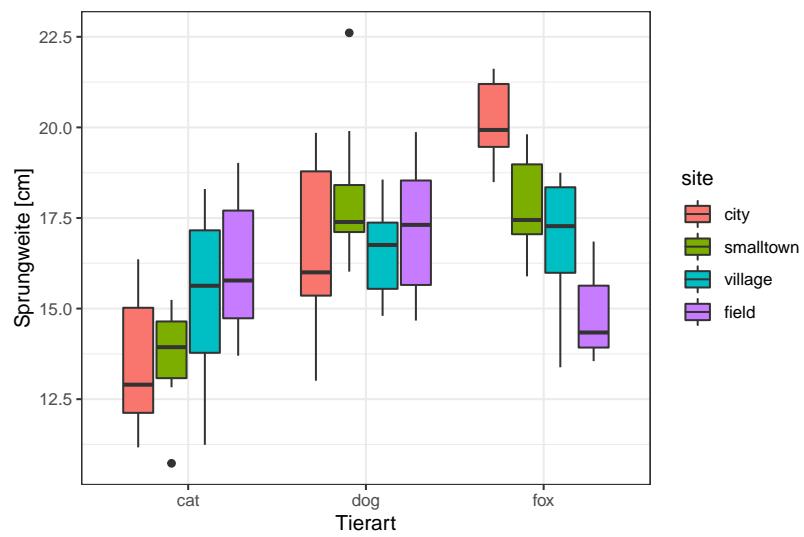


Abbildung 7.1: Boxplot der Sprungweiten [cm] für Hunde-, Katzen- und Fuchsflöhe in verschiedenen Habitaten.

8 Von vielen Flöhen auf Hunden und Katzen

Version vom September 14, 2022 um 08:45:38

Wir schauen uns in diesem Beispiel wiederum nur zwei Tierarten an: Hunde und Katzen. Auf diesen Tierarten messen wir wieder die Sprunglänge in [cm] von jeweils 400 Tieren. Im Vergleich zu dem vorherigen Beispiel erweitern wir die Daten um eine Spalte `jump_weight` in [mg] sowie `sex` [male, female]. Bei Versuch wurde noch in der Variable `hatch_time` gemessen, wie lange die Flöhe in Stunden zum Schlüpfen brauchen. Es ergibt sich folgende Tabelle ?? mit den ersten zehn Beobachtungen und die dazugehörige Abbildung ??.

Tabelle 8.1: Sprunglängen [cm], Gewichte [mg], Geschlecht [sex] und Schlüpfzeit [h] für Hunde- und Katzenflöhe.

animal	sex	weight	jump_length	flea_count	hatch_time
cat	male	6.02	15.79	5	483.60
cat	male	5.99	18.33	1	82.56
cat	male	8.05	17.58	1	296.73
cat	male	6.71	14.09	3	140.90
cat	male	6.19	18.22	1	162.20
cat	male	8.18	13.49	1	167.47
cat	male	7.46	16.28	1	291.20
cat	male	5.58	14.54	0	112.58
cat	male	6.19	16.36	1	143.97
cat	male	7.53	15.08	1	766.31

Die Datentabelle ist in dieser Form schon fast nicht mehr überschaubar. Daher hilft hier die explorative Datenanalyse weiter. Wir schauen uns daher die Daten einmal als einen Scatterplot

Über die explorative Datenanalyse erfährst du mehr im Kapitel ??

8 Von vielen Flöhen auf Hunden und Katzen

in Abbildung ?? an. Wir sehen hier, dass wir das mit dem Gewicht [mg] der Flöhe auch die Sprungweite in [cm] steigt.

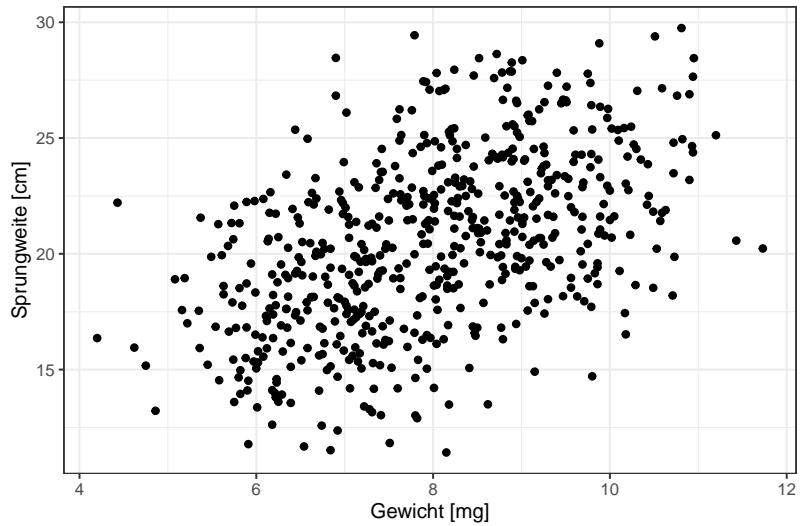


Abbildung 8.1: Scatterplot der Sprunglängen [cm] und Gewichte [mg] für Hunde- und Katzenflöhe.



Datei für von vielen Flöhen auf Hunden und Katzen

Du findest die Datei `flea_dog_cat_length_weight.xlsx` auf GitHub [jkruppa.github.io/data/](https://github.com/jkruppa/github.io/tree/main/data/) als Excel oder auch als CSV.

9 Gummibärchen

Version vom September 14, 2022 um 08:45:45

💡 Gummibärchen Daten und die explorative Datenanalyse

Du findest auf YouTube die Gummibärchen Daten und die explorative Datenanalyse als Video. Vielleicht interessiert es dich mal so eine Auswertung im Video anzuschauen.

Im Folgenden sehen wir in Tabelle ?? den Gummibärchen Datensatz, der im Laufe der letzten Jahre entstanden ist. Dabei wächst der Datensatz von Semester zu Semester immer ein wenig weiter. Jedes Semester darf Tütchen aufreißen und schauen was da so drin ist.

Wir erheben folgende Variablen im Datensatz. Dabei unterscheiden wir einmal in Daten, die technischer Natur sind:

- **year**, das Jahr in dem die Daten erhoben wurden.
- **module**, das Modul in welchem die Daten erhoben wurden. Am Anfang wurde das Modul noch nicht erfasst.
- **darkred** bis **white**, die Anzahl an Gummibärchen in der jeweiligen Farbe.
- **count_bears**, die Anzahl an Gummibärchen in der entsprechenden Tüte.
- **count_color**, die Anzahl an Farben und damit Geschmacksrichtungen in einer Tüte.

Dann wollen wir aber auch noch etwas über den Studierenden wissen, der die Tüte aufgemacht hat. Wir erheben hier noch einige demographische Informationen:

- **most_liked**, der Lieblingsgeschmack des Studierenden.
- **gender**, das Geschlecht des Studierenden. Aktuell gibt es nur männlich oder weiblich Studierende.

Wenn dich der Ablauf technisch interessiert findet du unter Kruppa und Sieg (2021) mehr Informationen dazu.

9 Gummibärchen

Tabelle 9.1: Auszug aus dem Daten zu den Gummibärchendaten.

year	moduledark	light	tocandy	yellow	green	white	count	cobertura	height	skewness	kurtosis	heightmester
2018NA	0	0	5	4	0	0	9	3	lightred	35	193	10
2018NA	0	3	1	4	1	1	10	5	yellow	21	159	6
2018NA	1	2	2	2	1	1	9	6	whitev	21	159	6
2018NA	2	0	2	1	2	3	10	5	whitev	36	180	10
2018NA	2	1	1	2	2	2	10	6	whiten	22	180	3
2018NA	2	4	1	2	0	1	10	5	whiten	NANA	NA	NA
...
202Fakultaetsinformatiknstag	2			12			5	darkred	46	165	0	
202Fakultaetsinformatiknstag	3			10			2	darkred	55	177	0	
202Fakultaetsinformatiknstag	1			9			5	greenw	46	173	0	
202Fakultaetsinformatidnstag	4			12			6	whitev	21	168	0	
202Fakultaetsinformatiknstag	2			8			5	greem	24	183	0	
202Fakultaetsinformatidnstag	2			9			5	darkred	21	171	0	

- **age**, das Alter in Jahren [y] der Studierenden.
- **height**, die Körpergröße des Studierenden in [cm]
- **semester**, das aktuelle Semester des Studierenden. Wir unterscheiden nicht zwischen Bachelor und Master

Aktuell hat der Datensatz $n = 315$ Beobachtungen. Da der Datensatz aber immer weiter wächst brauchen wir wirklich R dazu um den Datensatz uns anschauen zu können.

 Datei für von Flöhen, Hunden und Katzen

Du findest die Datei `gummibears.xlsx` auf GitHub [jkruppa.github.io/data/](https://github.com/jkruppa/github.io/tree/main/_data/) als Excel Datei.

Referenzen

Teil II

Programmieren in R

Version vom September 14, 2022 um 08:45:52

Was solltest du nun zuerst Lesen? Es ist sehr schwierig die Programmierung exakt so zu schreiben, dass das Programmieren *linear* verständlich ist. Du brauchst im Prinzip das Wissen aus Kapitel ?? *Operatoren, Funktionen und Pakete* um die Grundlagen zu verstehen. Auf der anderen Seite fehlt dir vielleicht noch das Verständnis von Buchstaben und Zahlen in R. Diesen Zusammenhang zwischen Buchstaben und Zahlen erkläre ich als erstes im folgenden Kapitel ?? *Von Buchstaben und Zahlen*.

Im vorherigen Kapitel zu den Beispielen haben wir die Datentabelle Tabelle ?? mit den Hunde- und Katzenflöhen erschaffen. Bevor wir uns weiter mit statistischen Kennzahlen beschäftigen, wollen wir uns einmal die Realisierung der Tabelle Tabelle ?? mit den Hunde- und Katzenflöhen in R anschauen. Dabei wollen wir auch Eigenschaften von Zahlen und Buchstaben lernen, die notwendig sind um mit einem Programm wie R kommunizieren zu können. Wir wollen später R nutzen um die explorative Datenanalyse anzuwenden. Über die explorative Datenanalyse lernen wir in späteren Kapiteln mehr.

Einführung in R per Video

Du findest auf YouTube Grundlagen in R als Video Reihe. Ich werde zwar alles nochmal hier als Text aufschreiben, aber manchmal ist das Sehen und Hören dann einfacher.

10 Von Buchstaben und Zahlen

Version vom September 14, 2022 um 08:45:59

Im Kapitel ?? haben wir uns die Sprungweiten und andere Eigenschaften von Hunden und Katzen angeschaut. Bevor wir uns weiter mit statistischen Kennzahlen beschäftigen, wollen wir uns einmal die Realisierung der Tabelle ?? in R anschauen. Das heist, wie ist eine Tabelle in R aufgebaut und was sehen wir da eigentlich?

Tabelle 10.1: Sprunglängen [cm] für Hunde- und Katzenflöhe.

animal	jump_length	flea_count	grade	infected
dog	5.7	18	8	FALSE
dog	8.9	22	8	TRUE
dog	11.8	17	6	TRUE
dog	8.2	12	8	FALSE
dog	5.6	23	7	TRUE
dog	9.1	18	7	FALSE
dog	7.6	21	9	FALSE
cat	3.2	12	7	TRUE
cat	2.2	13	5	FALSE
cat	5.4	11	7	FALSE
cat	4.1	12	6	FALSE
cat	4.3	16	6	TRUE
cat	7.9	9	6	FALSE
cat	6.1	7	5	FALSE

Dabei wollen wir auch Eigenschaften von Zahlen und Buchstaben lernen, die notwendig sind um mit einem Programm wie R kommunizieren zu können. Nun haben wir in der Tabelle ?? mit Daten zu verschiedenen Outcomes, wie Sprungweite [cm],

Anzahl an Flöhen auf Hunden und Katzen, die Boniturnoten oder aber den Infektionsstatus. Die Tabelle ist zwar nicht groß aber auch nicht wirklich klein. Wir wollen uns nun damit beschäftigen, die Zahlen sinnvoll in R darzustellen. Wir wollen mit der Darstellung einer Datentabelle in R beginnen, einem `tibble()`.

10.1 Daten in R sind `tibble()`

Im folgenden sehen wir die Daten aus der Tabelle ?? in R als `tibble` dargestellt. Was ist nun ein `tibble`? Ein `tibble` ist zu aller erst ein Speicher für Daten in R. Das heist wir haben Spalten und Zeilen. Jede Spalte repräsentiert eine Messung oder Variable und die Zeilen jeweils eine Beobachtung.

```
# A tibble: 14 x 5
  animal jump_length flea_count grade infected
  <chr>      <dbl>     <int> <dbl> <lgl>
1 dog         5.7       18    8 FALSE
2 dog         8.9       22    8 TRUE
3 dog        11.8       17    6 TRUE
4 dog         8.2       12    8 FALSE
5 dog         5.6       23    7 TRUE
6 dog         9.1       18    7 FALSE
7 dog         7.6       21    9 FALSE
8 cat         3.2       12    7 TRUE
9 cat         2.2       13    5 FALSE
10 cat        5.4       11    7 FALSE
11 cat        4.1       12    6 FALSE
12 cat        4.3       16    6 TRUE
13 cat        7.9       9    6 FALSE
14 cat        6.1       7    5 FALSE
```

Als erstes erfahren wir, dass wir einen `A tibble: 14 x 5` vorliegen haben. Das heist, wir haben 14 Zeile und 5 Spalten. In einem `tibble` wird immer in der ersten Zeile angezeigt wieviele Beobachtungen wir in dem Datensatz haben. Wenn das `tibble` zu groß wird, werden wir nicht mehr das ganze `tibble` sehen

10.2 Faktoren als Wörter zu Zahlen

sondern nur noch einen Ausschnitt. Im Weiteren hat jede Spalte noch eine Eigenschaft unter dem Spaltennamen:

- `<chr>` bedeutet **character**. Wir haben also hier Worte vorliegen.
- `<dbl>` bedeutet **double**. Ein **double** ist eine Zahl mit Kommastellen.
- `<int>` bedeutet **integer**. Ein **integer** ist eine ganze Zahl ohne Kommastellen.
- `<lgl>` bedeutet **logical** oder **boolean**. Hier gibt es nur die Ausprägung *wahr* oder *falsch*. Somit **TRUE** oder **FALSE**. Statt den Worten **TRUE** oder **FALSE** kann hier auch 0 oder 1 stehen.
- `<str>` bedeutet **string** der aus verschiedenen **character** besteht kann, getrennt durch Leerzeichen.

💡 Zahlen, Buchstaben, Skalenniveau - Was ist das eigentlich?

Du findest auf YouTube Einführung in R - Teil 06 - Zahlen, Buchstaben, Skalenniveau - Was ist das eigentlich? als Video. Hier erkläre ich den Zusammenhang nochmal in einem Video.

10.2 Faktoren als Wörter zu Zahlen

Ein Computer und somit auch eine Programmsprache wie R kann keine Buchstaben *verrechnen*. Ein Programm kann nur mit Zahlen rechnen. Wir haben aber in der Tabelle `??` in der Spalte `animal` Buchstaben stehen. Da wir hier einen Kompromiss eingehen müssen führen wir Faktoren ein. Ein Faktor kombiniert Buchstaben mit Zahlen. Wir als Anwender sehen die Buchstaben, die Wörter bilden. Intern steht aber jedes Wort für eine Zahl, so dass R mit den Zahlen rechnen kann. Klingt ein wenig kryptisch, aber wir schauen uns einen **factor** einmal an.

```
data_tbl$animal[1:8]
```

Ein **Faktor** ist eine Variable mit mehreren **Faktorstufen** oder **Leveln**. Für uns sieht der Faktor wie ein Wort aus, hinter jedem Wort steht aber eine Zahl mit der gerechnet werden kann.

10 Von Buchstaben und Zahlen

```
[1] "dog" "dog" "dog" "dog" "dog" "dog" "dog" "cat"
```

Was haben wir gemacht? Als erstes haben wir die Spalte `animal` aus dem Datensatz `data_tbl` mit dem Dollarzeichen `$ herausgezogen`. Mit dem `$` Zeichen können wir uns eine einzelne Spalte aus dem Datensatz `data_tbl` rausziehen. Du kannst dir das `$` wie einen Kleiderbügel und das `data_tbl` als einen Schrank für Kleiderbügel verstellen. An dem Kleiderbügel hängen dann die einzelnen Zahlen und Worte. Wir nehmen aber nicht den ganzen Vektor sondern nur die Zahlen 1 bis 8, dargestellt durch `[1:8]`. Die Gänsefüße " um `dog` zeigen uns, dass wir hier Wörter oder `character` vorliegen haben. Schauen wir auf das Ergebnis, so erhalten wir sieben Mal `dog` und einmal `cat`. Insgesamt die ersten acht Einträge der Datentabelle. Wir wollen diesen Vektor uns nun einmal als Faktor anschauen. Wir nutzen die Funktion `as.factor()`.

Kannst du im

Kapitel ?? mehr erfahren.

```
as.factor(data_tbl$animal[1:8])
```

```
[1] dog dog dog dog dog dog dog cat  
Levels: cat dog
```

Im direkten Vergleich verschwinden die Gänsefüße " um `dog` und zeigen uns, dass wir hier keine `character` mehr vorliegen haben. Darüber hinaus sehen wir auch, dass die der Faktor jetzt `Levels` hat. Exakt zwei Stück. Jeweils einen für `dog` und einen für `cat`. Wir werden später Faktoren benötigen, wenn wir zum Beispiel eine einfaktorielle ANOVA rechnen. Hier siehst du schon den Begriff *Faktor* wieder.

Wir brauchen später zum Modellieren einen Datensatz, der **meist** aus einer `Outcome`-Spalte einer `Faktor`-Spalte mit der `Behandlung` und einer `Faktor`-Spalte mit dem `Block` oder `Cluster`. Das kann etwas verwirrend sein, denn es gibt in R Wörter `string <str>` oder `character <chr>`. Wörter sind was anderes als Objekte. Streng genommen sind beides Wörter, aber in `Outcome ~ Behandlung + Block` werden Dinge gespeichert wohin gegen das Wort einfach ein Wort ist. Deshalb kennzeichnen wir Wörter auch mit

10.4 Zusammenfassung

Gänsefußchen als win "wort" und zeigen damit, dass es sich hier um einen String handelt.

Wir tippen "animal" in R und erhalten "animal" als Wort zurück. Das sehen wir auch an dem Ausdruck mit den Gänsefußchen.

```
"animal"
```

```
[1] "animal"
```

Wir tippen `animal` ohne die Anführungszeichen in R und erhalten den Inhalt von `animal` ausgegeben. Dafür müssen wir aber das Objekt `animal` erst einmal über den Zuweisungspfeil `<-` erschaffen.

```
animal <- c("dog", "cat", "fox")
animal
```

```
[1] "dog" "cat" "fox"
```

Sollte es das Objekt `animal` nicht geben, also nicht über den Zuweisungspfeil `<-` erschaffen worden, dann wird eine Fehlermeldung von R ausgegeben:

```
Fehler in eval(expr, envir, enclos) : Objekt 'animal'
nicht gefunden
```

Über den Zuweisungspfeil `<-` kannst du im Kapitel ?? mehr erfahren.

10.4 Zusammenfassung

Tabelle ?? zeigt eine Übersicht wie einzelne Variablennamen und deren zugehörigen Beispielen sowie den Namen in R, der Informatik allgemein, als Skalennevau und welcher Verteilungsfamilie die Variable angehören würde. Leider ist es so, dass wieder gleiche Dinge unterschiedliche benannt werden. Aber an dieses doppelte Benennen können wir uns in der Statistik schonmal gewöhnen.

Variablenamen meint hier immer den **Namen der Spalte** im Datensatz bzw. `tibble`

Tabelle 10.2: Zusammenfassung und Übersicht von Variablennamen und deren Benennung in R, in der Informationsweise allgemein, als Skalenniveau und die dazugehörige Verteilungsfamilie.

Variable	Beispiel	R	Infomatik	Skalenniveau	Verteilungsfamilie
weight	12.3, 12.4, 5.4, 21.3, 13.4	numeridouble	continuous		Gaussian
count	5, 0, 12, 23, 1, 4, 21	integerinteger	discrete		Poisson
dosis	low, mid, high	ordered	categorical / ordinal		Ordinal
field	mainz, berlin, kiel	factor	categorical		Multinomial
cancer	0, 1	factor	dichotomous / binary / nominal		Binomial
treatment	“placebo”, “aspirin”	charactercharacter	dichotomous / binary / nominal		Binomial
birth	2001-12-02, 2005-05-23	date			

11 Operatoren, Funktionen und Pakete

Version vom September 14, 2022 um 08:46:11

Es ist immer schwierig, wann die Grundlagen von R einmal gelehrt werden sollte. Wenn du nichts von Programmierung bis jetzt gehört hast, dann mag es keinen Sinn ergeben mit Operatoren, wie dem Zuweisungspfeil `<-` und der Pipe `%>%` zu beginnen. Wir brauchen aber für die Programmierung folgende zentrale Konzepte.

- Wir müssen zusätzliche Pakete in R installieren und laden können (siehe Kapitel ??).
- Wir müssen verstehen wie wir uns einen Vektor mit `c()` bauen (siehe Kapitel ??).
- Wir müssen wissen was eine Funktion in R ist (siehe Kapitel ??).
- Wir müssen den Operator Zuweisungspfeil `<-` verstehen und anwenden können (siehe Kapitel ??).
- Wir müssen den Operator Pipe `%>%` verstehen und anwenden können (siehe Kapitel ??).
- Wir müssen den Operator `$` verstehen, da manche Funktionen in R nicht mit Datensätzen sondern nur mit Vektoren arbeiten können (siehe Kapitel ??).
- Wir müssen verstehen wie wir ein Modell in R mit der Tilde `~` definieren (siehe Kapitel ??).
- Wir müssen wissen und verstehen wie wir mit `?` englische Hilfeseiten öffnen können (siehe Kapitel ??).

Nicht alle Konzepte brauchst du *unmittelbar* aber ich nutze diese Konzepte wiederholt in allen Kapiteln, so dass du hier immer wieder mal schauen kannst, was die Grundlagen sind.

11.1 Pakete und library()

In der *Vanilla*-Variante hat R sehr wenige Funktionen. Ohne zusätzliche Pakete ist R mehr ein sehr potenter Taschenrechner. Leider mit der Funktionalität aus den 90'zigern, was die Programmierumgebung und die Funktionen angeht. Das wollen wir aber nicht. Wir wollen auf den aktuellen Stand der Technik und auch Sprache programmieren. Daher nutzen wir zusätzliche R Pakete.

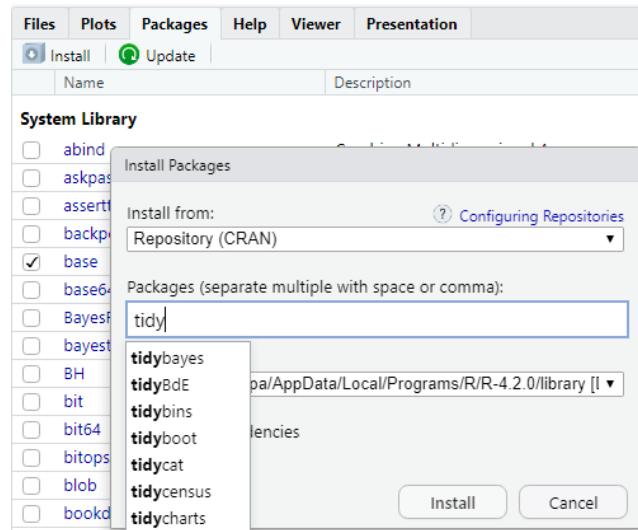


Abbildung 11.1: Auf den Reiter *Packages* klicken und dann *Install*. In der deutschen version vom RStudio mögen die Begriffe leicht anders sein.

In Abbildung ?? wird gezeigt wie du ein zusätzliches Paket installieren kannst. Hierbei ist nochmal wichtig den semantischen Unterschied zu wissen. Es gibt das Paket *tidyverse* was wir viel nutzen. Wir installieren *einmalig* Pakete der Funktion *install.packages()* oder eben wie in Abbildung ?? gezeigt. Wir nutzen die Funktion *library()* um ein Paket in R zu laden. Ja, es müsste anders heisen, tut es aber nicht.

```
## Das Paket tidyverse installieren - einmalig
install.packages(tidyverse)
```

11.2 Einen Vektor bauen `c()`

```
## Das Paket tidyverse laden - jedes Mal  
library(tidyverse)
```

Nun muss man sich immer merken, ob das Paket schon installiert ist oder man schreibt relativ viele `library()` untereinander. Das passiert schnell, wenn du viele Pakete laden willst. Dafür erlaubt dir das Paket `pacman` eine Vereinfachung. Die Funktion `p_load()` installiert Pakete, wenn die Pakete nicht installiert sind. Sollten die Pakete installiert sein, so werden die Pakete geladen. Du musst nur einmal `install.packages(pacman)` ausführen um das Paket `pacman` zu installieren.

```
pacman::p_load(tidyverse, magrittr, readxl)
```

Schlussendlich gibt es noch die Möglichkeit sich alles nochmal bei YouTube anzuschauen.

💡 Unterschied von Packages und Libraries in R

Du findest auf YouTube Einführung in R - Teil 03 - Unterschied Packages und Libraries in R als Video. Hier erkläre ich nochmal den Ablauf zwischen Installieren eines Paketes und dem Laden eines Paketes.

11.2 Einen Vektor bauen `c()`

Wir können mit der Funktion `c()` Zahlen und Wörter zu einem Vektor kombinieren.

```
c("dog", "dog", "cat", "cat", "fox", "fox")
```

```
[1] "dog" "dog" "cat" "cat" "fox" "fox"
```

Hier werden die Wörter “dog”, “cat” und “fox” miteinander in einen Vektor kombiniert. Wir erinnern uns an das \$ Zeichen, was uns erlaubt eine Variable als Vektor aus einem `tibble()` herauszuziehen.

11.3 Funktionen

Wir haben schon einige Funktion nebenbei in R kennengelernt. Zum einen `as.factor()` um einen Faktor zu erstellen oder aus dem Kapitel ??, wo wir die Funktion `install.packages()` nutzen um ein Paket zu installieren oder aber die Funktion `library()` um ein Paket in R zu laden.

Funktionen sehen aus wie Wörter. Haben aber keine Gänsefüßchen und beinhalten auch keine Daten oder Vektoren. Funktionen können mit Daten und Vektoren rechnen und geben das Berechnete dann wieder. Nehmen wir als Beispiel die Funktion `mean()`, die den Mittelwert von einer Reihe Zahlen berechnet.

```
y <- c(1.2, 3.4, 2.1, 6, 4.3)
mean(y)
```

```
[1] 3.4
```

Wir sehen, dass wir mit der Funktion `c()` die Zahlen 1.2, 3.4, 2.1, 6, 4.3 zusammenkleben. Danach speichern wir die Zahlen in den Objekt `y` als einen Vektor ab. Wir müssen `ynicht` erst erschaffen, das Erschaffen und Speichern passiert in R in einem Schritt. Wir stecken nun den Vektor `y` in die Funktion `mean()` und erhalten den Mittelwert von 3.4 der Zahlen wiedergegeben.

Eigentlich müssen in der Programmierung Objekte erst **deklariert** werden und somit erschaffen. Erst dann können **Objekte initialisiert** und somit befüllt bzw. etwas zugewiesen werden. Mit dem Zuweisungspfeil **<-** speichern wir *Dinge* in Objekte in R. Das heißt wir speichern damit intern in R Datensätze und viele andere Sachen, die wir dan später wieder verwenden wollen. Schauen wir uns das einmal im Beispiel an. Schreiben wir nur den Vektor `c()` mit Hunden und Katzen darin, so erscheint eine Ausgabe in R.

```
c("dog", "dog", "cat", "cat", "fox", "fox")
```

11.5 Pipe %>%

```
[1] "dog" "dog" "cat" "cat" "fox" "fox"
```

Schreiben wir den gleichen Vektor und nutzen den Zuweisungspfeil, dann wird der Vektor in dem Objekt `animal` gespeichert.

```
animal <- c("dog", "dog", "cat", "cat", "fox", "fox")
```

Wie kommen wir jetzt an die Sachen, die in `animal` drin sind? Wir können einfach `animal` in R schreiben und dann wird uns der Inhalt von `animal` ausgegeben.

```
animal
```

```
[1] "dog" "dog" "cat" "cat" "fox" "fox"
```

Wir nutzen den Zuweisungspfeil `<-` ist zentral für die Nutzung von R. Wir brauchen den Zuweisungspfeil `<-` um Objekte in R zu erschaffen und Ergebnisse intern abzuspeichern. Zusammen mit Funktionen nutzen wir nur noch die Pipe `%>%` öfter.

Der Zuweisungspfeil `<-` ist zentral für die Nutzung von R.

11.5 Pipe %>%

Pipes in R

Du findest auf YouTube Einführung in R - Teil 11 - Pipes in R als Video. Hier erkläre ich den Zusammenhang nochmal in einem Video.

Im Weiteren nutzen wir den Pipe Operator dargestellt als `%\>%`. Du kannst dir den Pipe Operator als eine Art Röhre vorstellen in dem die Daten verändert werden und dann an die nächste Funktion weitergeleitet werden. Im folgenden siehst du viele Funktionen, die aneinander über Objekte miteinander verbunden werden. Im Kapitel ?? erfährst du mehr über die Funktionen `select()` und `filter()`.

11 Operatoren, Funktionen und Pakete

```
data_tbl <- read_excel("data/flea_dog_cat.xlsx")
animal_1_tbl <- select(data_tbl, animal, jump_length)
animal_2_tbl <- filter(animal_1_tbl, jump_length >= 4)
sort(animal_2_tbl$jump_length)
```

```
[1] 4.1 4.3 5.4 5.6 5.7 6.1 7.6 7.9 8.2 8.9 9.1 11.8
```

```
data_tbl %>%
  select(animal, jump_length) %>%
  filter(jump_length >= 4) %>%
  pull(jump_length) %>%
  sort
```

```
[1] 4.1 4.3 5.4 5.6 5.7 6.1 7.6 7.9 8.2 8.9 9.1 11.8
```

Im unteren Beispiel siehst du die Nutzung des Pipe Operators `%>%`. Das Ergebnis ist das gleiche, aber der Code ist einfacher zu lesen. Wir nehmen den Datensatz `data_tbl` leiten den Datensatz in den Funktion `select()` und wählen die Spalten `animal` sowie `jump_length`. Dann filtern wir noch nach `jump_length` größer als 4 cm. Dann ziehen wir uns mit der Funktion `pull()` die Spalte `jump_length` aus dem Datensatz. Den Vektor leiten wir dann weiter in die Funktion `sort()` und erhalten die sortierten Sprunglängen zurück.

11.6 Spalte extrahieren \$

Wir nutzen eigentlich die Funktion `pull()` um eine Spalte bzw. Vektor aus einem Datensatz zu extrahieren.

```
data_tbl %>%
  pull(animal)
```

```
[1] "dog" "dog" "dog" "dog" "dog" "dog" "dog" "cat" "cat" "cat"
[13] "cat" "cat"
```

11.7 Modelle definieren mit `formula`

Manche Funktionen in R, besonders die älteren Funktionen, benötigen keinen Datensatz sondern meist zwei bis drei Vektoren. Das heißt, wir können nicht einfach einen Datensatz in eine Funktion über `data = data_tbl` stecken sondern müssen der Funktion Vektoren übergeben. Dafür nutzen wir den `$` Operator.

```
data_tbl$animal
```

```
[1] "dog" "dog" "dog" "dog" "dog" "dog" "dog" "cat" "cat" "cat" "cat" "cat"  
[13] "cat" "cat"
```

```
data_tbl$jump_length
```

```
[1] 5.7 8.9 11.8 8.2 5.6 9.1 7.6 3.2 2.2 5.4 4.1 4.3 7.9 6.1
```

Wir werden versuchen diese Schreibweise zu vermeiden, aber manchmal ist es sehr nützlich die Möglichkeit zu haben auf diese Weise eine Spalte zu extrahieren.

11.7 Modelle definieren mit `formula`

Wir müssen später Modelle in R definieren um zum Beispiel den t Test oder aber eine lineare Regression rechnen zu können. Wir nutzen dazu in R die `formula` Syntax. Das heißt links von der Tilde `~` steht das y , also der Spaltenname aus dem Datensatz `data` = den wir nutzen, der das Outcome repräsentiert. Rechts von der Tilde `~` stehen alle x_1, \dots, x_p , also alle Spalten aus dem Datensatz `data` = den wir nutzen, der die Einflussfaktoren repräsentiert.

In unserem Beispiel mit den Hunde- und Katzenflöhen aus Kapitel ?? wäre das y die Spalte `jump_length` und das x der Faktor `animal`. Wir erstellen mit der Funktion `formula()` das Modell in R. Wir brauchen später die Funktion `formula` nur implizit, aber hier ist es gut, das du einmal siehst, wie so eine Formula in R aussieht.

11 Operatoren, Funktionen und Pakete

```
formula(jump_length ~ animal)
```

```
jump_length ~ animal
```

Wenn die Formel sehr lang wird bzw. wir die Namen der Spalten aus anderen Funktionen haben, können wir auch die Funktion `reformulate()` nutzen. Wir brauchen die Funktion aber eher im Bereich des maschinellen Lernens. Hier ist die Funktion `reformulate()` aufgeführt, da es inhaltlich passt.

```
reformulate(term.labels = c("animal", "sex", "site"),
            response = "jump_length",
            intercept = TRUE)
```

```
jump_length ~ animal + sex + site
```

11.8 Hilfe mit ?

Das Fragezeichen `?` vor einem Funktionsnamen erlaubt die Hilfeseite zu öffnen. Die Hilfsseiten findest du auch in einem der Reiter im RStudio.

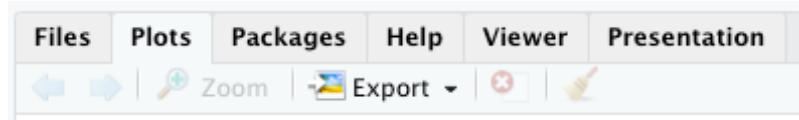


Abbildung 11.2: Neben den Paketen in R findet sich auch der Reiter Help, wo du Hilfe für die einzelnen Funktionen findest..

12 Daten einlesen

Version vom September 14, 2022 um 08:46:20

Die Daten aus unserem Experiment müssen rein in R. Das heißt, wir haben meist unsere Daten in einer Exceldatei vorliegen und wollen diese Daten nun in R einlesen.

Gängige Fehler beim Einlesen von Dateien in R sind folgende Probleme. Wir wollen diese Probleme nacheinander einmal durchgehen. Aber keine Sorge, das Einlesen von Daten in R ist immer am Anfang etwas frickelig. Du kannst gerne in das R Tutorium (siehe Kapitel ?? für Raum und Zeiten) kommen, dann können wir dir da beim Einlesen der Daten helfen.

- das Format der Daten ist nicht richtig (Kapitel ??)
- der Pfad zur Datei ist falsch (Kapitel ??)
- in der Datei sind komische Zeichen, wie Umlaute und Co. (Kapitel ??)
- in der Datei sind Leerzeichen in den Spaltennamen (Kapitel ??)

Im Anhang ?? findest du Beispiele für die Auswertung von Daten. Du kannst dir dort das Format anschauen und dann entsprechend deine Daten formatieren. Du findest auch alle Dateien auf GitHub unter jkruppa.github.io/data/ als Excel oder auch als CSV. Schau dir die Beispiele einmal an.

12.1 Genutzte R Pakete für das Kapitel

Wir wollen folgende R Pakete in diesem Kapitel nutzen.

```
pacman::p_load(tidyverse, magrittr, janitor)
```

Am Ende des Kapitels findest du nochmal den gesamten R Code in einem Rutsch zum selber durchführen oder aber kopieren.

12.2 Dateiformat

Wir unterschieden bei Datenformaten zwischen den Wide Format und dem Long Format. Meistens gibst du die Daten intuitiv im Wide Format in Excel ein. Das ist in Excel auch übersichtlicher. R und später die Funktion `ggplot()` zur Visualisierung der Daten kann aber nur mit dem Long Format arbeiten. Wir können aber mit der Funktion `gather()` das Wide Format in das Long Format umwandeln.

12.2.1 Wide Format

In Tabelle ?? sehen wir eine typische Datentabelle in einem Wide Format. Die Spalten ergeben jeweils die Tierart wieder und die Einträge in den Spalten sind die Sprungweiten in [cm].

Tabelle 12.1: Eine Datentabelle mit Sprungweiten in [cm] von Hunde- und Katzenflöhen im Wide Format.

	dog	cat
5.2	10.1	
4.9	9.4	
12.1	11.8	
8.2	6.7	
5.6	8.2	
9.1	9.1	
7.4	7.1	

Wir können diese Datentabelle auch in R erstellen und uns als `tibble()` wiedergeben lassen.

```
jump_wide_tbl <- tibble(dog = c(5.2, 4.9, 12.1, 8.2, 5.6, 9.1,
                                cat = c(10.1, 9.4, 11.8, 6.7, 8.2, 9.1)
                                jump_wide_tbl

# A tibble: 7 x 2
  dog    cat
  <dbl> <dbl>
1 5.2   10.1
2 4.9   9.4
3 12.1  11.8
4 8.2   6.7
5 5.6   8.2
6 9.1   9.1
7 7.4   7.1
```

12.2 Dateiformat

```
1 5.2 10.1
2 4.9 9.4
3 12.1 11.8
4 8.2 6.7
5 5.6 8.2
6 9.1 9.1
7 7.4 7.1
```

Wir können aber mit einem Wide-Format nicht mit `ggplot()` die Daten aus der Tabelle ?? visualisieren. Deshalb müssen wir entweder das Wide Format in das Long Format umwandeln oder die Daten gleich in Excel im Long Format erstellen.

Wenn du schon Daten hast, dann macht es eventuell mehr Sinn eine **neue** Exceldatei anzulegen in der du dann die Daten in das Long Format kopierst.

12.2.2 Long Format

Wenn du Daten erstellst ist es wichtig, dass du die Daten in Excel im Long-Format erstellst. Dabei muss eine Beobachtung eine Zeile sein. Du siehst in Abbildung ?? ein Beispiel für eine Tabelle in Excel, die dem Long Format folgt.

	A	B	C	D	E
1	animal	jump_length	flea_count	grade	infected
2	dog	5,2	18	8	0
3	dog	4,9	22	7	1
4	dog	12,1	17	5	1
5	dog	8,2	12	6	0
6	dog	5,6	23	7	1
7	dog	9,1	18	7	0
8	dog	7,4	21	9	0
9	cat	3,2	12	9	1
10	cat	1,2	13	5	0
11	cat	6,6	11	7	0
12	cat	4,1	12	8	0
13	cat	4,3	16	6	1
14	cat	7,8	9	6	0
15	cat	6,2	7	8	0

Abbildung 12.1: Beispiel für eine Exceldatentabelle in Long Format.

12 Daten einlesen

Im Folgenden sehen wir einmal wie die Funktion `gather()` das `tibble()` in Wide Format in ein `tibble()` in Long Format umwandelt. Wir müssen dafür noch die Spalte benennen mit der Option `key =` in die die Namen der Spalten aus dem Wide Format geschrieben werden sowie den Spaltennamen für die eigentlichen Messwerte mit der Option `value =`.

```
jump_tbl <- tibble(dog = c(5.2, 4.9, 12.1, 8.2, 5.6, 9.1, 7.4,
                           cat = c(10.1, 9.4, 11.8, 6.7, 8.2, 9.1, 7.1),
                           gather(key = "animal", value = "jump_length")
                           jump_tbl

# A tibble: 14 x 2
  animal jump_length
  <chr>     <dbl>
1 dog         5.2
2 dog         4.9
3 dog        12.1
4 dog         8.2
5 dog         5.6
6 dog         9.1
7 dog         7.4
8 cat        10.1
9 cat         9.4
10 cat       11.8
11 cat         6.7
12 cat         8.2
13 cat         9.1
14 cat         7.1
```

Wir sehen, dass ein Long Format viel mehr Platz benötigt. Das ist aber in R kein Problem. Wir sehen die Daten kaum sondern nutzen Funktionen wie `ggplot()` um die Daten zu visualisieren. Wichtig ist, dass du die Daten in Excel sauber abgelegt hast.

Im Folgenden schauen wir uns noch komplexere Daten in Tabelle ?? an. Das Datenbeispiel ist im Wide Format mit einem Behandlungsfaktor `treatment` einem Clusterfaktor `block` sowie mehreren Messwiederholungen zu unterschiedlichen Zeitpunkten `t_1` bis `t_6` angelegt.

12.2 Dateiformat

Tabelle 12.2: Komplexeres Datenbeispiel im Wide Format mit einem Behandlungsfaktor `treatment` einem Clusterfaktor `block` sowie mehreren Messwiederholungen zu unterschiedlichen Zeitpunkten `t_1` bis `t_6`.

treatment	block	t_1	t_2	t_3	t_4	t_5	t_6
A	1	12.54	16.90	17.72	14.72	17.28	18.99
A	2	14.18	17.51	17.60	14.27	17.70	18.64
A	3	13.63	19.28	17.77	13.42	20.87	18.25
A	4	14.63	13.44	16.81	16.05	17.80	19.15
B	1	15.92	15.75	12.50	15.95	15.40	20.47
B	2	15.41	15.13	16.04	13.45	16.29	18.18
B	3	14.26	16.41	17.73	17.71	18.49	16.91
B	4	17.57	15.52	17.37	16.94	18.02	18.69
C	1	16.64	19.33	17.23	17.80	22.37	21.54
C	2	16.05	16.19	15.81	16.66	18.79	12.98
C	3	14.87	17.08	12.12	15.53	16.61	20.36
C	4	14.75	13.04	17.48	19.01	20.73	19.34
D	1	13.11	14.86	17.50	16.56	17.35	16.15
D	2	17.72	15.08	17.86	13.83	20.43	12.77
D	3	18.60	15.08	16.12	17.32	16.54	17.37
D	4	12.44	16.64	19.34	19.00	18.93	19.87

Im Folgenden Codeblock sehen wir, wie die Funktion `gather()` die Daten in Tabelle Tabelle ?? in ein Long Format umwandelt. Die Funktion fasst die Messwiederholungen der Spalten `t_1` bis `t_6` zusammen, in dem die Werte alle in der Spalte `drymatter` untereinander geklebt werden. Die Spalten `treatment` und `block` werden dann sechs Mal wiederholt untereinander geklebt.

```
data_tbl %>%
  gather(key = "time_point", value = "drymatter", t_1:t_6) %>%
  arrange(treatment, block)

# A tibble: 96 x 4
  treatment block time_point drymatter
  <fct>     <int>   <chr>        <dbl>
1 A          1      t_1       12.54
2 A          1      t_2       16.9
3 A          1      t_3       17.72
4 A          1      t_4       14.72
5 A          1      t_5       17.28
6 A          1      t_6       18.99
7 A          2      t_1       14.18
8 A          2      t_2       17.51
9 A          2      t_3       17.6
10 A         2      t_4       14.27
11 A         2      t_5       17.7
12 A         2      t_6       18.64
13 A          3     t_1       13.63
14 A          3     t_2       19.28
15 A          3     t_3       17.77
16 A          3     t_4       13.42
17 A          3     t_5       20.87
18 A          3     t_6       18.25
19 A          4     t_1       14.63
20 A          4     t_2       13.44
21 A          4     t_3       16.81
22 A          4     t_4       16.05
23 A          4     t_5       17.8
24 A          4     t_6       19.15
25 B          1     t_1       15.92
26 B          1     t_2       15.75
27 B          1     t_3       12.5
28 B          1     t_4       15.95
29 B          1     t_5       15.4
30 B          1     t_6       20.47
31 B          2     t_1       15.41
32 B          2     t_2       15.13
33 B          2     t_3       16.04
34 B          2     t_4       13.45
35 B          2     t_5       16.29
36 B          2     t_6       18.18
37 B          3     t_1       14.26
38 B          3     t_2       16.41
39 B          3     t_3       17.73
40 B          3     t_4       17.71
41 B          3     t_5       18.49
42 B          3     t_6       16.91
43 B          4     t_1       17.57
44 B          4     t_2       15.52
45 B          4     t_3       17.37
46 B          4     t_4       16.94
47 B          4     t_5       18.02
48 B          4     t_6       18.69
49 C          1     t_1       16.64
50 C          1     t_2       19.33
51 C          1     t_3       17.23
52 C          1     t_4       17.8
53 C          1     t_5       22.37
54 C          1     t_6       21.54
55 C          2     t_1       16.05
56 C          2     t_2       16.19
57 C          2     t_3       15.81
58 C          2     t_4       16.66
59 C          2     t_5       18.79
60 C          2     t_6       12.98
61 C          3     t_1       14.87
62 C          3     t_2       17.08
63 C          3     t_3       12.12
64 C          3     t_4       15.53
65 C          3     t_5       16.61
66 C          3     t_6       20.36
67 C          4     t_1       14.75
68 C          4     t_2       13.04
69 C          4     t_3       17.48
70 C          4     t_4       19.01
71 C          4     t_5       20.73
72 C          4     t_6       19.34
73 D          1     t_1       13.11
74 D          1     t_2       14.86
75 D          1     t_3       17.5
76 D          1     t_4       16.56
77 D          1     t_5       17.35
78 D          1     t_6       16.15
79 D          2     t_1       17.72
80 D          2     t_2       15.08
81 D          2     t_3       17.86
82 D          2     t_4       13.83
83 D          2     t_5       20.43
84 D          2     t_6       12.77
85 D          3     t_1       18.6
86 D          3     t_2       15.08
87 D          3     t_3       16.12
88 D          3     t_4       17.32
89 D          3     t_5       16.54
90 D          3     t_6       17.37
91 D          4     t_1       12.44
92 D          4     t_2       16.64
93 D          4     t_3       19.34
94 D          4     t_4       19.0
95 D          4     t_5       18.93
96 D          4     t_6       19.87
```

12 Daten einlesen

```
1 A          1 t_1        12.5
2 A          1 t_2        16.9
3 A          1 t_3        17.7
4 A          1 t_4        14.7
5 A          1 t_5        17.3
6 A          1 t_6        19.0
7 A          2 t_1        14.2
8 A          2 t_2        17.5
9 A          2 t_3        17.6
10 A         2 t_4       14.3
# ... with 86 more rows
```

12.3 Importieren mit RStudio

Wir können das RStudio nutzen um Daten mit Point-and-Klick rein zuladen und dann den Code wieder in den Editor kopieren. Im Prinzip ist dieser Weg der einfachste um einmal zu sehen, wie ein Pfad funktioniert und der Code lautet. Später benötigt man diese ‘Krücke’ nicht mehr. Wir nutzen dann direkt den Pfad zu der Datei. Abbildung ?? zeigt einen Ausschnitt, wo wir im RStudio die *Import Dataset* Funktionalität finden.

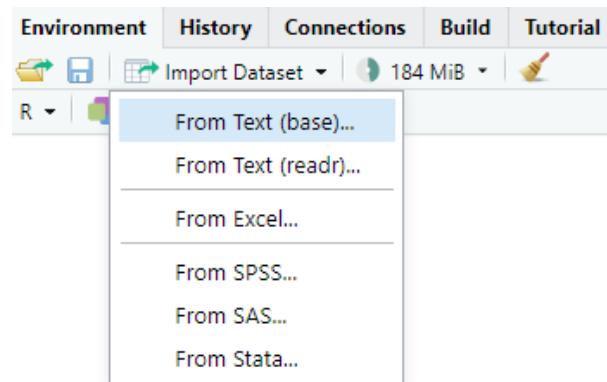


Abbildung 12.2: Auf den Reiter *Environment* klicken und dann *Import Dataset*. In der deutschen Version vom RStudio mögen die Begriffe leicht anders sein.

12.4 Importieren per Pfad

💡 Importieren mit RStudio als Video

Du findest auf YouTube Einführung in R - Teil 21.0 - Daten importieren mit RStudio - Point and Klick als Video. Point and Klick ist als Video einfacher nachzuvollziehen als Screenshots in einem Fließtext.

12.4 Importieren per Pfad

In Abbildung ?? können wir sehen wie wir den Pfad zu unserer Excel Datei `flea_dog_cat.xlsx` finden. Natürlich kannst du den Pfad auch anders herausfinden bzw. aus dem Explorer oder Finder kopieren.

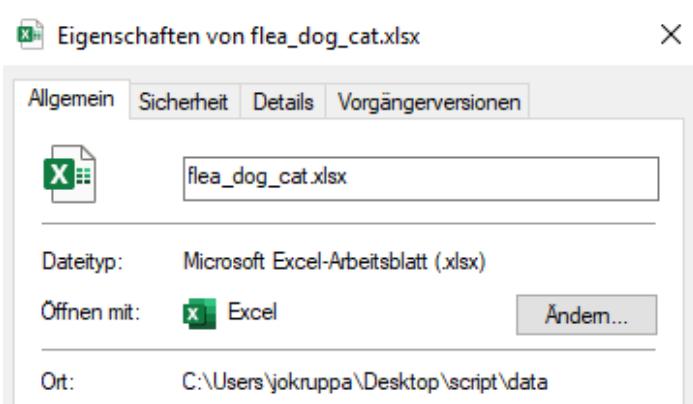


Abbildung 12.3: Durch den Rechts-Klick auf die Eigenschaften einer Datei kann man sich den Pfad zur Datei anzeigen lassen. **Achtung!** Unter Windows muss der Slash \ noch in den Backslash / gedreht werden.

Nachdem wir den Pfad gefunden haben, können wir den Pfad in die Funktion `read_excel()` kopieren und die Datei in das Objekt `data_tbl` einlesen. Ja, es wird nichts in der R Console ausgegeben, da sich die Daten jetzt in dem Object `data_tbl` befinden.

12 Daten einlesen

```
## Ganzer Pfad zur Datei flea_dog_cat.xlsx  
data_tbl <- read_excel("data/flea_dog_cat.xlsx")
```

! Unterschied zwischen \ in Windows und / in R

Achte einmal auf den Slash im Pfad in R und einem im Pfad in Windows. Einmal ist es der Slash \ im Dateipfad und einmal der Backslash /. Das ist sehr ärgerlich, aber dieses Problem geht zurück in die 80'ziger. Bill hat entschieden für sein Windows / zu nutzen und Steve (und Unix) eben /. Und mit dieser Entscheidung müssen wir jetzt leben...

12.5 Auf ein englisches Wort in Dateien

Ein großes Problem in Dateien sind Umlaute (ä,ö,ü) oder aber andere (Sonder)zeichen (ß, ?, oder #). Als dies sollte vermieden werden. Eine gute Datei für R beinhaltet nur *ganze* Wörter, Zahlen oder aber leere Felder. Ein leeres Feld ist ein fehlender Wert. Abbildung ?? zeigt eine gute Exceldatentable. Wir schreiben `jump_length` mit Unterstrich um den Namen besser zu lesen zu können. Sonst ist auch alles in Englisch geschrieben. Wir vermeiden durch die neglische Schreibweise *aus versehen* einen Umlaut oder anderweitig problematische Zeichen zu verwenden. Später können wir alles noch für Abbildungen anpassen.

12.6 Spaltennamen in der (Excel)-Datei

Die Funktion `clean_names()` aus dem R Paket `janitor` erlaubt es die Spaltennamen einer eingelesenen Datei in eine für R gute Form zu bringen.

- Keine Leerzeichen in den Spaltennamen.
- Alle Spaltennamen sind klein geschrieben.

12.6 Spaltennamen in der (Excel)-Datei

	A	B	C	D	E
1	animal	jump_length	flea_count	grade	infected
2	dog	5,2	18	8	0
3	dog	4,9	22	7	1
4	dog	12,1	17	5	1
5	dog	8,2	12	6	0
6	dog	5,6	23	7	1
7	dog	9,1	18	7	0
8	dog	7,4	21	9	0
9	cat	3,2	12	9	1
10	cat	1,2	13	5	0
11	cat	6,6	11	7	0
12	cat	4,1	12	8	0
13	cat	4,3	16	6	1
14	cat	7,8	9	6	0
15	cat	6,2	7	8	0

Abbildung 12.4: Beispiel für eine gute (Excel)Datentabelle.
Keine Umlaute sind vorhanden und die Spaltennamen haben keine Leerzeichen oder Sonderzeichen.

12 Daten einlesen

```
data_tbl %>%
  clean_names()

# A tibble: 14 x 5
  animal jump_length flea_count grade infected
  <chr>      <dbl>       <dbl>   <dbl>     <dbl>
1 dog          5.7        18      8      0
2 dog          8.9        22      8      1
3 dog         11.8        17      6      1
4 dog          8.2        12      8      0
5 dog          5.6        23      7      1
6 dog          9.1        18      7      0
7 dog          7.6        21      9      0
8 cat          3.2        12      7      1
9 cat          2.2        13      5      0
10 cat         5.4        11      7      0
11 cat         4.1        12      6      0
12 cat         4.3        16      6      1
13 cat         7.9        9      6      0
14 cat         6.1        7      5      0
```

13 Daten bearbeiten

Version vom September 14, 2022 um 08:46:32

Wir haben in dem vorherigen Kapitel Daten eingelesen. Jetzt wollen wir die Daten aufräumen (eng. *tidy*). Es ist notwendig, dass wir die Daten so aufarbeiten, dass R damit umgehen kann. Insbesondere das Erstellen von Faktoren ist wichtig, wenn die Spalte ein Faktor ist. R muss wissen was für Eigenschaften eine Spalte hat. Sonst funktionieren spätere Anwendungen in R nicht richtig oder geben einen Fehler wieder.

Es gibt zwei Möglichkeiten wie du mit deinen Daten umgehst:

- 1) Du änderst all deine Daten in Excel. Das mag bei einem kleinen Datensatz gut funktionieren. Dann musst du dich nicht mit dem *Programmieren* beschäftigen.
- 2) Du willst lernen die Daten auch in R zu verändern. Dann hilft dir dieses Kapitel. Auch in den folgenden Kapiteln werde ich immer wieder Funktionen wie `select()`, `filter()` und `mutate()` nutzen. Dann kannst du hier nochmal schauen, was die Funktionen machen.

Im Folgenden wollen wir den Datensatz `data_tbl` in R bearbeiten. Das heißt wir wollen Spalten auswählen mit `select()` oder Zeilen auswählen mit `filter()`. Schlussendlich wollen wir auch die Eigenschaften von Spalten mit der Funktion `mutate` ändern. Wir laden also den Datensatz `flea_dog_cat.xlsx` einmal in R.

```
data_tbl <- read_excel("data/flea_dog_cat_fox.xlsx")
```

Es ergibt sich folgende Tabelle ??, die wir schon aus vorherigen Kapiteln kennen.

13 Daten bearbeiten

Tabelle 13.1: Tabelle der Sprunglängen [cm], Anzahl an Flöhen, Boniturnote sowie der Infektionsstatus von Hunden, Katzen und Füchsen.

animal	jump_length	flea_count	grade	infected
dog	5.7	18	8	0
dog	8.9	22	8	1
dog	11.8	17	6	1
dog	8.2	12	8	0
dog	5.6	23	7	1
dog	9.1	18	7	0
dog	7.6	21	9	0
cat	3.2	12	7	1
cat	2.2	13	5	0
cat	5.4	11	7	0
cat	4.1	12	6	0
cat	4.3	16	6	1
cat	7.9	9	6	0
cat	6.1	7	5	0
fox	7.7	21	5	1
fox	8.1	25	4	1
fox	9.1	31	4	1
fox	9.7	12	5	1
fox	10.6	28	4	0
fox	8.6	18	4	1
fox	10.3	19	3	0

13.1 Genutzte R Pakete für das Kapitel

Wir wollen folgende R Pakete in diesem Kapitel nutzen.

```
pacman::p_load(tidyverse, readxl, magrittr, janitor)
```

Am Ende des Kapitels findest du nochmal den gesamten R Code in einem Rutsch zum selber durchführen oder aber kopieren.

13.2 Spalten wählen mit `select()`

💡 YouTube - Spalten auswählen mit `select()`

Du findest auf YouTube Einführung in R - Teil 12 - Spalten auswählen mit `select()` als Video zum nochmal anschauen.

Der Datensatz, den wir im Experiment erschaffen, ist meist riesig. Jetzt könnten wir natürlich eine Exceltabelle mit unterschiedlichen Sheets bzw. Reitern erstellen oder aber die *Spalten* die wir brauchen in R selektieren. Wir nutzen die Funktion `select()` um Spalten zu wählen. Im folgenden Codeblock wählen wir die Spalten `animal`, `jump_length` und `flea_count`.

```
data_tbl %>%
  select(animal, jump_length, flea_count)
```

```
# A tibble: 21 x 3
  animal   jump_length   flea_count
  <chr>        <dbl>       <dbl>
1 dog            5.7        18
2 dog            8.9        22
3 dog           11.8        17
4 dog            8.2        12
5 dog            5.6        23
6 dog            9.1        18
7 dog            7.6        21
8 cat            3.2        12
9 cat            2.2        13
10 cat           5.4        11
# ... with 11 more rows
```

Wir können die Spalten beim selektieren auch umbenennen und in eine andere Reihenfolge bringen.

```
data_tbl %>%
  select(Sprungweite = jump_length, flea_count, animal)
```

Wir nutzen die Funktion `select()` um Spalten zu wählen.

13 Daten bearbeiten

```
# A tibble: 21 x 3
  Sprungweite flea_count animal
     <dbl>      <dbl>   <chr>
1       5.7        18 dog
2       8.9        22 dog
3      11.8        17 dog
4       8.2        12 dog
5       5.6        23 dog
6       9.1        18 dog
7       7.6        21 dog
8       3.2        12 cat
9       2.2        13 cat
10      5.4        11 cat
# ... with 11 more rows
```

Du findest auf der englischen Hilfeseite für `select()` noch weitere Beispiele für die Nutzung.

13.3 Zeilen wählen mit `filter()`

💡 YouTube - Zeilen auswählen mit `filter()`

Du findest auf YouTube Einführung in R - Teil 13 - Zeilen auswählen mit `filter()` als Video zum nochmal anschauen.

Wir nutzen die Funktion `filter()`. Während wir die Auswahl an Spalten gut und gerne auch in um Zeilen nach Kriterien zu wählen, Excel durchführen können, so ist dies bei der Auswahl der Zeilen nicht so einfach. Wir können in R hier auf die Funktion `filter()` zurückgreifen. Wir nutzen die Funktion `filter()` um Zeilen nach Kriterien zu wählen.

Im folgenden Codeblock wählen wir die Zeilen aus in denen die Worte `dog` und `fox` stehen. Wir nutzen dazu den Operator `%in%` um auszudrücken, dass wir alle Einträge in der Spalte `animal` wollen die in dem Vektor `c("dog", "fox")` beschrieben sind.

```
data_tbl %>%
  filter(animal %in% c("dog", "fox"))
```

13.3 Zeilen wählen mit `filter()`

```
# A tibble: 14 x 5
  animal jump_length flea_count grade infected
  <chr>      <dbl>       <dbl>     <dbl>     <dbl>
1 dog          5.7        18       8       0
2 dog          8.9        22       8       1
3 dog         11.8        17       6       1
4 dog          8.2        12       8       0
5 dog          5.6        23       7       1
6 dog          9.1        18       7       0
7 dog          7.6        21       9       0
8 fox          7.7        21       5       1
9 fox          8.1        25       4       1
10 fox         9.1        31       4       1
11 fox         9.7        12       5       1
12 fox        10.6        28       4       0
13 fox         8.6        18       4       1
14 fox        10.3        19       3       0
```

Es stehen dir Folgende logische Operatoren zu Verfügung wie in Tabelle ?? gezeigt. Am Anfang ist es immer etwas schwer sich in den logischen Operatoren zurechtzufinden. Daher kann ich dir nur den Tipp geben einmal die Operatoren selber auszuprobieren und zu schauen, was du da so rausfilterst.

Tabelle 13.2: Logische Operatoren und R und deren Beschreibung

Logischer Operator	Beschreibung
<	kleiner als (eng. <i>less than</i>)
<=	kleiner als oder gleich (eng. <i>less than or equal to</i>)
>	größer als (eng. <i>greater than</i>)
>=	größer als oder gleich (eng. <i>greater than or equal to</i>)
==	exact gleich (eng. <i>exactly equal to</i>)
!=	nicht gleich (eng. <i>not equal to</i>)
!x	nicht (eng. <i>not x</i>)
x y	oder (eng. <i>x or y</i>)
x & y	und (eng. <i>x and y</i>)

13 Daten bearbeiten

Hier ein paar Beispiele. Probiere gerne auch mal Operatoren selber aus. Im folgenden Codeblock wollen wir nur die Zeilen haben, die eine Anzahl an Flöhen größer von 15 haben.

```
data_tbl %>%
  filter(flea_count > 15)

# A tibble: 13 x 5
  animal jump_length flea_count grade infected
  <chr>      <dbl>       <dbl>   <dbl>     <dbl>
1 dog          5.7        18      8       0
2 dog          8.9        22      8       1
3 dog         11.8        17      6       1
4 dog          5.6        23      7       1
5 dog          9.1        18      7       0
6 dog          7.6        21      9       0
7 cat          4.3        16      6       1
8 fox          7.7        21      5       1
9 fox          8.1        25      4       1
10 fox         9.1        31      4       1
11 fox        10.6        28      4       0
12 fox         8.6        18      4       1
13 fox        10.3        19      3       0
```

Wir wollen nur die infizierten Tiere haben.

```
data_tbl %>%
  filter(infected == TRUE)

# A tibble: 10 x 5
  animal jump_length flea_count grade infected
  <chr>      <dbl>       <dbl>   <dbl>     <dbl>
1 dog          8.9        22      8       1
2 dog         11.8        17      6       1
3 dog          5.6        23      7       1
4 cat          3.2        12      7       1
5 cat          4.3        16      6       1
6 fox          7.7        21      5       1
7 fox          8.1        25      4       1
```

13.4 Spalten ändern mit `mutate()`

```
8 fox          9.1        31      4      1  
9 fox          9.7        12      5      1  
10 fox         8.6       18      4      1
```

Wir wollen nur die infizierten Tiere haben UND die Tiere mit einer Flohanzahl größer als 20.

```
data_tbl %>%  
  filter(infected == TRUE & flea_count > 20)
```

```
# A tibble: 5 x 5  
  animal jump_length flea_count grade infected  
  <chr>     <dbl>       <dbl>   <dbl>     <dbl>  
1 dog        8.9        22      8      1  
2 dog        5.6        23      7      1  
3 fox        7.7        21      5      1  
4 fox        8.1        25      4      1  
5 fox        9.1        31      4      1
```

Du findest auf der englischen Hilfeseite für `filter()` noch weitere Beispiele für die Nutzung.

13.4 Spalten ändern mit `mutate()`

💡 YouTube - Eigenschaften von Variablen ändern mit `mutate()`

Du findest auf YouTube Einführung in R - Teil 14 - Eigenschaften von Variablen ändern mit `mutate()` als Video zum nochmal anschauen.

Nachdem wir die Spalten mit `select()` udn eventuell die Zeilen mit `filter()` gewählt haben. müssen wir jetzt noch die Eigenschaften der Spalten ändern. Das Ändern müssen wir nicht immer tun, aber häufig müssen wir noch einen Faktor erschaffen. Wir nutzen noch die Funktion `pull()` um uns die Spalte

Wir nutzen die Funktion `mutate()` um die Eigenschaften von Spalten daher Variablen zu ändern.

Die Reihenfolge der Funktionen ist wichtig um unliebsame Effekte zu vermeiden.

- 1) Erst wählen wir die Spalten mit `select()`
- 2) Dann filtern wir die Zeilen mit `filter()`
- 3) Abschließend ändern wir die Eigenschaften der Spalten mit `mutate()`

13 Daten bearbeiten

`animal` aus dem Datensatz zu ziehen. Nur so sehen wir die vollen Eigenschaften des Faktors. Später nutzen wir `pull` seltener und nur um um zu kontrollieren, was wir gemacht haben.

Im folgenden Codeblock verwandeln wir die Variable `animal` in einen Faktor durch die Funktion `as_factor`. Wir sehen, dass die Level des Faktoes so sortiert sind, wie das Auftreten in der Spalte `animal`.

```
data_tbl %>%
  mutate(animal = as_factor(animal)) %>%
  pull(animal)
```

```
[1] dog dog dog dog dog dog cat cat cat cat cat cat fox
[20] fox fox
Levels: dog cat fox
```

Wollen wir die Sortierung der Level ändern, können wir die Funktion `factor()` nutzen. Wir ändern die Sortierung des Faktors zu `fox`, `dog` und `cat`.

```
data_tbl %>%
  mutate(animal = factor(animal, levels = c("fox", "dog", "cat"))
  pull(animal)
```

```
[1] dog dog dog dog dog dog cat cat cat cat cat cat fox
[20] fox fox
Levels: fox dog cat
```

Wir können auch die Namen (eng. *labels*) der Level ändern. Hier musst du nur aufpassen wie du die alten Labels überschreibst. Wenn ich *gleichzeitig* die Level und die Labels ändere komme ich häufig durcheinander. Da muss du eventuell nochmal schauen, ob auch alles so geklappt hat wie du wolltest.

```
data_tbl %>%
  mutate(animal = factor(animal, labels = c("Hund", "Katze", "Fuchs"))
  pull(animal)
```

13.5 Gruppieren mit `group_by()`

```
[1] Katze Katze Katze Katze Katze Katze Hund Hund Hund Hund Hund  
[13] Hund Hund Fuchs Fuchs Fuchs Fuchs Fuchs Fuchs  
Levels: Hund Katze Fuchs
```

Du findest auf der englischen Hilfeseite für `mutate()` noch weitere Beispiele für die Nutzung. Insbesondere die Nutzung von `mutate()` über mehrere Spalten gleichzeitig erlaubt sehr effizientes Programmieren. Aber das ist für den Anfang etwas viel.

i Die Funktionen `select()`, `filter()` und `mutate()` in R

Bitte schaue dir auch die Hilfeseiten der Funktionen an. In diesem Skript kann ich nicht alle Funktionalitäten der Funktionen zeigen. Oder du kommst in das R Tutorium welches ich anbiete und fragst dort nach den Möglichkeiten Daten in R zu verändern.

13.5 Gruppieren mit `group_by()`

Sobald wir einen Faktor erschaffen haben, können wir die Daten in R auch nach dem Faktor *gruppieren*. Das heißt wir nutzen die Funktion `group_by()` um R mitzuteilen, dass nun folgende Funktionen *getrennt* für die einzelnen Gruppen erfolgen sollen. Im folgenden Codeblock siehst du die Anwendung.

```
data_tbl %>%  
  mutate(animal = as_factor(animal)) %>%  
  group_by(animal)  
  
# A tibble: 21 x 5  
# Groups:   animal [3]  
  animal jump_length flea_count grade infected  
  <fct>     <dbl>      <dbl> <dbl>    <dbl>  
1 dog        5.7       18     8     0  
2 dog        8.9       22     8     1  
3 dog       11.8       17     6     1  
4 dog        8.2       12     8     0  
5 dog        5.6       23     7     1
```

13 Daten bearbeiten

```
6 dog          9.1      18      7      0
7 dog          7.6      21      9      0
8 cat          3.2      12      7      1
9 cat          2.2      13      5      0
10 cat         5.4     11      7      0
# ... with 11 more rows
```

Auf den ersten Blick ändert sich nicht viel. Es entsteht aber die Zeile `# Groups: animal [3]`. Wir wissen nun, dass wir nach der Variable `animal` mit drei Gruppen die Datentabelle gruppiert haben. Die Anwendung siehst du in Kapitel ?? bei der Berechnung von deskriptiven Maßzahlen.

13.6 Mehr Informationen durch `glimpse()` und `str()`

Am Ende noch zwei Funktionen zur Kontrolle, was wir hier eigentlich gerade tun. Mit der Funktion `glimpse()` können wir uns einen Einblick in die Daten geben lassen. Wir sehen dann nochmal kurz und knapp wieviel Zeilen und Spalten wir haben und welche Inhalte in den Spalten stehen. Die gleichen Informationen erhalten wir auch durch die Funktion `str()`. Die Funktion `str()` geht aber noch einen Schritt weiter und nennt uns auch Informationen zu dem Objekt. Daher wir wissen jetzt, dass es sich beim dem Objekt `data_tbl` um ein `tibble()` handelt.

```
glimpse(data_tbl)
```

```
Rows: 21
Columns: 5
$ animal      <chr> "dog", "dog", "dog", "dog", "dog", "dog", "do
$ jump_length <dbl> 5.7, 8.9, 11.8, 8.2, 5.6, 9.1, 7.6, 3.2, 2.2,
$ flea_count   <dbl> 18, 22, 17, 12, 23, 18, 21, 12, 13, 11, 12, 1
$ grade        <dbl> 8, 8, 6, 8, 7, 7, 9, 7, 5, 7, 6, 6, 6, 5, 5,
$ infected     <dbl> 0, 1, 1, 0, 1, 0, 0, 1, 0, 0, 1, 0, 0, 1,
```

13.6 Mehr Informationen durch `glimpse()` und `str()`

```
str(data_tbl)
```

```
tibble [21 x 5] (S3: tbl_df/tbl/data.frame)
$ animal      : chr [1:21] "dog" "dog" "dog" "dog" ...
$ jump_length: num [1:21] 5.7 8.9 11.8 8.2 5.6 9.1 7.6 3.2 2.2 5.4 ...
$ flea_count  : num [1:21] 18 22 17 12 23 18 21 12 13 11 ...
$ grade       : num [1:21] 8 8 6 8 7 7 9 7 5 7 ...
$ infected    : num [1:21] 0 1 1 0 1 0 0 1 0 0 ...
```


Teil III

Explorative Datenanalyse

Version vom September 14, 2022 um 08:46:38

Wir haben die Daten jetzt in R Eingelesen und im Zweifel noch angepasst. Nun wollen wir uns die Daten einmal angucken. Nicht in dem Sinne, dass wir auf die Datentabelle schauen. Sondern wir wollen die Daten visualisieren. Wir erstellen Abbildungen von den Daten und versuchen so mehr über die Daten zu erfahren. Sehen wir Zusammenhänge zwischen verschiedenen Variablen bzw. Spalten? Wir führen eine explorative Datenanalyse durch. Über die explorative Datenanalyse wollen wir uns in diesem Kapitel einmal Gedanken machen.

Wir kürzen die explorative Datenanalyse häufig als **EDA** ab.

💡 Einführung in R per Video

Du findest auf YouTube Grundlagen in R als Video Reihe.
Du musst die Grundlagen in R verstanden haben, damit du dem R Code folgen kannst.

14 Deskriptive Statistik

Version vom September 14, 2022 um 08:46:50

Wir nutzen die deskriptive Statistik um Zahlen zusammenzufassen. Das heißt wir haben einen Datensatz vorliegen wie den Datensatz `flea_dog_cat.xlsx`. Wir wollen jetzt den großen Datensatz in wenige Zahlen wiedergeben. Warum wenige Zahlen? Wenn wir das Ergebnis *präsentieren* wollen, dann müssen es wenige Zahlen sein, die den Datensatz gut zusammenfassen. Daher ist es wichtig zu wissen, dass wir *dutzende bis hunderte Zahlen* durch meist eine oder zwei Zahlen beschreiben wollen. Wir brauchen die statistischen Maßzahlen aus diesem Kapitel später um teilweise noch extrem größere Datensätze darstellen zu können. Ebenso werden wir die Maßzahlen aus diesem Kapitel dafür verwenden statistische Tests und Modelle zu rechnen.

Nehmen wir nun als Beispiel die Sprungweiten in [cm] von Hundeflühen. Wir messen sieben Sprungweiten von sieben Hundeflühen und messen dabei folgende Werte in [cm]: 5.7, 8.9, 11.8, 8.2, 5.6, 9.1 und 7.6. Wir schreiben nun y als einen Vektor in der Form

$$y = \{5.7, 8.9, 11.8, 8.2, 5.6, 9.1, 7.6\}.$$

In R würde der Vektor wie etwas anders aussehen.

```
y <- c(5.7, 8.9, 11.8, 8.2, 5.6, 9.1, 7.6)
```

Wir wollen nun die Zahlen in y beschrieben und durch wenige andere Zahlen zusammenfassen. Einige der statistischen Maßzahlen sind dir vermutlich schon bekannt, andere eher neu.

Eigentlich *schätzen* wir die **Parameter einer Verteilung**. Aber das kommt nochmal später genauer, wenn wir wissen was Verteilungen sind.

i Parametrik versus Nicht-Parametrik

Wenn wir einen Zahlenvektor wie durch $y = \{5.7, 8.9, 11.8, 8.2, 5.6, 9.1, 7.6\}$ beschrieben zusammenfassen wollen, haben wir zwei Möglichkeiten.

- 1) Die **parametrische Variante** indem wir *mit den Zahlen* rechnen und deskriptive Maßzahlen wie Mittelwert, Varianz und Standardabweichung berechnen. Diese Maßzahlen kommen aber in den Zahlen nicht vor.
- 2) Die **nicht-parametrische Variante** indem wir die Zahlen in Ränge umwandeln, also sortieren, und *mit den Rängen* der Zahlen rechnen. Die deskriptiven Maßzahlen wären dann Median, Quantile und Quartile.

14.1 Mittelwert

Der Mittelwert einer Zahlenreihe beschreibt den Schwerpunkt der Zahlen. Der Mittelwert wird auch als Lageparameter be-

Der **Mittelwert** und **Winkelmaß** haben den Mittelwert mit einem Strich über den sind zwei **Vektoren**, oder die Zahlen enthält. Im folgenden ist die Formel für Verteilung. **Reale Mittelwert** der Sprungweite in [cm] der Hunde gezeigt. Der Stelle, wo die **Mittelwert** ist, in dem Sinne eine künstliche Zahl, da der Mittelwert häufig nicht in den beobachteten Zahlen vorkommt.



Wir werden immer mal wieder **Formeln vereinfachen**. Zum Beispiel nur \sum schreiben anstatt \sum_i^n , wenn wir einen Vektor aufsummieren und uns die Indizes sparen...

$$\bar{y} = \sum_{i=1}^n \frac{x_i}{n} = \frac{5.7 + 8.9 + 11.8 + 8.2 + 5.6 + 9.1 + 7.6}{7} = 8.13$$

Im Durchschnitt oder im Mittel springen Hundeflühe 8.13 cm weit.

14.1 Mittelwert

In der Abbildung ?? wollen wir die Formel nochmal visualisieren. Vielleicht fällt dir dann der Zusammenhang von dem Index i und der gesamten Fallzahl n leichter.

$$\bar{Y} = \sum_{i=1}^n \frac{Y_i}{n}$$

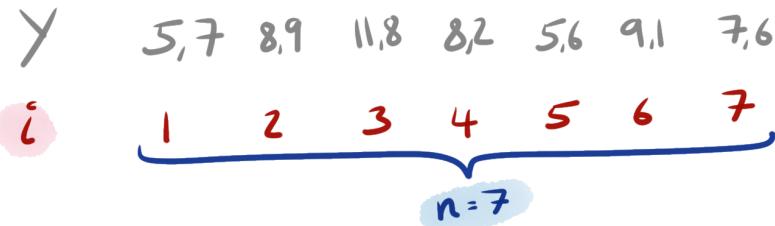


Abbildung 14.1: Zusammenhang zwischen y sowie dem Index i in der Formel für den Mittelwert.

In R können wir den Mittelwert einfach mit der Funktion `mean()` berechnen. Wir wollen dann den Mittelwert noch auf die zweite Kommastelle runden. Das machen wir dann mit der Funktion `round()`.

```
y %>% mean %>% round(2)
```

```
[1] 8.13
```

Wir erhalten das gleiche Ergebnis wie oben in unserer händischen Rechnung. Die Hundeflühe springen im Mittel 8.13 cm weit.

Der Mittelwert ist eine bedeutende Maßzahl der Normalverteilung. Daher merken wir uns hier schon mal, dass wir den Mittelwert brauchen werden. Auch wenn wir darüber nachdenken ob sich zwei Gruppen unterscheiden, so nutzen wir hierzu den Mittelwert. Unterscheiden sich die *mittleren* Sprungweiten in [cm] von Hunde- und Katzenflöhen?

14.2 Spannweite

Die *Spannweite* erlaubt uns zu überprüfen was die kleinste Zahl und die größte Zahl ist. Also uns das Minimum und das Maximum einer Zahlenreihe anzuschauen. Auf den ersten Blick mag das nicht so sinnig sein, aber wenn wir uns hunderte von Beobachtungen anschauen, wollen wir wissen, ob wir nicht einen Fehler bei Eintragen der Daten gemacht haben. Wir wissen eigentlich, dass z.B keine negativen Zuwachsraten auftreten können.

Die Spannweite dient dazu in einem

Datensatz zu übersprüfen ob die

Spalte, oder auch **Variable** $y_{range} = y_{max} - y_{min} = 12.1 - 4.9 = 7.2$

genannt, den richtigen ~~Zahl~~ ~~Hundert~~ Die Hundertflöhe springen in einer Spannweite von 7.2 cm. Das aufweist. Das machen ~~wollen~~ ~~kommt~~ ~~einem~~ *normal* vor. Die Spannweite ist nicht übertrieben ~~funktional~~ ~~groß~~ Der minimale Wert ist 4.9 und der maximale Wert ist 12.1 und somit sind beide Zahlen in Ordnung. Keine der beiden Zahlen ist übertrieben groß oder gar negativ.

In R können wir die Spannweite mit `range()` wie folgt berechnen. Wir erhalten den minimalen und maximalen Wert.

```
range(y)
```

```
[1] 5.6 11.8
```

Wir merken uns, dass die Spannweite eine Maßzahl für die Validität der Daten ist. Hat das Experiment geklappt oder kamen da nur komische Zahlen raus, die wir so in der Realität nicht erwarten würden. Zum Beispiel negative Sprungweiten, weil wir einmal auf das Minuszeichen gekommen sind.

14.3 Varianz

Bis jetzt können wir mit dem Mittelwert \bar{y} die Lage oder den Mittelpunkt unserer Zahlenreihe beschreiben. Uns fehlt damit aber die Information über die Streuung der Zahlen. Sind die Zahlen alle eher gleich oder sehr verschieden? Liegen die Zahlen

14.4 Standardabweichung

daher alle bei dem Mittelwert oder sind die Zahlen weit um den Mittelwert gestreut.

Die Streuung der Zahlen um den Mittelwert beschreibt die Varianz oder auch s^2 . Wir berechnen die Varianz indem wir von jeder Zahl den Mittelwert aller Zahlen abziehen und dann das Ergebnis quadrieren. Das machen wir für alle Zahlen und addieren dann die Summe auf. Wir erhalten die *Quadratsumme* von y .

$$s^2 = \sum_{i=1}^n \frac{(y_i - \bar{y})^2}{n-1} = \frac{(5.7 - 8.13)^2 + \dots + (7.6 - 8.13)^2}{7-1} = 4.6$$

Die Varianz beschreibt also die Streuung der Zahlen *im Quadrat* um den Mittelwert. Das heißt in unserem Beispiel, dass die Sprungweite eine Varianz von 4.6 cm^2 hat. Wir können Quadratzentimeter schlecht interpretieren. Deshalb führen wir gleich die Wurzel der Varianz ein: die Standardabweichung.

In R lässt sich die Varianz einfach durch die Funktion `var()` berechnen.

```
y %>% var %>% round(2)
```

```
[1] 4.6
```

Wir benötigen die Varianz häufig nur als Zwischenschritt um die Standardabweichung zu berechnen. Das Konzept der Abweichungsquadrate benötigen wir aber in der Varianzanalyse (ANOVA) und für die Beschreibung einer Normalverteilung.

14.4 Standardabweichung

Die *Standardabweichung* ist die Wurzel der Varianz. Wo die Varianz die Abweichung der Sprungweite in $[\text{cm}^2]$ beschreibt, beschreibt die Standardabweichung die Streuung der Sprungweite in $[\text{cm}]$.

Abweichungsquadrate sind ein wichtiges Konzept in der Statistik. Wenn wir wissen wollen, wie groß eine Abweichung von einer Zahl zu einer anderen ist, dann nutzen wir immer das Quadrat der Abweichung und bilden die Quadratsumme..

$$s = \sqrt{s^2} = \sqrt{4.6} = 2.14$$

Wir können also schreiben, dass die Flöhe im Mittel $8.13 \pm 2.14\text{cm}$ weit springen. Somit haben wir die Lage und die Streuung der Zahlenreihe y der Sprungweite in [cm] mit zwei Zahlen beschrieben.

In R können wir die Standardabweichung einfach mit der Funktion `sd()` berechnen.

```
y %>% sd %>% round(2)
```

```
[1] 2.14
```

14.5 Mittelwert und Varianz - eine Herleitung

Was ist der Mittelwert und die Varianz genau? Schauen wir uns das einmal in Abbildung ?? an. Die graue Linie oder Grade beschreibt den Mittelwert der fünf Beobachtungen. Die fünf Beobachtungen sind als blaue Punkt dargestellt. Auf der x-Achse ist nur der Index des Punktes. Das heißt y_1 ist der erste Punkt, das der Index i gleich 1 ist.

Wenn wir die Summe der Abweichungen von y_1 bis y_5 zu dem Mittelwert bilden, so wird diese Summe 0 sein. Der Mittelwert liegt genau in der Mitte der Punkte. In unserem Beispiel ist der Mittelwert $\bar{y} = 5.8$. Wir können jetzt die Abstände wie in der folgenden Tabelle berechnen.

Wir nennen die Abstände $y_i - \bar{y}$ nach dem griechischen Buchstaben Epsilon ϵ . Das ϵ soll an das e von *Error* erinnern. So meint dann *Error* eben auch Abweichung. Ja, es gibt hier viele Worte für das gleiche Konzept.

Wir berechnen einen Mittelwert von den Epsilons mit $\bar{\epsilon} = 0$. Ein Mittelwert nahe Null bzw. von Null wundert uns nicht. Wir haben die Gerade ja so gebaut, das nach oben und unten

14.5 Mittelwert und Varianz - eine Herleitung

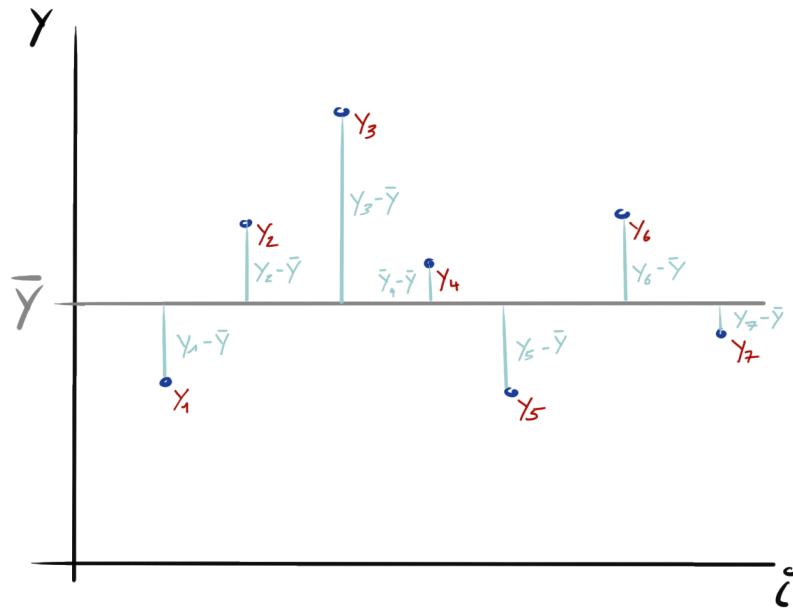


Abbildung 14.2: Die graue Linie beschreibt den Mittelwert der genau so durch die blauen Punkte geht, dass die Abstände der Punkte oberhalb und unterhalb zu Null aufaddieren. Die Linie liegt in der Mitte der Punkte. Die quadrierten Abstände sind die Varianz der blauen Punkte. Auf der x-Achse ist der Index des Punktes eingetragen.

Index				
i	y	$y_i - \bar{y}$	Wert	ϵ
1	5.7	$y_1 - \bar{y}$	$5.7 - 8.13 =$ -2.43	ϵ_1
2	8.9	$y_2 - \bar{y}$	$8.9 - 8.13 =$ 0.77	ϵ_2
3	11.8	$y_3 - \bar{y}$	$11.8 -$ $8.13 = 3.67$	ϵ_3
4	8.2	$y_4 - \bar{y}$	$8.2 - 8.13 =$ 0.07	ϵ_4
5	5.6	$y_5 - \bar{y}$	$5.6 - 8.13 =$ -2.53	ϵ_5
6	9.1	$y_4 - \bar{y}$	$9.1 - 8.13 =$ 0.97	ϵ_4
7	7.6	$y_5 - \bar{y}$	$7.6 - 8.13 =$ -0.53	ϵ_5

die gleichen Abstände sind. Die Varianz s^2 der y ist $s_y^2 = 4.599$ und die Varianz von ϵ ist $s_\epsilon^2 = 4.599$. In beiden Fällen ist die Zahl gleich.

14.6 Standardfehler oder Standard Error (SE)

Wenn wir den Mittelwert der Sprungweiten berichten dann gehört die Standardabweichung der Sprungweiten mit als beschreibendes Maß dazu. Wir berichten keinen Mittelwert ohne Standardabweichung.

Nun ist es aber so, dass der Mittelwert und die Standardabweichung von der Fallzahl abhängen. Je mehr Fallzahl bzw. Beobachtungen wir haben, desto genauer wird der Mittelwert sein. Oder anders ausgedrückt \bar{y} wird sich μ_y annähern. Das gleiche gilt auch für die Standardabweichung s_y , die sich σ_y mit steigender Fallzahl annähert.

14.6 Standardfehler oder Standard Error (SE)

Aus diesem Grund brauchen wir noch einen Fehler bzw. eine Maßzahl für die Streuung, die unabhängig von der Fallzahl ist. Wir skalieren also die Standardabweichung mit der Fallzahl indem wir die Standardabweichung durch die Wurzel der Fallzahl teilen.

$$SE = \frac{s}{\sqrt{n}} = \frac{2.14}{2.65} = 0.81$$

Wir müssten ein Paket in R laden um den Standardfehler zu berechnen. Das Laden von zusätzlichen Paketen wollen wir hier aber vermeiden; wir können den Standardfehler auch einfach selber berechnen.

```
se <- sd(y)/sqrt(length(y))  
se %>% round(2)
```

```
[1] 0.81
```

Wir erhalten einen Standardfehler von 0.81. Diese Zahl ist in dem Sinne nicht zu interpretieren, da wir hier nur Experimente losgelöst von deren Fallzahl miteinander vergleichen können. Auf der anderen Seite können wir ohne die berichtete Fallzahl nicht vom Standardfehler auf die Standardabweichung schließen.

Wir benötigen den Standardfehler eigentlich nicht zum Berichten von Ergebnissen. Der Standardfehler ist nicht als Zahl interpretierbar und somit eine reine statistische Größe. Tabelle ?? zeigt die Zusammenfassung und den Vergleich von Standardabweichung und Standardfehler.

Wir berichten den **Standardfehler** immer zusammen mit der Fallzahl, so dass die Standardabweichung berechnet werden kann.

Tabelle 14.2: Zusammenfassung und Vergleich von Standardabweichung und Standardfehler

Standardabweichung	Standardfehler
... ist eine Aussage über die Streuung der erhobenen Werte einer Stichprobe.	... ist eine Aussage über die Genauigkeit des Mittelwertes einer Stichprobe.

Standardabweichung	Standardfehler
... hängt von der biologischen Variabilität ab.	... abhängig von der Messgenauigkeit
... ist ein beschreibendes Maß.	... ist ein statistisches Maß.
... ist nur wenig durch die Größe der Stichprobe beeinflussbar.	... steht im direkten Verhältnis zur Größe der Stichprobe.

Der Standardfehler oder Standard Error (SE) oder Standardfehler wird in der Metaanalyse genutzt. Der Mean (SEM) wird uns wieder beim statistischen Testen. Der Standardfehler ist bedeutend in der Metaanalyse. Als t-Test gegenüber gemeinsamen Auswerten von mehreren *klinischen* Studien. Du kannst im Buch Doing Meta-Analysis with R: A Hands-On Guide mehr darüber erfahren. Wir nutzen kleine Metaanalysen in den Grundlagenveranstaltungen.

$$T_{calc} = \frac{\bar{y}_1 - \bar{y}_2}{s_p \cdot \sqrt{\frac{2}{n}}} \approx \frac{\bar{y}_1 - \bar{y}_2}{SEM}$$

Der Nenner beim t-Test kann als Standardfehler gesehen werden. Wir benötigen den Standardfehler also im Kontext des statistischen Testen als eine statistische Maßzahl.

Wir wollen uns jetzt noch eine andere Art der Zusammenfassung von Zahlen anschauen. Anstatt *mit den Zahlen* zu rechnen, sortieren wir jetzt die Zahlen aus dem Vektor $y = \{5.7, 8.9, 11.8, 8.2, 5.6, 9.1, 7.6\}$ nach dem Rang. Wir rechnen dann *mit den Rängen*. Die kleinste Zahl kriegt den kleinsten Rang. Wir können R nutzen über die Funktion `sort()` um den Vektor y zu sortieren.

```
y %>% sort()
```

```
[1] 5.6 5.7 7.6 8.2 8.9 9.1 11.8
```

Der Median \tilde{y} ist die mittlere Zahl eines Zahlenvektors. Wir haben hier sieben Zahlen, also ist der Median die vierte Zahl. Wir müssen hier aber zwischen einer ungeraden Anzahl und einer geraden Anzahl unterscheiden.

14.7 Median

- **Ungerade Anzahl** von Zahlen, der Median ist die mittlere Zahl des Vektors y :

$$5.6, 5.7, 7.6, \underbrace{8.2}_{\text{Median}}, 8.9, 9.1, 11.8$$

In R können wir den Median einfach mit der Funktion `median()` berechnen.

```
median(y)
```

```
[1] 8.2
```

- **Gerade Anzahl** von Zahlen, der Median ist der Mittelwert der *beiden* mittleren Zahlen des Vektors y :

$$5.6, 5.7, 7.6, \underbrace{8.2, 8.9}_{\text{Median} = \frac{8.2+8.9}{2} = 8.55}, 9.1, 11.8, 13.1$$

In R können wir den Median wieder einfach mit der Funktion `median()` berechnen. Wir müssen nur die Zahl 13.1 zu dem Vektor y mit der Funktion `c()` hinzufügen.

```
c(y, 13.1) %>% median()
```

```
[1] 8.55
```

Der Median ist eine Alternative zu dem Mittelwert. Insbesondere in Fällen, wo es sehr große Zahlen gibt, die den Mittelwert in der Aussage *verzerren*, kann der Median sinnvoll sein.

💡 Median versus Mittelwert

Zur Veranschaulichung des Unterschiedes zwischen Median und Mittelwert nehmen wir die Mietpreise in New York. Der *mittlere* Mietpreis für eine 2-Zimmerwohnung in Manhattan liegt bei 5000\$ pro Monat. In den *mittleren* Mietpreis gehen aber auch die Mieten der Billionaires' Row mit ein. Der *mediane* Mietpreis liegt bei 4000\$. Die hohen

Wenn der **Mittelwert** stark von dem **Median** abweicht, deutet dies auf eine schiefe Verteilung oder aber Ausreißer in den Daten hin. Wir müssen dann in der explorativen Datenanalyse der Sachlage nachgehen

Mieten ziehen den Mittelwert nach rechts.

14.8 Quantile und Quartile

Bei dem Mittelwert beschreibt die Standardabweichung die Streuung der Daten um den Mitelwert. Bei dem Median sind dies die *Quartile*. Die Quartile beschreiben die Streuung der Daten um den Median. Um die Quartile bestimmen zu können, teilen wir die Daten in 100 Quartile. Du kannst dir Quantile wie Prozente vorstellen. Wir schneiden die Daten also in 100 Scheiben. Das geht natürlich erst wirklich, wenn wir hundert Zahlen haben. Deshalb hilft man sich mit Quartilen - von Quarta, ein Viertel - aus. Tabelle ?? zeigt den Zusammenhang.

Tabelle 14.3: Zusammenfassung und Vergleich von Quantilen, Quartilen und Median

	Quantile	Quartile	Median
25% Quantile		1 st Quartile	
50% Quantile		2 nd Quartile	Median
75% Quantile		3 rd Quartile	

Wir bestimmen die Quartile wie den Median. Wir müssen unterscheiden, ob wir eine ungerade Anzahl an Zahlen oder eine gerade Anzahl an Zahlen vorliegen haben.

- **Ungerade Anzahl** von Zahlen, das 1st Quartile ist die mittlere Zahl des unteren Mittels und das 3rd Quartile ist die mittlere Zahl des oberen Mittels des Vektors y :

$$5.6, \quad \underbrace{5.7,}_{1\text{st Quartile}} \quad 7.6, 8.2, 8.9, \quad \underbrace{9.1,}_{3\text{rd Quartile}} \quad 11.8$$

- **Gerade Anzahl** von Zahlen, das 1st Quartile ist der Mittelwert der beiden mittleren Zahl des unteren Mittels und das 3rd Quartile ist der Mitelwert der beiden mittleren

14.9 Interquartilesabstand (IQR)

Zahlen des oberen Mittels des Vektors y :

$$5.6, \quad \underbrace{5.7, 7.6,}_{1st \text{ Quartile} = \frac{5.7+7.6}{2} = 6.65} \quad 8.2, 8.9, \quad \underbrace{9.1, 11.8}_{3rd \text{ Quartile} = \frac{9.1+11.8}{2} = 10.45} \quad 13.1$$

In R können wir den Median einfach mit der Funktion `quantile()` berechnen. Wir berechnen hier das 25% Quantile also das 1st Quartile sowie das 50% Quantile also den Median und das 75% Quantile also das 3rd Quartile.

```
y %>% quantile(probs = c(0.25, 0.5, 0.75)) %>% round(2)
```

```
25% 50% 75%
6.65 8.20 9.00
```

```
c(y, 13.1) %>% quantile(probs = c(0.25, 0.5, 0.75)) %>% round(2)
```

```
25% 50% 75%
7.12 8.55 9.77
```

Das **95% Quantile** und das **97.25% Quantile** werden wir später nochmal im statistischen Testen brauchen. Auch hier ist die Idee, dass wir die Daten in hundert Teile schneiden und uns dann die extremen Zahlen anschauen.

Warum unterscheiden sich die händisch berechneten Quartile von den Quartilen aus R? Es gibt verschiedene Arten der Berechnung. In der Klausur nutzen wir die Art und Weise wie die händische Berechnung hier beschrieben ist. Später in der Anwendung nehmen wir die Werte, die R ausgibt. Die Abweichungen sind so marginal, dass wir diese Abweichungen in der praktischen Anwendung ignorieren wollen.

14.9 Interquartilesabstand (IQR)

Der Interquartilesabstand (IQR) beschreibt den Abstand zwischen dem 1st Quartile und dem 3rd Quartile. Daher ist der Interquartilesabstand (IQR) ähnlich der Spannweite zwischen dem maximalen und minimalen Wert. Wir benötigen das Interquartilesabstand (IQR) in der explorativen Datenanalyse wenn wir einen Boxplot erstellen wollen.

$$IQR = 3^{rd} \text{ Quartile} - 1^{st} \text{ Quartile} = 9.1 - 5.7 = 3.4$$

14.10 Zusammenfassen von Daten per Faktor

Gut und soll ich jetzt für jeden Faktorlevel überall den Mittelwert mit `mean()` berechnen? Geht das nicht einfacher? Ja, geht es. Im folgenden siehst du, wie du den verschiedenen deskriptiven Maßzahlen in einem Rutsch berechnen kannst.

```
data_tbl %>%
  mutate(animal = as_factor(animal)) %>%
  group_by(animal) %>%
  summarise(mean = mean(jump_length),
            sd = sd(jump_length),
            median = median(jump_length),
            quantiles = quantile(jump_length,
                                  probs = c(0.25, 0.5, 0.75)))
  mutate(across(where(is.numeric), round, 2))

# A tibble: 6 x 5
# Groups:   animal [2]
  animal  mean     sd median quantiles
  <fct>   <dbl>   <dbl>   <dbl>    <dbl>
1 dog      8.13   2.14    8.2     6.65
2 dog      8.13   2.14    8.2     8.2
3 dog      8.13   2.14    8.2      9
4 cat      4.74   1.9     4.3     3.65
5 cat      4.74   1.9     4.3     4.3
6 cat      4.74   1.9     4.3     5.75
```

15 Visualisierung von Daten

Version vom September 14, 2022 um 08:47:09

Ein wichtiger Teil in der Analyse von Daten ist die Visualisierung. Wir glauben keine Auswertung eines mathematischen Algorithmus, wenn wir nicht die Bestätigung in einer Abbildung sehen. Daher ist die Visualisierung die Grundlage für ein fundiertes, wissenschaftliches Arbeiten. In diesem Kapitel stelle ich dir verschiedene Abbilungen vor, die uns helfen werden zu Verstehen ob es einen Zusammenhang zwischen Y und X gibt. Wir haben ein y vorliegen, was wir auf die y-Achse eines Graphen legen und daneben dann mehrere Variablen bzw. Spalten die wir x nennen. Eine der Variablen legen wir auf die x-Achse des Graphen. Nach den anderen x färben wir die Abbildung ein.

Wir nennen eine Abbildung auch häufig Plot. Das ist der englische Begriff und hat nichts in unserem Kontext mit einer Fläche zu tun.

15.1 Genutzte R Pakete für das Kapitel

Wir wollen folgende R Pakete in diesem Kapitel nutzen.

```
pacman::p_load(tidyverse, magrittr, readxl, ggmosaic,
                janitor, see, patchwork)
```

Am Ende des Kapitels findest du nochmal den gesamten R Code in einem Rutsch zum selber durchführen oder aber kopieren.

15.2 Grundlagen in ggplot()

Wir nutzen in R das R Paket `ggplot2` um unsere Daten zu visualisieren. Die zentrale Idee von `ggplot2` ist, dass wir uns eine Abbildung wie ein Sandwich bauen. Zuerst legen wir eine Scheibe Brot hin und legen uns dann Scheibe für Scheibe

Im Gegensatz zu dem Pipe-Operator `%>%` nutzt `ggplot` den Operator `+` um die verschiedenen `ggplot` Funktionen (`geom_`) miteinander zu verbinden.

weitere Schichten übereinander. Oder die Idee eines Bildes, wo wir erst die Leinwand definieren und dann Farbschicht über Farbschicht auftragen. Das Konzept von `ggplot2` ist schlecht zu beschreiben deshalb habe ich auch noch zwei Videos hierfür gemacht. Um den Prozess von `ggplot2` zu visualisieren...

💡 Grundlagen von `ggplot()` im Video

Du findest auf YouTube Einführung in R - Teil 16.0 - Trockenübung `ggplot2` simpel und einfach erklärt als Video. Sowie auch auf YouTube Einführung in R - Teil 16.1 - Abbildungen mit `ggplot` in R erstellen. Idee und Konzept von `ggplot` als Video. Also alles nochmal als Video - vielleicht einfacher nachzuvollziehen als in einem Fließtext.

Die Funktion `ggplot()` ist die zentrale Funktion, die die Leinwand erschafft auf der wir dann verschiedene Schichten aufbringen werden. Diese Schichten heißen `geom`. Es gibt nicht nur ein `geom` sondern mehrere. Zum Beispiel das `geom_boxplot` für die Erstellung von Boxplots, das `geom_histogram` für die Erstellung von Histogrammen. Die Auswahl ist riesig. Die einzelnen Schichten werden dann über den Operator `+` miteinander verbunden. Soviel erstmal zur Trockenübung. Schauen wir uns das ganze einmal an einem Beispiel an.

15.2.1 Datenbeispiel

Wir importieren den Datensatz `flea_cat_dog.xlsx` und wollen einzelne Variablen visualisieren. Wir kennen den Datensatz schon aus dem Kapitel `??`. Dennoch nochmal hier der Datensatz in Tabelle `??`.

```
flea_dog_cat_tbl <- read_excel("data/flea_cat_dog.xlsx") %>%  
  mutate(animal = as_factor(animal))
```

Spaltennamen sind in **Englisch** und im folgenden ist es wichtig, dass du dir die Spaltennamen haben **keine Leerzeichen**. Die merkst. Wir können nur die exakten, wortwörtlichen Spaltenfunktion `clean_names()` aus dem R-Paket `janitor` aus dem R Namen verwenden. Sonst erhalten wir einen Fehler. Deshalb haben wir auch keine Leerzeichen in den Spaltennamen.

15.2 Grundlagen in `ggplot()`

Tabelle 15.1: Beispieldatensatz für Eigenschaften von Flöhen von zwei Tierarten.

animal	jump_length	flea_count	grade	infected
dog	5.7	18	8	0
dog	8.9	22	8	1
dog	11.8	17	6	1
dog	8.2	12	8	0
dog	5.6	23	7	1
dog	9.1	18	7	0
dog	7.6	21	9	0
cat	3.2	12	7	1
cat	2.2	13	5	0
cat	5.4	11	7	0
cat	4.1	12	6	0
cat	4.3	16	6	1
cat	7.9	9	6	0
cat	6.1	7	5	0

15.2.2 Erste Abbildung in `ggplot()`

Der folgende R Code erstellt die Leinwand in der Abbildung ?? für die folgende, zusätzliches Schichten (`geom`).

```
ggplot(data = flea_dog_cat_tbl,  
       aes(x = animal , y = jump_length))
```

Wir schauen uns einmal den Code im Detail an.

- `ggplot` ruft die Funktion auf. Die Funktion ist dafür da den Plot zu zeichnen.
- `data = flea_dog_cat_tbl` bennt den Datensatz aus dem der Plot gebaut werden soll.
- `aes()` ist die Abkürzung für *aesthetics* und beschreibt, was auf die x-Achse soll, was auf die y-Achse soll sowie ob es noch andere Faktoren in den Daten gibt.
 - `x` braucht den Spaltennamen für die Variable auf der x-Achse.

15 Visualisierung von Daten

- y braucht den Spaltennamen für die Variable auf der y-Achse.

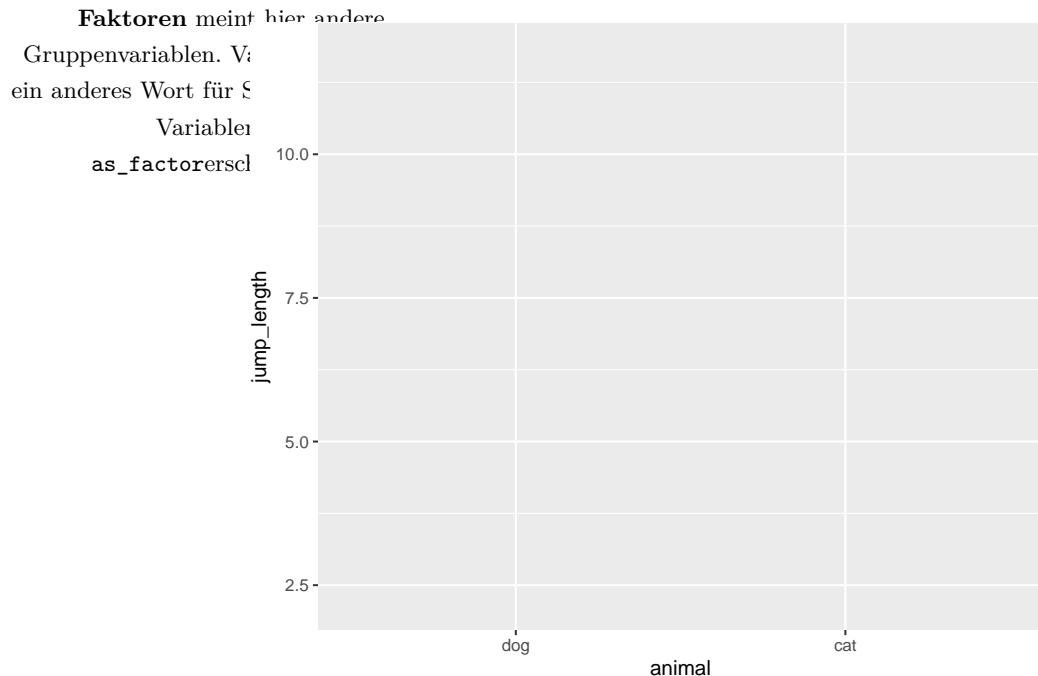


Abbildung 15.1: Leere ggplot() Leinwand mit den Spalten animal und jump_length aus dem Datensatz flea_dog_cat_tbl.

Wir sehen, dass wir nichts sehen in Abbildung ???. Der Grund ist, dass wir noch kein geom hinzugefügt haben. Das geom beschreibt nun wie die Zahlen in der Datentabelle flea_dog_cat_tbl visualisiert werden sollen.

15.3 Häufig verwendete Abbildungen

In diesem Kapitel wollen wir durch die häufigsten und wichtigsten Abbildungen in der explorativen Datenanalyse durchgehen. Das wären im folgenden diese Abbildungen:

- **Histogramm** in Kapitel ?? für mehr als 20 Beobachtungen (pro Gruppe). Wir nutzen ein Histogramm um die Verteilung einer Variable zu visualisieren.

15.3 Häufig verwendete Abbildungen

- **Boxplot** in Kapitel ?? für 5 bis 20 Beobachtungen (pro Gruppe). Ebenso wie bei einem Histogramm, geht es bei einem Boxplot auch um die Verteilung der einer Variable.
- **Barplot** in Kapitel ?? für 5 und mehr Beobachtungen (pro Gruppe). Der Barplot oder das **Balkendiagramm** stellt den Mittelwert und die Standardabweichung da.
- **Dotplot** in Kapitel ?? für 3 bis 5 Beobachtungen (pro Gruppe). Hier geht es weniger um die Verteilung der Variable, sondern darum die wenigen Beobachtungen zu visualisieren.
- **Scatterplot** in Kapitel ?? für zwei kontinuierliche Variablen. Auch **xy-Plot** genannt. Die Abbildung, die dir bekannt sein müsste. Wir zeichnen hier eine Grade durch eine Punktewolke.
- **Mosaicplot** in Kapitel ?? für zwei diskrete Variablen. Eine etwas seltene Abbildung, wenn wir Variablen abbilden wollen, die diskret sind bzw. aus Kategorien bestehen.

Konkret ist eine **Variable** gleich einer **Spalte** in einem Datensatz.

💡 Histogramm, Boxplot, Scatterplot und Mosaicplot im Video

Du findest auf YouTube Einführung in R - Teil 16.2 - Histogramm, Boxplot, Scatterplot und Mosaicplot mit ggplot in R als Video. Weitere Videos werden dann noch folgen und ergänzt.

15.3.1 Histogramm

Wir nutzen für die Erstellung eines Histogramms den Datensatz `dog_fleas_hist.csv`. Wir brauchen für ein anständiges Histogramm, wo du auch was erkennen kannst, mindestens 20 Beobachtung. Am besten mehr noch mhr Beobachtungen. Deshalb schauen wir uns jetzt einmal 39 Hunde an und zählen wieviele Flöhe die Hunde jeweils haben, dargestellt in der Spalte `flea_count`. Darüber hinaus bestimmen wir auch noch das mittlere Gewicht der Flöhe auf dem jeweiligen Hund, dargestellt in der Spalte `flea_weight`.

15 Visualisierung von Daten

```
dog_fleas_hist_tbl <- read_csv("data/dog_fleas_hist.csv")
```

Tabelle 15.2: Beispieldatensatz für die Anzahl an Flöhen auf 39 Hunden. Gezählt wurde die Anzahl an Flöhen `flea_count` und das gemittelte Gewicht der Flöhe `flea_weight`.

flea_count	flea_weight
0	0.00
1	7.43
4	21.04
2	20.07
1	21.90
0	0.00
2	24.96
1	27.08
5	16.58
1	19.92
0	0.00
0	0.00
2	24.63
4	21.64
3	20.97
1	23.15
0	0.00
3	14.91
1	19.39
2	17.66
1	19.15
1	25.10
2	26.38
2	19.33
2	13.29
1	17.81
0	0.00
2	23.56
1	18.64
1	15.64
3	19.88
1	18.40

15.3 Häufig verwendete Abbildungen

flea_count	flea_weight
1	25.17
0	0.00
0	0.00

Tabelle ?? zeigt den Datensatz `dog_fleas_hist.csv`. Wir wollen jetzt die Variable `flea_count` und `flea_weight` jeweils abbilden. Wir beginnen mit der diskreten Variable `flea_count`. Im Gegensatz zu der Variable `flea_weight` haben wir bei der Anzahl gleiche Zahlen vorliegen, die wir dann zusammen darstellen können. Abbildung ?? zeigt die Darstellung der Tabelle. Auf der x-Achse ist die Anzahl an Flöhen dargestellt. Auf der y-Achse die Anzahl der jeweiligen Anzahl an Flöhen. Das klingt jetzt etwas schief, aber schauen wir uns die Abbildung näher an.

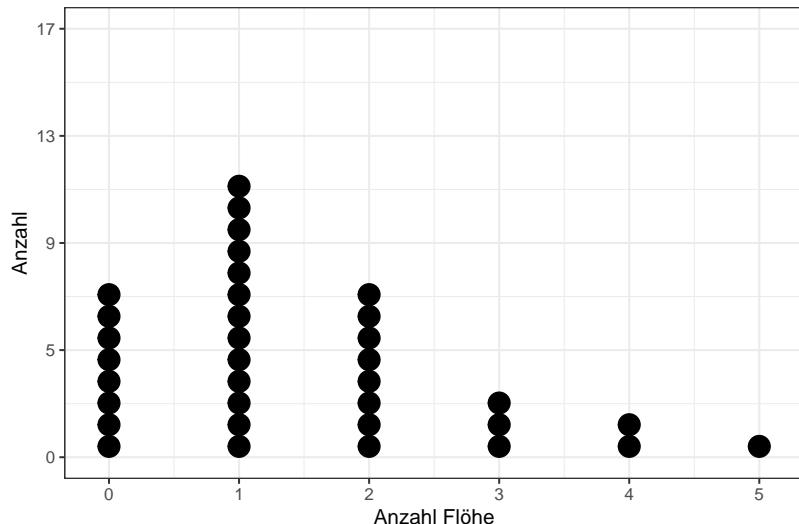


Abbildung 15.2: Die Anzahl von Flöhen auf 39 Hunden. Jeder Punkt entspricht einem Hund und der entsprechenden Anzahl an Flöhen auf dem Hund.

Wir sehen in Abbildung ?? das acht Hunde keine Flöhe hatten - also eine Anzahl an Flöhen von 0. Auf der anderen Seite hatten zwei Hunde vier Flöhe und ein Hund hatte sogar fünf Flöhe. Wir sehen also die *Verteilung* der Anzahl an Flöhen über alle unsere 39 Hundebeobachtungen.

15 Visualisierung von Daten

Wir schauen uns aber die Verteilung der Anzahl an Flöhen meist nicht in der Form von gestapelten Punkten an, sondern in der Form eines Histogramms also einem Balkendiagramm. Abbildung ?? zeigt das Histogramm für die Anzahl der Flöhe.

```
ggplot(data = dog_fleas_hist_tbl, aes(x = flea_count)) +  
  geom_histogram(binwidth = 1, fill = "gray", color = "black")  
  theme_bw() +  
  labs(x = "Anzahl Flöhe", y = "Anzahl")
```

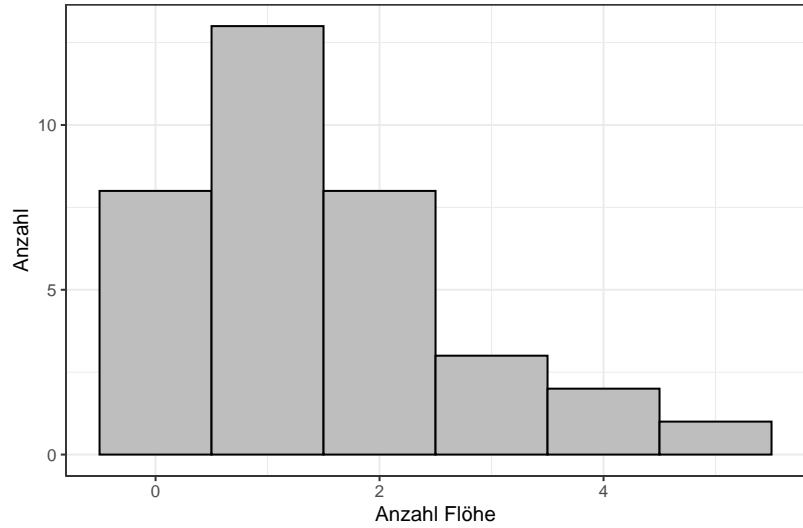


Abbildung 15.3: Histogramm der Anzahl von Flöhen auf 39 Hunden.

Was sehen wir in der Abbildung ??? Anstatt von gestapelten Punkten sehen wir jetzt Balken, die die jeweilige Anzahl an Flöhen zusammenfassen. Der Unterschied ist bei einer diskreten Variable wie der Anzahl (eng. *count*) relativ gering.

Anders sieht es für kontinuierliche Variablen mit Kommazahlen aus. Schauen wir uns das Gewicht der Flöhe an, so sehen wir, dass es sehr viele Zahlen gibt, die nur einmal vorkommen. Abbildung ?? zeigt das Histogramm für das Geicht der Flöhe.

15.3 Häufig verwendete Abbildungen

```
ggplot(data = dog_fleas_hist_tbl, aes(x = flea_weight)) +  
  geom_histogram(binwidth = 1, fill = "gray", color = "black") +  
  theme_bw() +  
  labs(x = "Gewicht [mg]", y = "Anzahl")
```

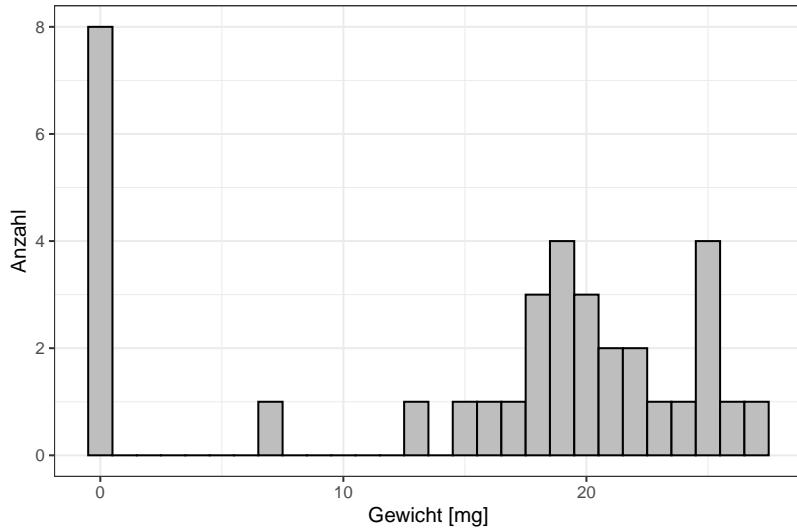


Abbildung 15.4: Histogramm des Gewichts von Flöhen auf 39 Hunden.

Wie entsteht nun ein Hisotgramm für konettnerliche Zahlen? Schauen wir uns dafür einmal ein kleineres Datenbeispiel an, in dem wir nur Flöhe mit einem Gewicht größer als 11 und kleiner als 19 wählen. Wir nutzen dazu die Funktion `filter(flea_weight > 11 & flea_weight < 19)`. Wir erhalten folgende Zahlen und das entsprechende Histogramm.

```
[1] 13.29 14.91 15.64 16.58 17.66 17.81 18.40 18.64
```

Abbildung ?? zeigt das Histogramm der reduzierten Daten. Die roten vertikalen Linien zeigen die Position der einzelnen Flohgewichte auf der x-Achse. Die blauen Hilfslinien machen nochmal klarer, wie hoch die einzelnen Balken sind sowie welche Beobachtungen auf der x-Achse in den jeweiligen Balken mit eingehen. Wir sehen, dass wir einen Hund mit Flöhen haben, die

15 Visualisierung von Daten

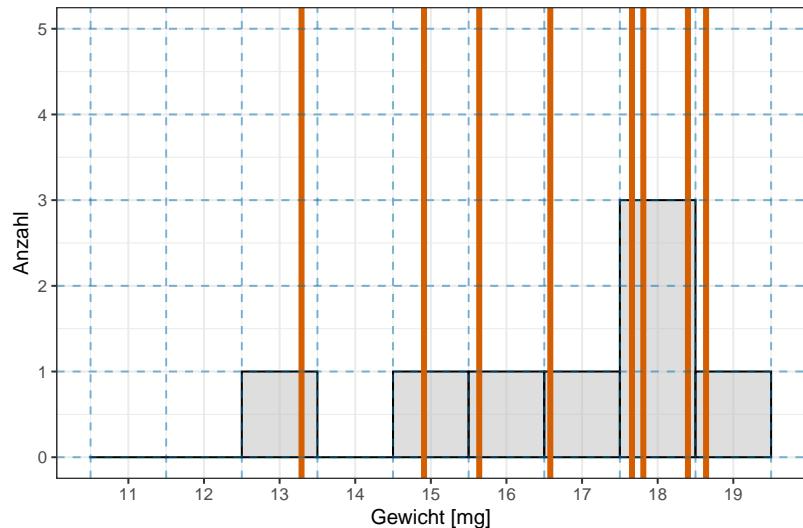


Abbildung 15.5: Zusammenhang zwischen den einzelnen Beobachtungen und der Höhe der einzelnen Balken am Beispiel von acht Hunden.

zwischen 12.5 und 13.5 wiegen - der entsprechende Balken erhält die Anzahl von eins. Auf der anderen Seite sehen wir, dass es drei Hunde mit Flöhen, die zwischen 17.5 und 18.5 wiegen. Daher wächst der Balken auf eine Anzahl von drei.

Wir können mit der Option `binwidth` in dem `geom_histogram()` einstellen, wie breit auf der x-Achse die jeweiligen Balken sein sollen. Hier empfiehlt es sich verschiedene Zahlen für `binwidth` auszuprobieren.

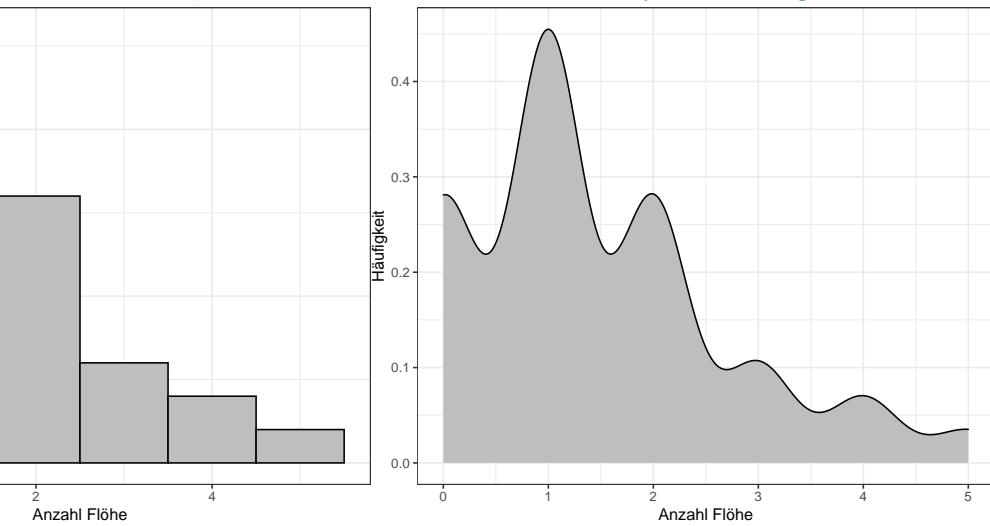
15.3.2 Density Plot

Eine weitere Möglichkeit sich eine Verteilung anzuschauen, ist die Daten nicht als Balkendiagramm sondern als Densityplot - also DichteVerteilung - anzusehen. Im Prinzip verwandeln wir die Balken in eine Kurve. Damit würden wir im Prinzip unterschiedliche Balkenhöhen ausgleichen und eine "glattere" Darstellung erreichen. Wir werden aber gleich sehen werden, benötigen wir dazu eine Menge an Beobachtungen und auch dann ist das Ergebnis eventuell nicht gut zu interpretieren.

15.3 Häufig verwendete Abbildungen

```
ggplot(data = dog_fleas_hist_tbl, aes(x = flea_count)) +
  geom_histogram(binwidth = 1, fill = "gray", color = "black") +
  theme_bw() +
  labs(x = "Anzahl Flöhe", y = "Anzahl")

ggplot(data = dog_fleas_hist_tbl, aes(x = flea_count)) +
  geom_density(fill = "gray", color = "black") +
  theme_bw() +
  labs(x = "Anzahl Flöhe", y = "Häufigkeit")
```



(b) Densityplot

nenhang von Histogramm und Densityplot an der Hunden.

Abbildung ?? zeigt auf der linken Seite erneut die Abbildung des Histogramms als Balkendiagramm für die Anzahl der Flöhe auf den 39 Hunden. Auf der rechten Seite die entsprechenden gleichen Daten als Denistyplot. Klar ist die Wellenbewegung des Densityplots zu erkennen. Hier liegen zu wenige Beobachtungen und Kategorien auf der x-Achse vor, so dass der Densityplot nicht zu empfehlen ist.

```
ggplot(data = dog_fleas_hist_tbl, aes(x = flea_weight)) +
  geom_histogram(binwidth = 1, fill = "gray", color = "black") +
```

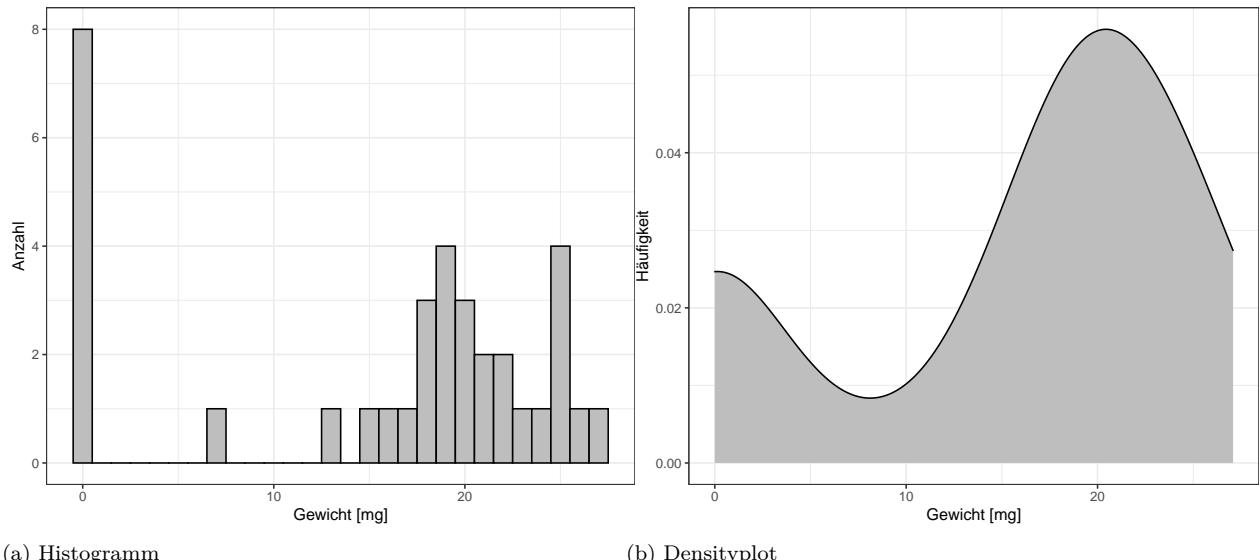
15 Visualisierung von Daten

```

theme_bw() +
labs(x = "Gewicht [mg]", y = "Anzahl")

ggplot(data = dog_fleas_hist_tbl, aes(x = flea_weight)) +
  geom_density(fill = "gray", color = "black") +
  theme_bw() +
  labs(x = "Gewicht [mg]", y = "Häufigkeit")

```



(a) Histogramm

(b) Densityplot

Abbildung 15.7: Zusammenhang von Histogramm und Densityplot am Gewicht der Flöhe auf 39 Hunden.

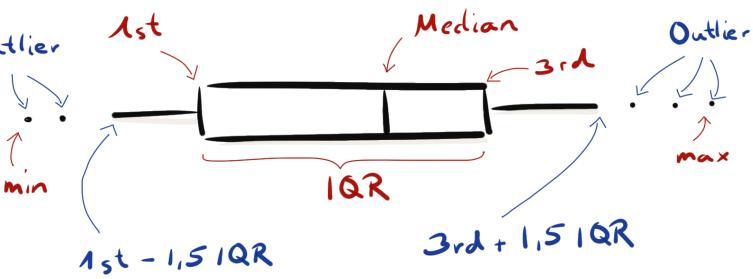
Abbildung ?? zeigt auf der linken Seite erneut die Abbildung des Histogramms als Balkendiagramm für das Gewicht der Flöhe auf den 39 Hunden. Insbesondere bei dieser Abbildung erkennst du die Nachteile des Densityplot. Dadurch das es einen Peak von acht Hunden mit einem Flohgewicht von 0 gibt, zeigt der Densityplot eine seltsame Wellenform. Es empfiehlt sich daher die Daten zuerst als Histogramm zu betrachten.

15.3.3 Boxplot

In Kapitel ?? haben wir den Median und die Quartile kennengelernt. Mit dem Boxplot können wir den Median und die Quartile visualisieren. In Abbildung ?? sehen wir einen Boxplot, der

15.3 Häufig verwendete Abbildungen

den Median und die Quartile visualisiert. Die Box wird aus dem IQR gebildet. Der Median wird als Strich in der Box gezeigt. Die Schnurrhaare (eng. *Whiskers*) sind das 1.5 fache des IQR. Punkte die außerhalb der Schnurrhaare liegen werden als einzelne Punkte dargestellt. Diese einzelnen Punkte werden auch als Ausreißer (eng. *Outlier*) bezeichnet.



Boxplot der die statistischen Maßzahlen Median und Box wird aus dem IQR gebildet. Der Median wird eingezeichnet. Die Schnurrhaare sind das 1.5 fache des IQR. Punkte die außerhalb der Schnurrhaare liegen werden als einzelne Punkte dargestellt.

In Abbildung ?? sehen wir den Zusammenhang zwischen einem Histogramm, Densityplot und dem Boxplot. Der Median \tilde{y} im Boxplot zeigt die höchste Stelle des Densityplots an. Durch einen Boxplot kann die Verteilung der entsprechenden Zahlen abgeschätzt werden.

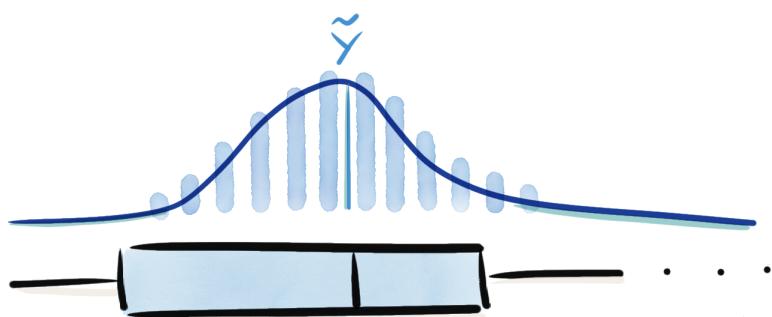


Abbildung 15.9: Der Zusammenhang von Histogramm, Densityplot und Boxplot.

Die "liegende" Darstellung des Boxplots dient nur der Veranschaulichung und dem Verständnis des Zusammenhangs von

15 Visualisierung von Daten

Histogramm und Boxplot. In der Abbildung ?? sehen wir drei Boxplots für einen Faktor mit drei Leveln. Jedes Level wird durch einen Boxplot dargestellt. Zum Beispiel eine Düngerbehandlung mit drei Konzentrationen. Auf der x-Achse würden wir die Behandlung finden und auf der y-Achse das Trocken Gewicht in [kg/ha].

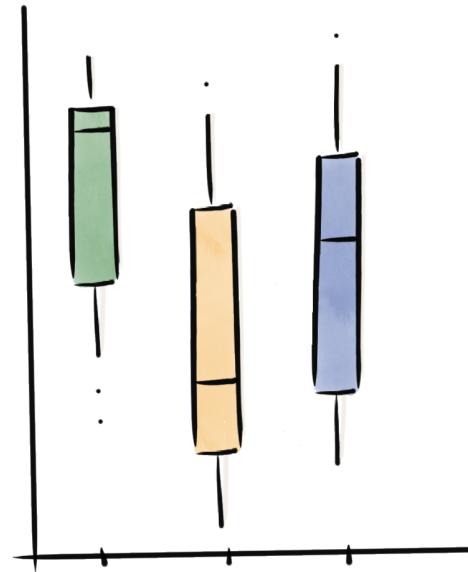


Abbildung 15.10: Typische Darstellung von drei Gruppen jeweils dargestellt durch einen Boxplot. Boxplots werden in der Anwendung stehend dargestellt. Insbesondere wenn die Boxplots mehrere Gruppen repräsentieren.

Wie erstellen wir nun einen Boxplot in R? Zuerst laden wir die Daten mit der Funktion `read_excel()` in R, wenn du die Daten als `.xlsx` Datei vorliegen hast. Im XX kannst du nochmal das Importieren von Daten wiederholen.

```
flea_dog_cat_tbl <- read_excel("data/flea_dog_cat.xlsx")
```

In Abbildung ?? ist der Boxplot für die Daten aus der Datei `flea_dog_cat.xlsx` dargestellt. Auf der x-Achse finden wir die Tierart als `cat` und `dog`. Auf der y-Achse ist die Sprungweite in [cm] dargestellt.

15.3 Häufig verwendete Abbildungen

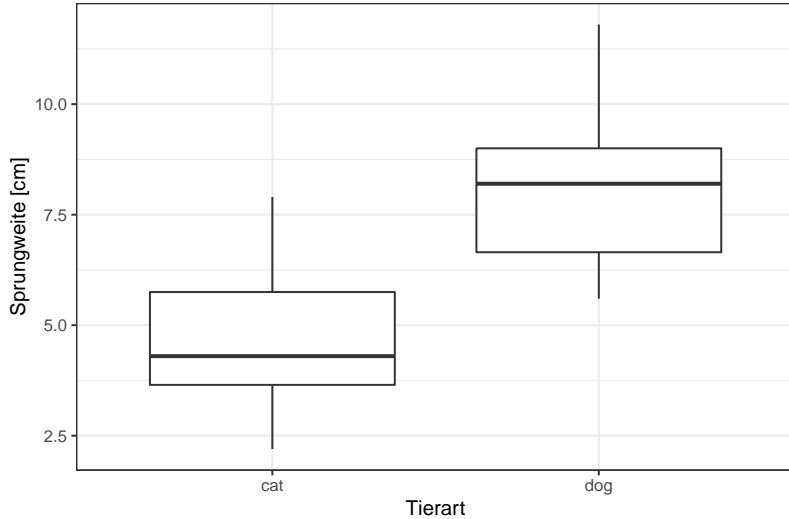


Abbildung 15.11: An 39 Hunden wurde die Anzahl an Flöhen gezählt.

Wir erkennen auf einen Blick, dass die Sprungweite von den Hundeflöhen weiter ist als die Sprungweite der Katzenflöhe. Im Weiteren können wir abschätzen, dass die Streuung etwa gleich groß ist. Die Boxen sind in etwa gleich groß und die Whiskers in etwa gleich lang.

```
ggplot(data = flea_dog_cat_tbl, aes(x = animal, y = jump_length,
                                      fill = animal)) +
  geom_boxplot() +
  geom_jitter(width = 0.25, shape = 1) +
  theme_bw() +
  labs(x = "Tierart", y = "Sprungweite [cm]")
```

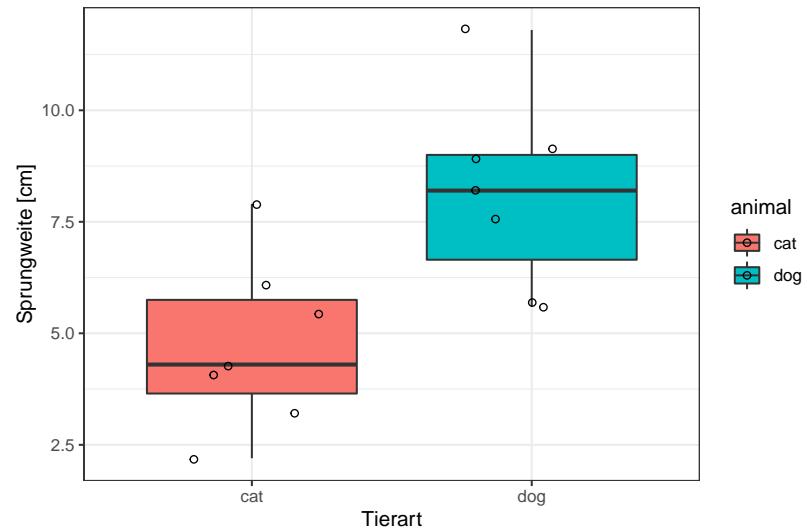


Abbildung 15.12: An 39 Hunden wurde die Anzahl an Flöhen gezählt.

Wir neigen dazu die Boxplots überzuinterpretieren, wenn die Anzahl der Beobachtungen klein ist. Deshalb können wir mit dem `geom_jitter()` noch die Beobachtungen zu den Boxplot ergänzen, dargestellt in Abbildung ???. Die Funktion `geom_jitter()` streut die Punkte zufällig, so dass keine Punkte übereinanderliegen. Wir haben hier die Streuweite durch die Option `width = 0.25` etwas eingeschränkt. Darüber hinaus habe ich das Aussehen der Punkte mit `shape = 1` geändert, so dass wir die Jitter-Punkte von den potenziellen Ausreißer-Punkten unterscheiden können. Du kannst auch andere Zahlen hinter `shape` eintragen um verschiedene Punkt-Symbole durchzuprobieren. Eine Übersicht an `shapes` findest du auch hier unter Cookbook for R > Graphs > Shapes and line types.

15.3.4 Barplot oder Balkendiagramm

Der Barplot oder das Balkendiagramm ist eigentlich veraltet. Wir haben mit dem Boxplot eine viel bessere Methode um eine Verteilung und *gleichzeitig* auch die Gruppenunterschiede zu visualisieren. Warum nutzen wir jetzt so viel den Barplot? Das

15.3 Häufig verwendete Abbildungen

hat damit zu tun, dass früher - oder besser bis vor kurzem - in Excel kein Boxplot möglich war. Daher nutzte jeder der mit Excel seine Daten auswertet den Barplot. Und was der Bauer nicht kennt...

Deshalb ist hier auch der Barplot dargestellt. Ich persönlich mag den Barplot überhaupt nicht. Der Barplot ist einfach schlechter als der Boxplot. Aber gut, häufig musst du den Barplot in deiner Abschlussarbeit machen. Also dann hier der Barplot.

Wie erstellen wir nun einen Barplot in R? Zuerst laden wir die Daten mit der Funktion `read_excel()` in R, wenn du die Daten als `.xlsx` Datei vorliegen hast. Im Kapitel ?? kannst du nochmal das Importieren von Daten wiederholen.

```
flea_dog_cat_tbl <- read_excel("data/flea_dog_cat.xlsx")
```

Wir müssen jetzt für `ggplot()` noch den Mittelwert und die Streuung für die Gruppen berechnen. Ein komplexeres Beispiel für einen Barplot findest du in Kapitel ???. Du kannst als Streuung die Standardabweichung oder den Standardfehler nehmen. Ich würde die Standardabweichung bei kleinen Fallzahlen kleiner als 20 Beobachtungen nehmen.

```
stat_tbl <- flea_dog_cat_tbl %>%
  group_by(animal) %>%
  summarise(mean = mean(jump_length),
            sd = sd(jump_length),
            se = sd/sqrt(n()))
```

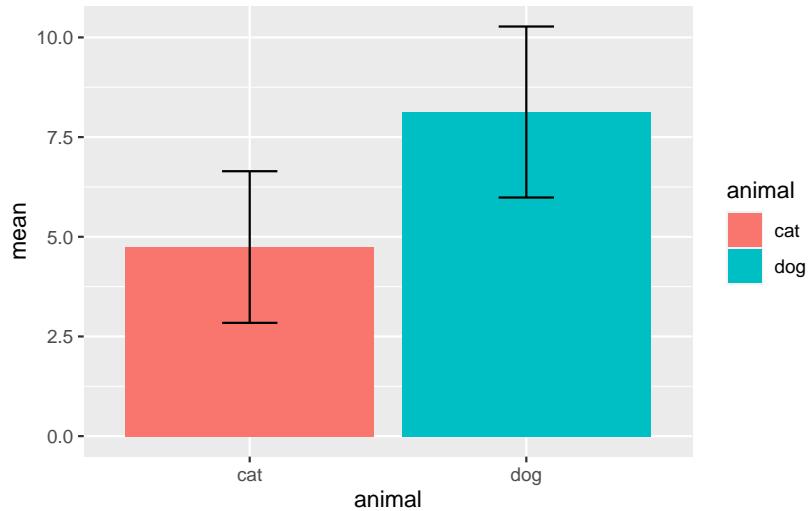
Wir nutzen nun das Objekt `stat_tbl` um den Barplot mit der Funktion `ggplot()` zu erstellen. Dabei müssen wir zum einen schauen, dass die Balken nicht übereinander angeordnet sind. Nebeneinander angeordnete Balken kriegen wir mit der Option `stat = "identity"` in dem `geom_bar()`. Dann müssen wir noch die Fehlerbalken ergänzen mit dem `geom_errorbar`. Hier kann nochmal mit der Option `width =` an der Länge der Fehlerbalken gedreht werden.

1. Alles was es schon gab, als Du geboren wurdest, ist normal und gewöhnlich. Diese Dinge werden als natürlich wahrgenommen und halten die Welt am Laufen.
2. Alles was zwischen Deinem 16ten und 36ten Lebensjahr erfunden wird ist neu, aufregend und revolutionär. Und vermutlich kannst Du in dem Bereich sogar Karriere machen.
3. Alles was nach dem 36ten Lebensjahr erfunden wird ist gegen die natürliche Ordnung der Dinge.

– Douglas Adams aus *Per Anhalter durch die Galaxis*

15 Visualisierung von Daten

```
ggplot(stat_tbl, aes(x = animal, y = mean, fill = animal)) +  
  geom_bar(stat = "identity") +  
  geom_errorbar(aes(ymin = mean-sd, ymax = mean+sd),  
    width = 0.2)
```



Im Zweifel muss du nochmal googlen und schauen welche Form dir am besten zusagt. Es gibt sehr viele Möglichkeiten einen Barplot zu erstellen. Daher komm im Zweifel einmal ins R Tutorium.

15.3.5 Dotplot

Wenn wir weniger als fünf Beobachtungen haben, dann ist meist ein Boxplot verzerrend. Wir sehen eine Box und glauben, dass wir viele Datenpunkte vorliegen haben. Bei 3 bis 7 Beobachtungen je Gruppe bietet sich der Dotplot als eine Lösung an. Wir stellen hier alle Beobachtungen als einzelne Punkte dar.

Wie erstellen wir nun einen Dotplot in R? Zuerst laden wir die Daten mit der Funktion `read_excel()` in R, wenn du die Daten als `.xlsx` Datei vorliegen hast. Im XX kannst du nochmal das Importieren von Daten wiederholen.

```
flea_dog_cat_tbl <- read_excel("data/flea_dog_cat.xlsx")
```

15.3 Häufig verwendete Abbildungen

```
ggplot(data = flea_dog_cat_tbl, aes(x = animal, y = grade,
                                      fill = animal)) +
  geom_dotplot(binaxis = "y", stackdir = "center") +
  theme_bw() +
  labs(x = "Tierart", y = "Boniturnote [1-9]")
```

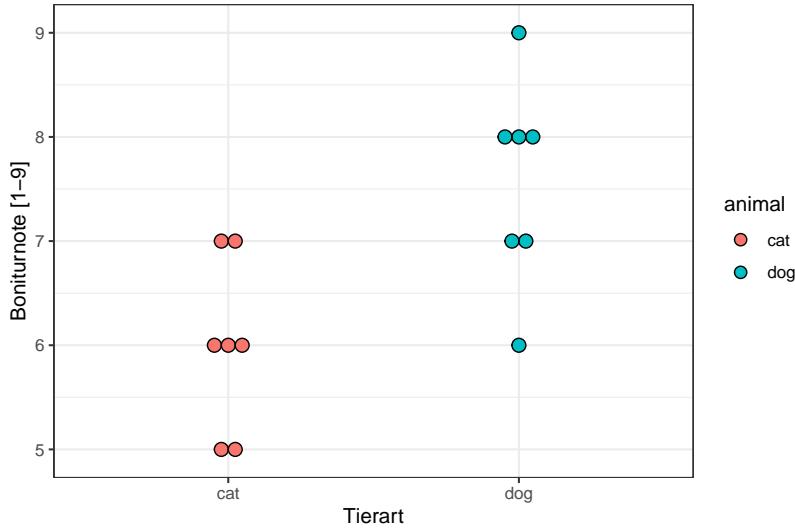


Abbildung 15.13: Der Dotplot für die Anzahl der Flöhe für die beiden Tierarten Hund und Katze.

In Abbildung ?? sehen wir den Dotplot aus der Datei `flea_dog_cat.xlsx`. Auf der x-Achse sind die Level des Faktors `animal` dargestellt und auf der y-Achse die Notenbewertung `grade` der einzelnen Hunde und Katzen. Die Funktion `geom_dotplot()` erschafft das Layer für die Dots bzw. Punkte. Wir müssen in der Funktion noch zwei Dinge angeben, damit der Plot so aussieht, dass wir den Dotplot gut interpretieren können. Zum einen müssen wir die Option `binaxis = y` wählen, damit die Punkte horizontal geordnet werden. Zum anderen wollen wir auch, dass die Punkte zentriert sind und nutzen dafür die Option `stackdir = center`.

```
ggplot(data = flea_dog_cat_tbl, aes(x = animal, y = grade,
                                      fill = animal)) +
```

15 Visualisierung von Daten

```
geom_dotplot(binaxis = "y", stackdir = "center") +
stat_summary(fun = median, fun.min = median, fun.max = median,
            geom = "crossbar", width = 0.5) +
theme_bw() +
labs(x = "Tierart", y = "Boniturnote [1-9]")

```

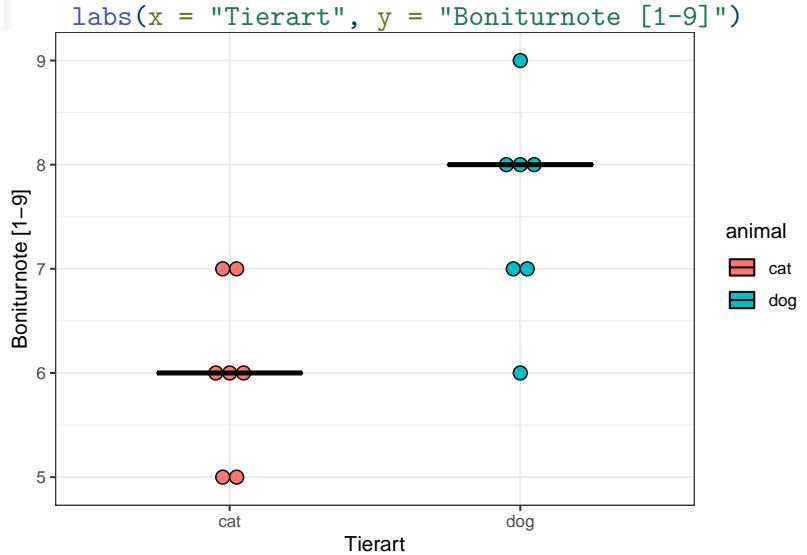


Abbildung 15.14: Der Dotplot für die Anzahl der Flöhe für die beiden Tierarten Hund und Katze. Die schwarze Linie stellt den Median für die beiden Tierarten dar.

Nun macht es wenig Sinn bei sehr wenigen Beobachtungen noch statistische Maßzahlen mit in den Plot zu zeichnen. Sonst hätten wir auch gleich einen Boxplot als Visualisierung der Daten wählen können. In Abbildung ?? sehen wir die Ergänzung des Medians. Hier müssen wir etwas mehr angeben, aber immerhin haben wir so eine Idee, wo die “meisten” Beobachtungen wären. Aber auch hier ist Vorsicht geboten. Wir haben sehr wenige Beobachtungen, so dass eine Beobachtung mehr oder weniger große Auswirkungen auf den Median und die Interpretation hat.

15.3.6 Scatterplot

Der Scatterplot wird auch xy-Plot genannt. Wir stellen in einem Scatterplot zwei kontinuierliche Variablen dar. Dann wollen wir eine Linie durch die Punkte legen. Im Prinzip fragen wir uns, wie hängt die Werte auf der y-Achse von den Werten auf der x-Achse ab? Wenn sich also die Werte auf der x-Achse erhöhen, wie verhalten sich dann die Werte auf der y-Achse?

```
ggplot(data = flea_dog_cat_tbl, aes(x = flea_count, y = jump_length)) +
  geom_point() +
  stat_smooth(method = "lm", se = FALSE) +
  theme_bw() +
  labs(x = "Anzahl der Flöhe", y = "Sprungweite in [cm]")
```

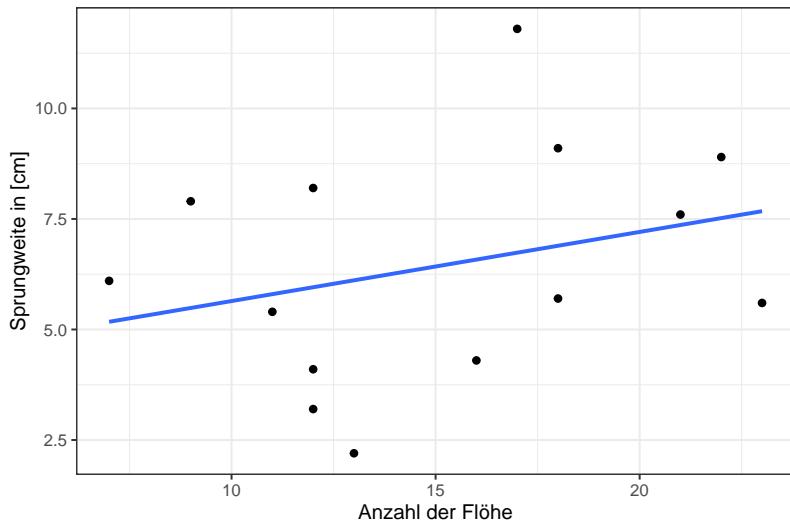


Abbildung 15.15: Zusammenhang zwischen der Sprungweite in [cm] und der Anzahl an Flöhen auf den 39 Hunden. Jeder Punkt stellt einen Hund dar.

Abbildung ?? zeigt den Scatterplot für die Spalte `flea_count` auf der x-Achse und `jump_length` auf der y-Achse. Mit der Funktion `geom_point()` können wir die Punktpaare für jede Beobachtung zeichnen. In unserem Fall zeichnen wir mit der Funktion `stat_smooth()` noch die entsprechende Grade durch

15 Visualisierung von Daten

die Punkte. Es handelt sich hierbei um eine Regression. Du kannst im Kapitel XX mehr darüber erfahren.

15.3.7 Mosaic Plot

Wenn wir zwei Spalten visualisieren wollen, die aus zwei Faktoren bestehen mit jeweils zwei Leveln, dann nutzen wir den Mosaic Plot. Wir nutzen den Datensatz `flea_dog_cat.xlsx` mit vierzehn Beobachtungen. Schauen wir uns einmal die 2x2 Kreuztabelle der beiden Spalten `animal` and `infected` an.

```
flea_dog_cat_tbl %>%
  mutate(animal = factor(animal, levels = c("dog", "cat"))) %>
  tabyl(animal, infected)
```

animal	0	1
dog	4	3
cat	5	2

Wir sehen in der Tabelle, dass wir mehr uninfizierte Tiere ($n = 9$) als infizierte Tiere haben ($n = 5$). Die Aufteilung zwischen den beiden Tierarten ist nahezu gleich. Im folgenden wollen wir diese Tabelle durch einen Mosaic Plot einmal visualisieren.

```
ggplot(data = flea_dog_cat_tbl) +
  geom_mosaic(aes(x = product(animal, infected), fill = animal))
```

15.4 Überschriften, Achsen und Legenden

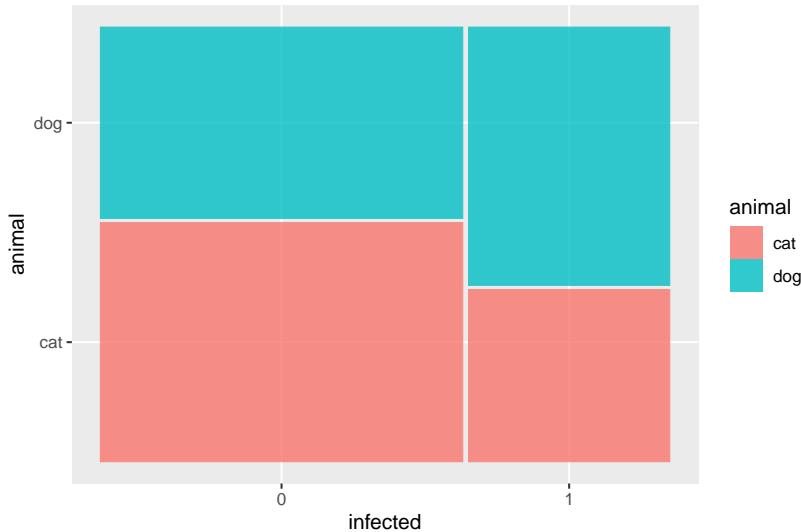


Abbildung 15.16: Visualisierung einer 2x2 Tabelle als Mosaic Plot. Die unterschiedlich großen Flächen geben die Verhältnisse wieder.

Abbildung ?? zeigt den Mosaic Plot für die Variable `animal` und `infected`. Die unterschiedlich großen Flächen bilden die Verhältnisse der 2x2 Tabelle ab. So sehen wir, dass es mehr uninizierte Tiere als infizierte Tiere gibt. Am meisten gibt es uninizierte Katzen. Am wenigsten treten infizierte Katzen auf.

15.4 Überschriften, Achsen und Legenden

Wenn du mehr machen willst, also die Überschriften anpassen oder aber die Achsenbeschriftung ändern, dann gibt es hier global Hilfe im ggplot Manual. Die Webseite R Cookbook hat auch spezielle Hilfe für `ggplot()`.

- Überschriften von Abbildungen
- Achsenbeschriftung
- Legende
- Farben

Im Kapitel ?? findest du Informationen zum R Tutorium, wann und wo es stattfindet.

15 Visualisierung von Daten

In Abbildung ?? siehst du eine Abbildung mit Titel und veränderten Beschriftungen. Die Möglichkeiten sind nahezu unbegrenzt und sprengen auch hier den Rahmen. Im Zweifel im R Tutorium vorbeischauen oder aber in der Vorlesung fragen.

```
ggplot(data = flea_dog_cat_tbl, aes(x = animal, y = jump_length,
                                         fill = animal)) +
  geom_boxplot() +
  labs(title = "Frischgewicht in Abhängigkeit von der Behandlung",
       x = "Behandlung", y = "Frischgewicht in kg/ha") +
  scale_x_discrete(labels = c("Katze", "Hund")) +
  scale_fill_discrete(name = "Behandlung", labels = c("Katze",
                                                       "Hund")) +
  theme_bw()
```

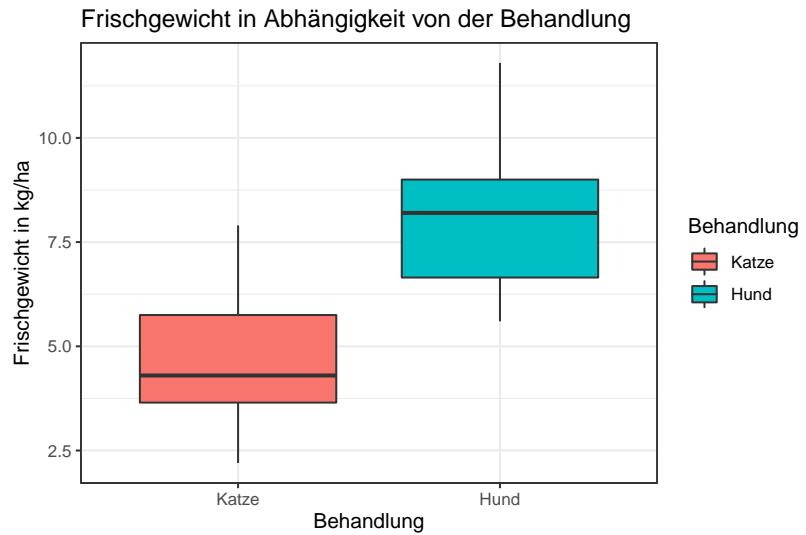


Abbildung 15.17: Beispielhafte Abbildung mit Titel und geänderter Achsenbeschriftung

15.5 Die Okabe-Ito Farbpalette

Neben den klassischen Farben im R Paket ggplot gibt es noch mehr zum R Paket [see](#) auf der [weil.weit](#) mehr Farbpaletten. Wir nutzen in der Folge immer wieder die Okabe-Ito Farbpalette aus dem R Paket [see](#). Die Okabe-Ito Farbpalette ist speziell so gebaut, dass die Farben

15.5 Die Okabe-Ito Farbpalette

sich gut für farbenblinde Personen unterscheiden. Der Kontrast zwischen den Farben ist sehr gut. Wenn du eine andere Farbpalette nutzen willst, findest du hier noch andere Color Scales.

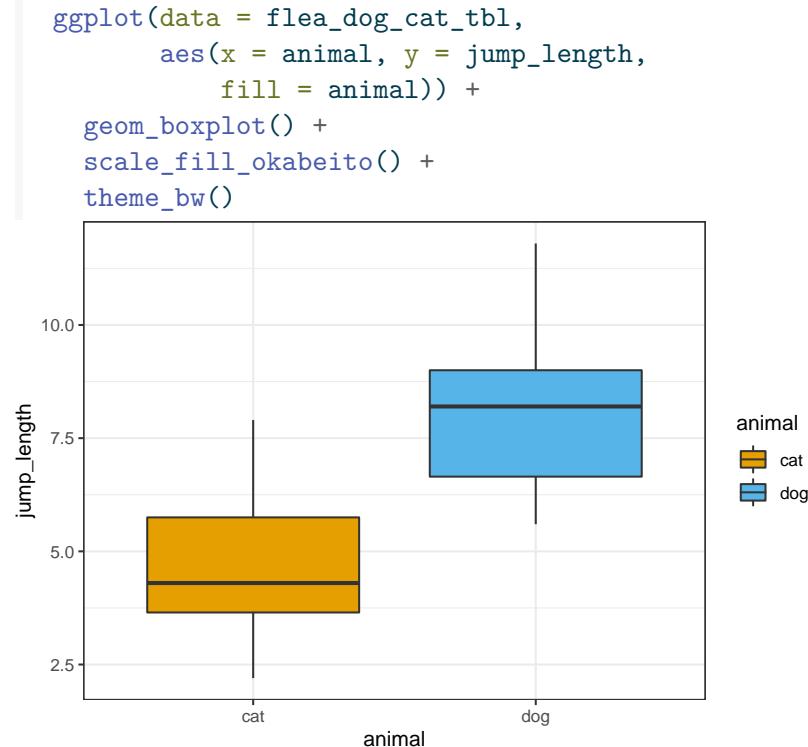


Abbildung 15.18: Beispielhafte Abbildung der Okabe-Ito Farbpalette für Boxplots.

```
ggplot(data = flea_dog_cat_tbl,
       aes(x = animal, y = jump_length,
           color = animal)) +
  geom_point() +
  scale_color_okabeito() +
  theme_bw()
```

15 Visualisierung von Daten

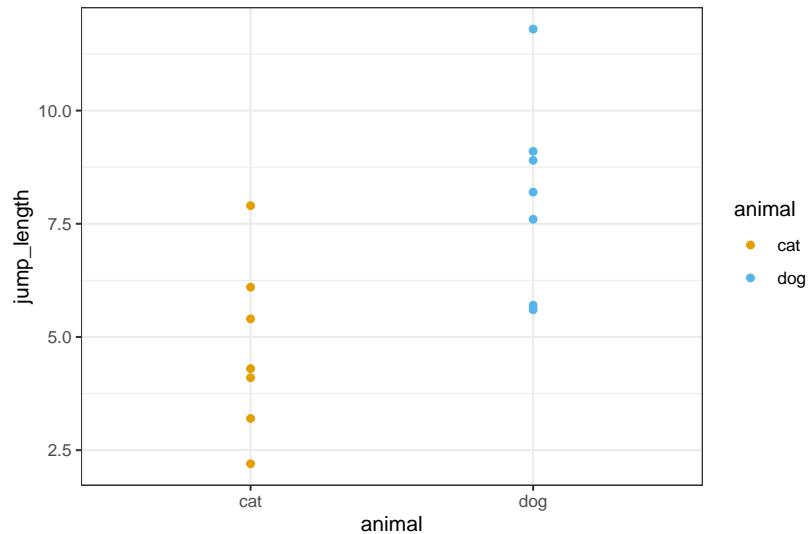


Abbildung 15.19: Beispielhafte Abbildung der Okabe-Ito Farbpalette für Punkte.

15.6 Abbildungen nebeneinander

Das R Paket patchwork erlaubt es mehrere `ggplot` Abbildungen nebeneinander oder in einem beliebigen Layout miteinander zu verbinden. Das tolle ist, dass die Idee sehr intuitiv ist. Wir nutzen wieder das `+` um verschiedene Plots miteinander zu verbinden.

Im Folgenden erschaffen wir uns zwei `ggplots` und speichern die Plots in den Objekten `p1` und `p2`. Das ist wie wir es bisher kennen, nur das jetzt keine Abbildung erscheint sondern beide Plots in zwei Objekten gespeichert sind.

```
p1 <- ggplot(data = flea_dog_cat_tbl,
              aes(x = flea_count, y = jump_length,
                  color = animal)) +
  geom_point() +
  scale_color_okabeito() +
  theme_bw()

p2 <- ggplot(data = flea_dog_cat_tbl,
```

15.6 Abbildungen nebeneinander

```
aes(x = animal, y = jump_length,  
     color = animal)) +  
geom_point() +  
scale_color_okabeito() +  
theme_bw()
```

Wie können wir nun die beiden Abbildungen nebeneinander zeichnen? Wir nutzen einfach das `+` Symbol.

```
p1 + p2
```

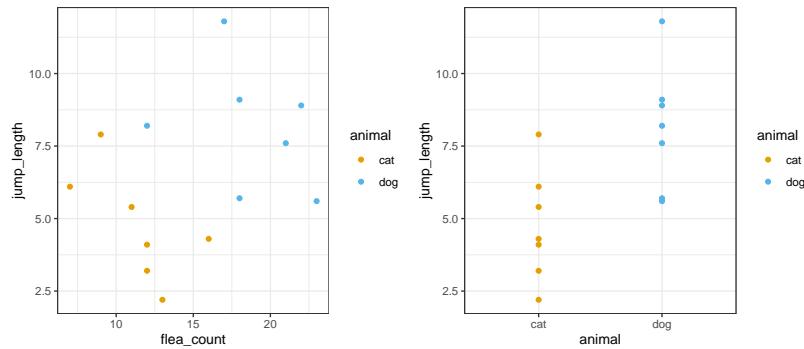


Abbildung 15.20: Beispielhafte Abbildung der zweier Plots nebeneinander.

Auf der Seite des R Paket patchwork findest du viel mehr Möglichkeiten das Layout anzupassen und auch die einzelnen Subplots zu beschriften.

16 Transformieren von Daten

Version vom September 14, 2022 um 08:47:40

Warum müssen wir Daten transformieren? Meistens hat dies zwei Hauptgründe.

- 1) Wir wollen eine ANOVA oder eine Gaussian lineare Regression rechnen und benötigen ein normalverteiltes Outcome y
- 2) Wir wollen einen Algorithmus zur Prädiktion (deu. *Vorhersage*) nutzen und haben sehr viele Einflussvariablen x in sehr unterschiedlichen Einheiten.

Ich verweise hier auch nochmal auf das tolle Tutorial von Matus Seci auf dem Coding Club

Im ersten Fall wollen wir meist unsere Daten *log*-Transformieren um aus einem *nicht*-normalverteilten Outcome y ein *log*-normalverteiltes y zu erschaffen. Im zweiten Fall wollen wir unsere Daten Standardisieren oder Normalisieren. Wir brauchen normalisierte Daten später beim Klassifizieren im Rahmen von maschinellen Lernverfahren.

Wir wollen uns nun die Verfahren zur Transformation von Daten in den folgenden Abschnitten einmal alle anschauen.

16.1 Genutzte R Pakete für das Kapitel

Wir wollen folgende R Pakete in diesem Kapitel nutzen.

```
pacman::p_load(tidyverse, magrittr, conflicted)
conflict_prefer("select", "dplyr")
conflict_prefer("filter", "dplyr")
```

Am Ende des Kapitels findest du nochmal den gesamten R Code in einem Rutsch zum selber durchführen oder aber kopieren.

16.2 Daten

Wir wollen uns in diesem Kapitel mit der normalverteilten Variable `jump_length` gemessen in [cm] und der nicht-normalverteilten Variable `hatch_time` gemessen in [h] aus dem Datensatz `flea_dog_cat_length_weight.csv` beschäftigen. Wir wählen über die Funktion `select()` nur die beiden Spalten aus dem Datensatz, die wir benötigen.

```
data_tbl <- read_csv2("data/flea_dog_cat_length_weight.csv") %>%  
  select(jump_length, hatch_time)
```

In der Tabelle ?? ist der Datensatz `data_tbl` nochmal dargestellt. Wir zeigen hier nur die ersten sieben Zeilen des Datensatzes.

Tabelle 16.1: Selektierter Datensatz mit einer normalverteilten Variable `jump_length` und der nicht-normalverteilten Variable `hatch_time`. Wir betrachten die ersten sieben Zeilen des Datensatzes.

jump_length	hatch_time
15.79	483.60
18.33	82.56
17.58	296.73
14.09	140.90
18.22	162.20
13.49	167.47
16.28	291.20

Im Folgenden nutzen wir oft die Funktion `mutate()`. Schau dir im Zweifel nochmal im Kapitel zu Programmierung die Funktion `mutate()` an.

16.3 *log*-Transformation

Wir nutzen die *log*-Transformation, wenn wir aus einem nicht-normalverteiltem Outcome y ein approximativer normalverteilt-

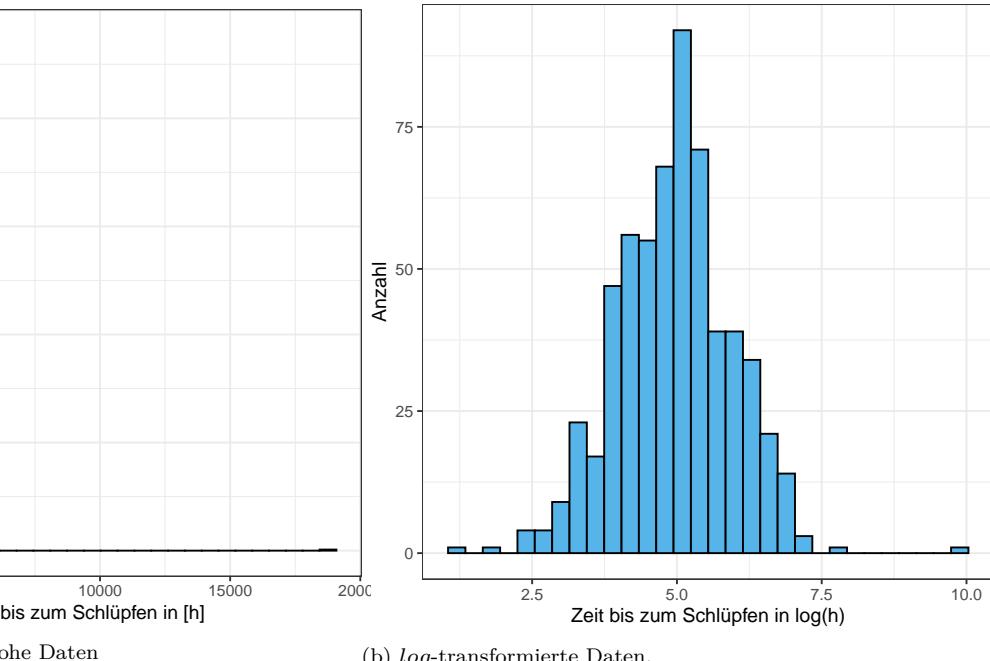
16.3 log-Transformation

tes Outcome y machen wollen. Dabei ist wichtig, dass wir natürlich auch die Einheit mit \log -transformieren.

Im Folgenden sehen wir die \log -Transformation der Variable `hatch_time` mit der Funktion `log()`. Wir erschaffen eine neue Spalte im `tibble` damit wir die beiden Variable vor und nach der \log -Transformation miteinander vergleichen können.

```
log_tbl <- data_tbl %>%
  mutate(log_hatch_time = log(hatch_time))
```

Wir können dann über ein Histogramm die beiden Verteilungen anschauen. In Abbildung ?? sehen wir die nicht transformierte, rohe Daten. Es gibt einen klaren Peak Schlüpfzeiten am Anfang. Dann läuft die Verteilung langsam aus. Wir können nicht annehmen, dass die Schlüpfzeiten normalverteilt sind. Abbildung ?? zeigt die \log -transmutierten Daten. In diesem Fall sehen wir normalverteilte Daten. Wir haben also ein \log normalverteiltes Outcome y mit dem wir jetzt weiterrechnen können.



16.4 Quadratwurzel-Transformationen

Die Quadratwurzel-Transformationen ist eine etwas seltener Transformation. Meist wird die Quadratwurzel-Transformationen als die schwächere *log*-Transformation bezeichnet. Wir sehen in Abbildung ?? den Grund dafür. Aber zuerst müssen wir aber über die Funktion `sqrt()` unsere Daten transformieren.

```
sqrt_tbl <- data_tbl %>%
  mutate(sqrt_hatch_time = sqrt(hatch_time))
```

In Abbildung ?? sehen wir die nicht transformierte, rohe Daten. Es gibt einen klaren Peak Schlüpfzeiten am Anfang. Dann läuft die Verteilung langsam nach rechts aus. Wir können nicht annehmen, dass die Schlüpfzeiten normalverteilt sind. Abbildung ?? zeigt die Wurzel-transmutierten Daten. Unser Ziel besser normalverteilte Daten vorliegen zu haben, haben wir aber mit der Quadratwurzel-Transformationen nicht erreicht. Die Daten sind immer noch rechtsschief. Wir würden also die *log*-Transformation bevorzugen.

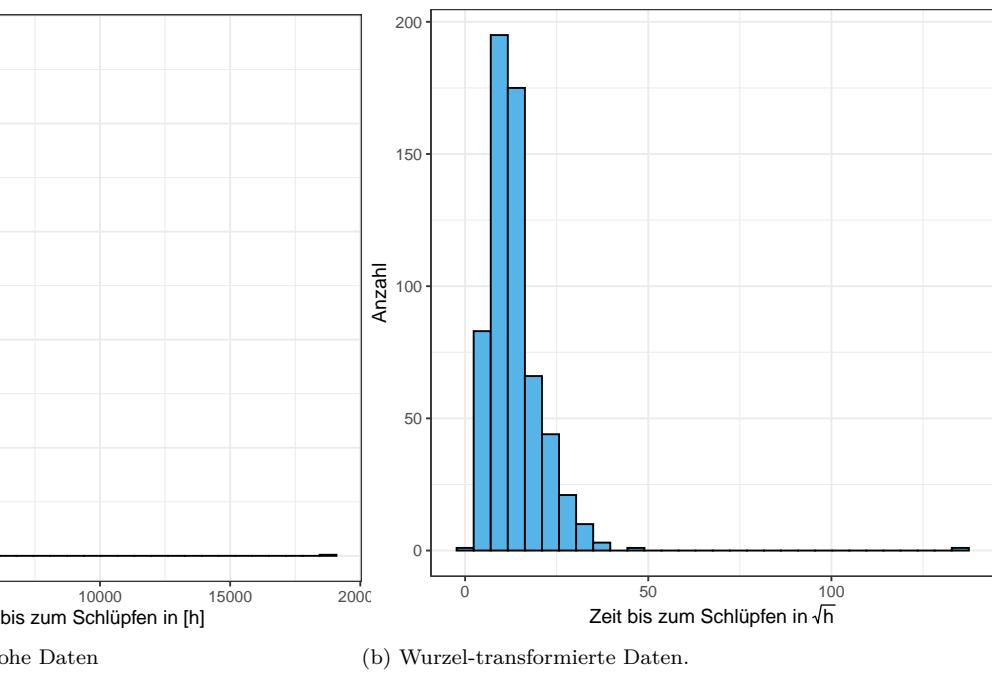
16.5 Standardisierung

Die Standardisierung wird auch *z*-Transformation genannt. In dem Fall der Standardisierung schieben wir die Daten auf den Ursprung, in dem wir von jedem Datenpunkt y_i den Mittelwert \bar{y} abziehen. Dann setzen wir noch die Standardabweichung auf Eins in dem wir durch die Standardabweichung s_y teilen. Unser standardisiertes y ist nun standard normalverteilt mit $\mathcal{N}(0, 1)$. Wir nutzen für die Standardisierung folgende Formel.

$$y_z = \frac{y_i - \bar{y}}{s_y}$$

In R können wir für die Standardisierung die Funktion `scale()` verwenden. Wir müssen auch nichts weiter in den Optionen von `scale()` angeben. Die Standardwerte der Funktion sind so eingestellt, dass eine Stanardnormalverteilung berechnet wird.

16.5 Standardisierung

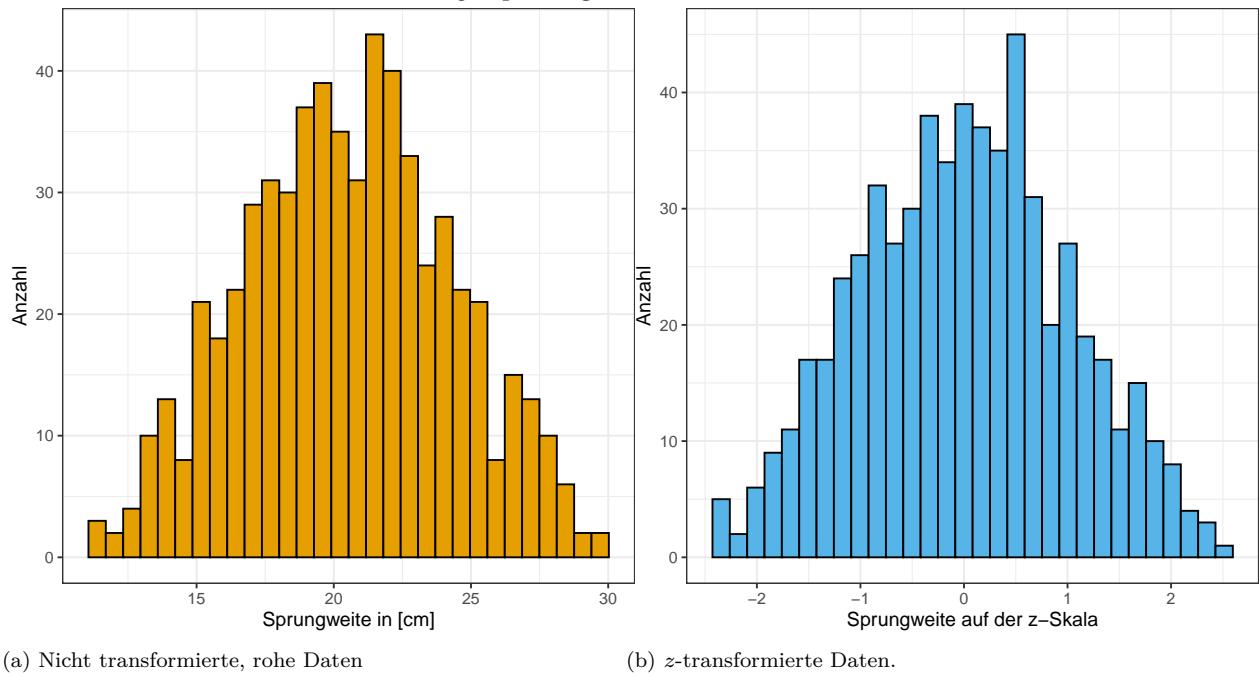


ohne Daten

(b) Wurzel-transformierte Daten.

zum Vergleich der nicht transformierten und transformierten

In Abbildung ?? sehen wir nochmal die nicht transformierten, rohen Daten. Wir haben in diesem Beispiel die normalverteilte Variable `jump_length` gewählt. Der Mittelwert von ~~16.7~~ ist ~~Transformieren der Daten~~ 20.91. Die Standardabweichung ist 3.77.



(a) Nicht transformierte, rohe Daten

(b) z -transformierte Daten.

Abbildung 16.3: Histogramm der nicht transfromierten und transformierten Daten.

16.6 Normalisierung

Abschließend wollen wir uns nochmal die Normalisierung anschauen. In diesem Fall wollen wir die Daten so transformieren, dass die Daten nur noch in der Spannweite 0 bis 1 vorkommen. Egal wie die Einheiten vorher waren, alle Variablen haben jetzt nur noch eine Ausprägung von 0 bis 1. Das ist besonders wichtig wenn wir viele Variablen haben und anhand der Variablen eine Vorhersage machen wollen. Uns interessieren die Werte in den Variablen an sich nicht, sondern wir wollen ein Outcome vorhersagen. Wir brauchen die Normalisierung später für das maschinelle Lernen und die Klassifikation. Die Formel für die Normalisierung lautet wie folgt.

$$y_n = \frac{y_i - \min(y)}{\max(y) - \min(y)}$$

In R gibt es die Normalisierungsfunktion nicht direkt. Wir könnten hier ein extra Paket laden, aber bei so einer simplen Formel können wir auch gleich die Berechnung in der Funktion `mutate()` machen. Wir müssen nur etwas mit den Klammern aufpassen.

```
sa_tbl %>%
  jump_length = (jump_length - min(jump_length))/(max(jump_length) - min(jump_length)))
```

In Abbildung ?? sehen wir nochmal die nicht transformierten, rohen Daten. In Abbildung ?? sehen wir die normalisierten Daten. Hier fällt dann auf, dass die normalisierten Sprungweiten nur noch Werte zwischen Null und Eins annehmen. Die Zahlen der auf der x-Achse haben jetzt aber keine Bedeutung mehr. Wie können die normalisierten Sprungweiten nicht mehr biologisch interpretieren.

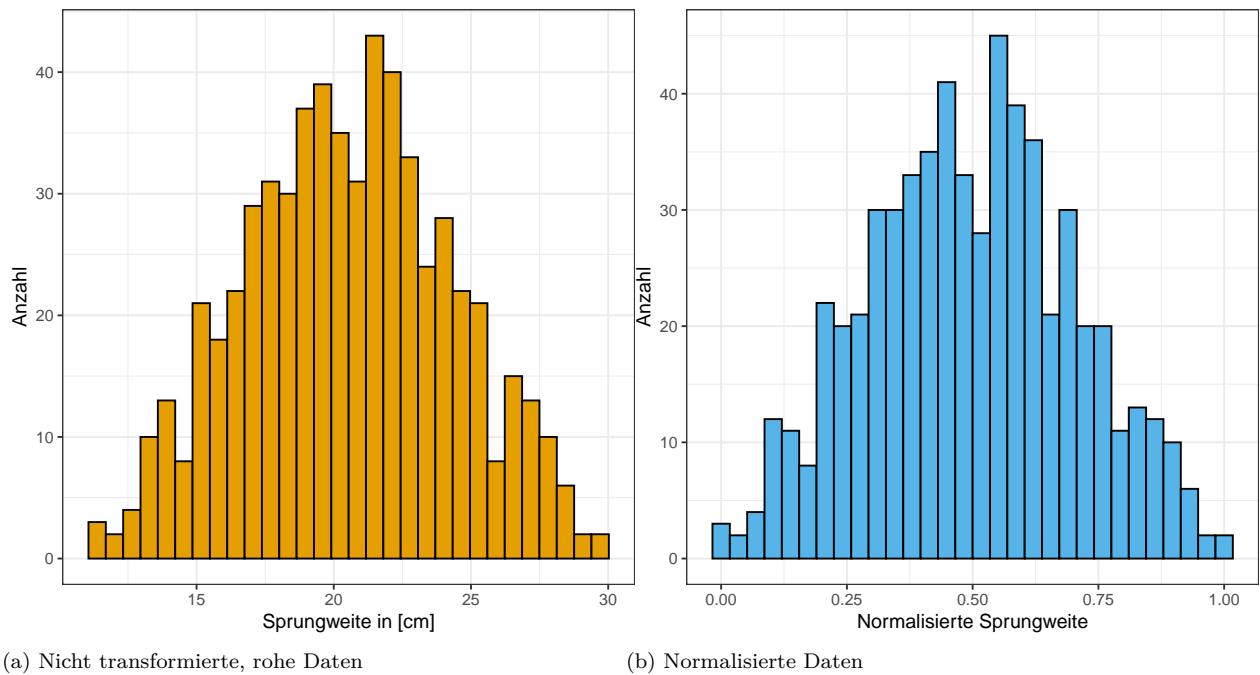


Abbildung 16.4: Histogramm der nicht transforierten und transformierten Daten.

17 Verteilung von Daten

Version vom September 14, 2022 um 08:48:02

In diesem Kapitel wollen wir uns mit Verteilungen beschäftigen. Dormann (2013) liefert eine weitreichende Übersicht über verschiedene Verteilungen. Wir wollen uns in diesem Kapitel mit folgenden Verteilungen beginnen.

- der **Normalverteilung**, die Glockenkurve oder auch **Gaussian** im englischen Sprachgebrauch genannt, die kontinuierliche Zahlen repräsentiert
- der **Poissonverteilung**, die diskrete Zähldaten repräsentiert.

Wir besuchen gerne die R Shiny App The distribution zoo um mehr über die verschiedenen Verteilungen und deren Parameter zu erfahren.

Wir wollen uns jetzt die verschiedenen Verteilungen einmal in der Anwendung anschauen. Dabei lassen wir viel Mathematik recht und links liegen. Du kannst bei Dormann (2013) mehr zu dem Thema statistische Verteilungen anlesen.

In diesem Kapitel geht es erstmal um das Grundverständnis, das Daten einer Verteilung folgen. Oder noch konkreter, dass unser Outcome y einer Verteilung folgt. Wir müssen später unseren Alogrithmen sagen, welcher Verteilung y entspringt, sonst können wir keine *korrekte* Analyse unser Daten rechnen.

Wir halten den mathematischen Teil zu den Verteilungen sehr kurz oder überspringen den Teil ganz. Wir brauchen die Idee der Verteilungen, weil wir später den Methoden sagen müssen wie unser Outcome y verteilt ist. Nur dann können wir die Daten richtig auswerten.



17.1 Genutzte R Pakete für das Kapitel

Wir wollen folgende R Pakete in diesem Kapitel nutzen.

```
pacman::p_load(tidyverse, magrittr, see, readxl)
```

Am Ende des Kapitels findest du nochmal den gesamten R Code in einem Rutsch zum selber durchführen oder aber kopieren.

17.2 Daten für Verteilungen

Damit wir uns auch eine Verteilung anschauen können brauchen wir *viele* Beobachtungen. Wir haben das ja schon bei den Histogrammen gesehen, wenn wir ein aussagekräftiges Histogramm erstellen wollen, dann brauchen wir viele Beobachtungen. Dafür nehmen wir für dieses Kapitel einmal den Gummibärchen-datensatz und schauen uns dort die Variablen `gender`, `height`, `count_bears` und `count_color` einmal genauer an. Wie immer nutzen wir die Funktion `select()` um die Spalten zu selektieren. Wir müssen jetzt nochmal alle fehlenden Werte mit der Funktion `na.omit()` entfernen, dass macht uns die Sache etwas leichter. Abschließend verwandeln wir das Geschlecht `gender` noch in einen Faktor.

```
gummi_tbl <- read_excel("data/gummibears.xlsx") %>%
  select(gender, height, count_bears, count_color) %>%
  na.omit() %>%
  mutate(gender = as_factor(gender))
```

Wir erhalten das Objekt `gummi_tbl` mit dem Datensatz in Tabelle ?? nochmal dargestellt.

Tabelle 17.1: Auszug aus den selektierten Daten zu den Gummibärchendaten.

gender	height	count_bears	count_color
m	193	9	3
w	159	10	5
w	159	9	6
w	180	10	5
m	180	10	6
m	180	10	5
...

17.3 Die Normalverteilung

gender	height	count_bears	count_color
w	165	12	5
w	177	10	2
w	173	9	5
w	168	12	6
m	183	8	5
w	171	9	5

Wir nutzen jetzt die Daten einmal um uns die Normalverteilung und die Poissonverteilung am Beispiel näher anzuschauen.

17.3 Die Normalverteilung

Wenn wir von der Normalverteilung sprechen, dann schreiben wir ein \mathcal{N} Symbol - also ein großes N mit Serifen. Die Normalverteilung sieht aus wie eine Glocke, deshalb wird die Normalverteilung auch Glockenkurve genannt. Im englischen Sprachgebrauch und auch in R nutzen wir dagegen die Bezeichnung nach dem “Endecker” der Normalverteilung, Carl Friedrich Gauß (1777 - 1985). Wir nennen daher die Normalverteilung auch Gaussian-Verteilung.

Eine Normalverteilung wird durch zwei Verteilungsparameter definiert. Eine Verteilung hat Parameter. Parameter sind die Eigenschaften einer Verteilung, die notwendig sind um eine Verteilung vollständig zu beschreiben. Im Falle der Normalverteilung brauchen wir zum einen den Mittelwert \bar{y} , der den höchsten Punkt unserer Glockenkurve beschreibt. Zum anderen brauchen wir auch die Standardabweichung s_y^2 , die die Ausbreitung oder Breite der Glockenkurve bestimmt. Wir beschreiben eine Normalverteilung wie folgt.

$$\mathcal{N}(\bar{y}, s_y^2)$$

Im Falle der Normalverteilung brauchen wir einen Parameter für den höchsten Punkt der Kurve, sowie einen Parameter für die Ausbreitung, also wie weit geht die Kurve nach links und nach

Wir sprechen in der Statistik auch von Verteilungsfamilien. Daher schreiben wir in R auch `family = gaussian`, wenn wir sagen wollen, dass unsere Daten einer Normalverteilung entstammen.

Parameter sind Zahlen, die eine Verteilungskurve beschreiben.

17 Verteilung von Daten

rechts. Je nach \bar{y} und s_y^2 können wir verschiedenste Normalverteilungen vorliegen haben. Eine Sammlung von Normalverteilungen nennen wir auch Familie (eng. *family*).

In Abbildung ?? sehen wir verschiedene Normalverteilungen mit unterschiedlichen Mittelwerten. In Abbildung ?? sehen wir eine Varianzhomogenität vorliegen, da die Varianzen in allen drei Normalverteilungen gleich sind. Wir können auch schreiben, dass $s_1^2 = s_2^2 = s_3^2 = 2$. In Abbildung ?? haben wir Varianzheterogenität vorliegen, da die Varianzen der Normalverteilungen ungleich sind. Wir können hier dann schreiben, dass $s_1^2 = 6 \neq s_2^2 = 1 \neq s_3^2 = 3$ sind. Häufig gehen statistische Verfahren davon aus, dass wir Varianzhomogenität über die Gruppen und daher auch die Normalverteilungen vorliegen haben. Konkret, wenn wir die Sprungweiten in [cm] von Hunde- und Katzenflöhen mit einander vergleichen wollen, dann gehen wir erstmal davon aus, dass die Mittelwerte verschieden sind, aber die Varianzen gleich sind.

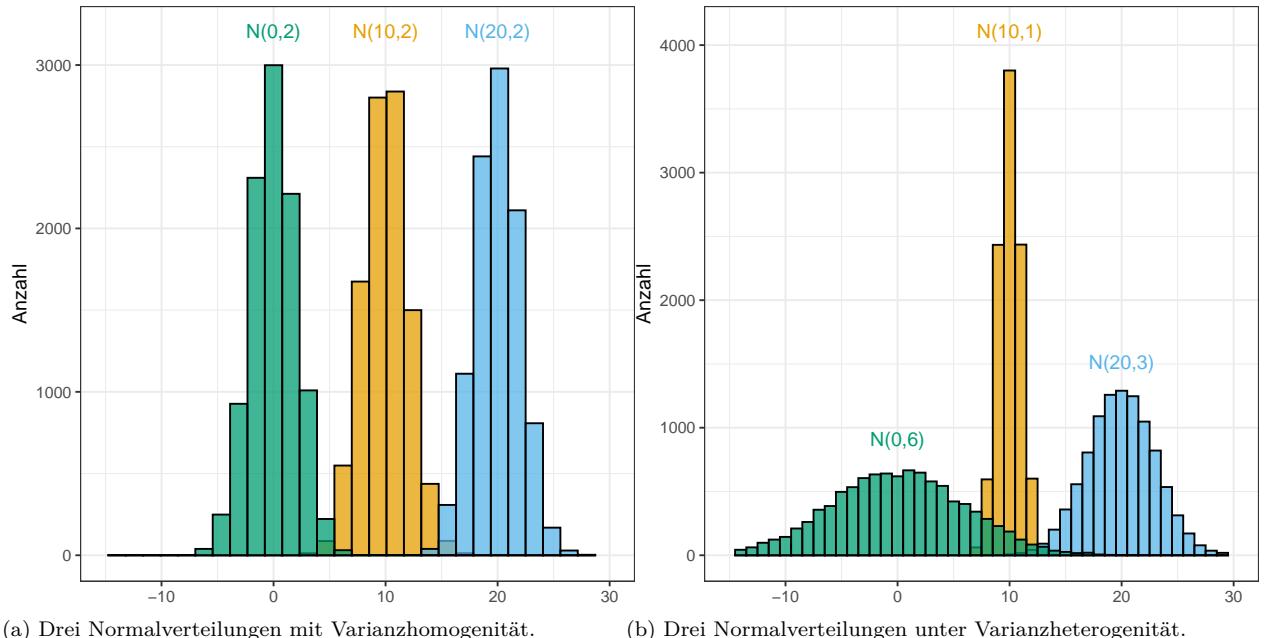


Abbildung 17.1: Histogramm verschiedener Normalverteilungen mit unterschiedlichen Mittelwerten.

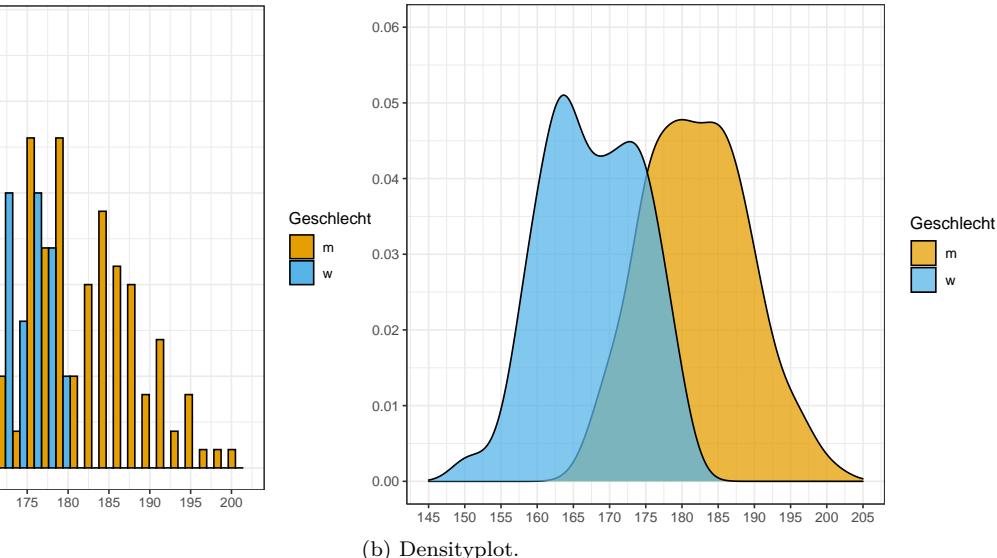
In einer Normalverteilung liegen 68% der Werte innerhalb $\bar{y} \pm s_y$. Wenn wir eine Normalverteilung vorliegen haben, dann liegen 95% der Werte innerhalb $\bar{y} \pm 2 \cdot s_y$.

17.3 Die Normalverteilung

68% der Werte plus/minus einer Standardabweichung vom Mittelwert. Ebenso liegen 95% der Werte plus/minus zwei Standardabweichungen vom Mittelwert. Über 99% der Werte befinden sich innerhalb von drei Standardabweichungen vom Mittelwert. Diese Eigenschaft einer Normalverteilung können wir später noch nutzen um abzuschätzen, ob wir einen relevanten Gruppenunterschied vorliegen haben oder aber ob unsere Daten *unnatürlich* breit streuen.

Schauen wir uns die Normalverteilung einmal am Beispiel unserer Gummibärchendaten und der Körpergröße der Studierenden an. Wir färben das Histogramm nach dem Geschlecht ein. In Abbildung ?? sehen wir das Ergebnis einmal als Histogramm und einmal als Densityplot dargestellt. Wir können annehmen, dass die Größe *approximativ* normalverteilt ist.

Wir nutzen das Wort
approximativ wenn wir sagen
 wollen, dass ein Outcome
 näherungsweise normalverteilt ist.



ung der Körpergröße in [cm] für die Geschlechter

Wir können die Funktion `rnorm()` nutzen um uns zufällige Zahlen aus der Normalverteilung ziehen zu lassen. Dazu müssen wir mit `n =` spezifizieren wie viele Beobachtungen wir wollen und den Mittelwert `mean =` und die gewünschte Standardabweichung mit `sd =` angeben. Im Folgenden einmal ein Beispiel für die Nutzung der Funktion `rnorm()` mit zehn Werten.

```
rnorm(n = 10, mean = 5, sd = 2) %>% round(2)
```

```
[1] 6.97 6.24 5.59 5.27 6.30 4.91 4.13 4.92 3.67 4.42
```

Du kannst ja mal den Mittelwert und die Standardabweichung der zehn Zahlen ausrechnen. Da wir es hier mit einer Stichprobe mit zehn Beobachtungen zu tun haben, wird der Mittelwert \bar{y} und die Standardabweichung s_y sich von den vorher definierten Mittelwert $\mu_y = 5$ und Standardabweichung $\sigma_y = 2$ der Grundgesamtheit unterscheiden.

Wir können auch aus unseren Gummibärchendaten für die Körpergröße in [cm] jeweils den Mittelwert und die Standardabweichung getrennt für die Geschlechter berechnen und dann die theoretische Normalverteilung zeichnen. In Abbildung ?? und Abbildung ?? sehen wir die Verteilung der theoretischen Werte, wenn wir die Mittelwerte und die Standardabweichung aus den Verteilungen in Abbildung ?? schätzen.

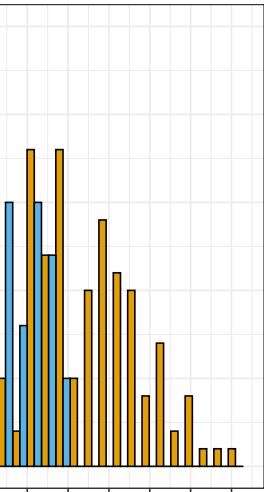
17.4 Die Standardnormalverteilung

Es gibt viele Normalverteilungen. Aber es gibt eine besondere Normalverteilung, so dass diese Verteilung einen eigenen Namen hat. Wir sprechen von der Standardnormalverteilung, wenn der Mittelwert gleich Null ist und die Standardabweichung gleich Eins. Du siehst hier nochmal die Standardnormalverteilung ausgeschrieben.

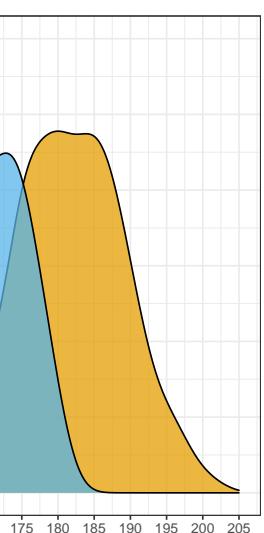
$$\mathcal{N}(0, 1)$$

Folgende Eigenschaften sind der Standardnormalverteilung gegeben. Die Standardnormalverteilung hat eine Fläche von $A = 1$ unter der Kurve. Darüber hinaus liegen 95% der Werte zwischen -2 und 2. Die einzelnen Werte einer Standardnormalverteilung nennen wir z -Werte. Wenn wir eine beliebige Normalverteilung in eine Standardnormalverteilung überführen wollen so machen wir die Umwandlung mit der z -Transformation.

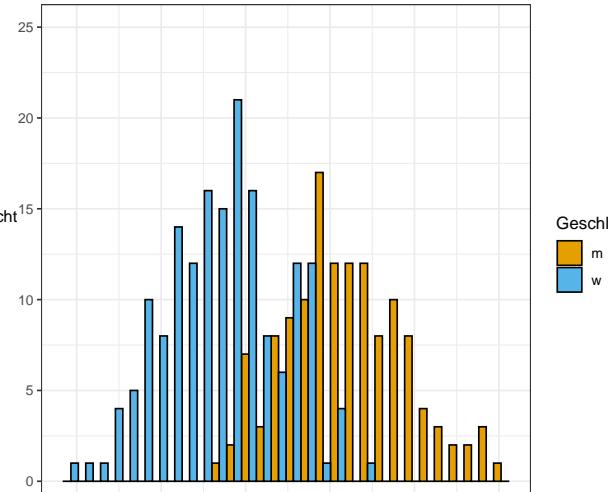
17.4 Die Standardnormalverteilung



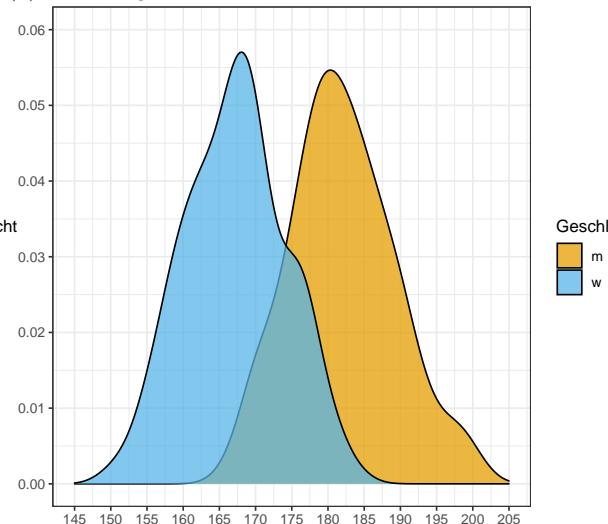
teten Werte.



teten Werte.



(b) Verteilung der theoretischen Werte.



(d) Verteilung der theoretischen Werte.

ung der Körpergröße in [cm] für die Geschlechter
Seite die beobachteten Werte und auf der rech-
nen Werte. Einmal dargestellt als Histogramm und

17.5 Die Poissonverteilung

Eine weitere wichtige Verteilung ist die Poissonverteilung. Die Poissonverteilung ist eine diskrete Verteilung. Daher kommen nur ganze Zahlen vor. Damit bildet die Poissonverteilung die Zähldaten ab. Wenn wir also etwas Zählen, dann ist diese Variable mit den gezählten Ergebnissen poissonverteilt. Im Folgenden sehen wir die Poissonverteilung einmal dargestellt.

$$\mathcal{Pois}(\lambda)$$

Im Gegensatz zur Normalverteilung hat die Poissonverteilung nur einen Parameter. Den Lageparameter λ ausgedrückt durch den griechischen Buchstaben Lambda. Eine Poissonverteilung mit $\mathcal{Pois}(4)$ hat den höchsten Punkt bei vier. Nun hat die Poissonverteilung hat mehrere Besonderheiten. Da die Poissonverteilung keinen Streuungsparameter hat, steigt mit dem λ auch die Streuung. Daher haben Poissonverteilungen mit einem großen λ auch eine große Streuung. ie Ausbreitung der Kurve ist eine Funktion von λ und steigt mit λ an. Du kannst diesen Zusammenhang in Abbildung ?? beobachten.

Darüber hinaus kann eine Poissonverteilung nicht negativ werden. Es kann keine kleinere Zahl als die Null geben. Durch die diskreten Zahlen haben wir auch immer mal Lücken zwischen den Balken der Poissonverteilung. Das passiert besonders, wenn wir eine kleine Anzahl an Beobachtungen haben. Abschließend konvergiert die Poissonverteilung bei großen λ hin zu einer Normalverteilung.

Schauen wir uns nun einmal die Poissonverteilung im Beispiel an. In Abbildung ?? sehen wir die Histogramme der Anzahl an Gummibärchen in einer Tüte und die Anzahl an Farben in einer Tüte. Da wir es hier mit Zähldaten zu tun haben, könnte es sich um eine Poissonverteilung handeln. Wie müssen uns nun die Frage stellen, ob die Gummibärchen in einer Tüte und die Anzahl an Farben in einer Tüte *wirklich* eine zufällige Realistierung sind. Daher eine zufällige Stichprobe der Grundgesamtheit. Wir können diese Annahme überprüfen in dem wir die theoretischen Werte für die beiden Poissonverteilung mit $\mathcal{Pois}(10)$ und $\mathcal{Pois}(5)$ generieren.

17.5 Die Poissonverteilung

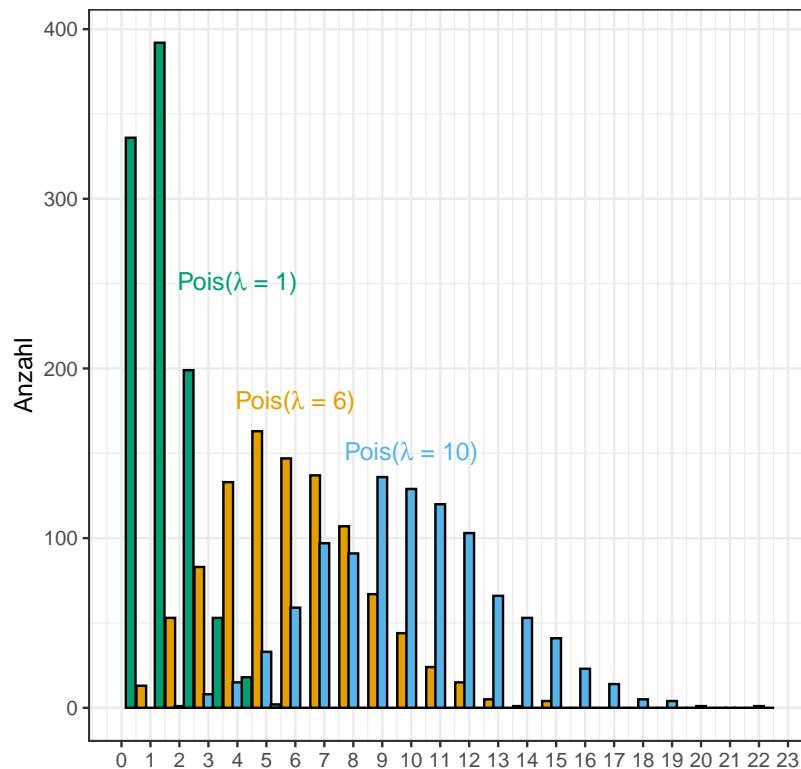


Abbildung 17.4: Histogramm verschiedener Poissonverteilungen.

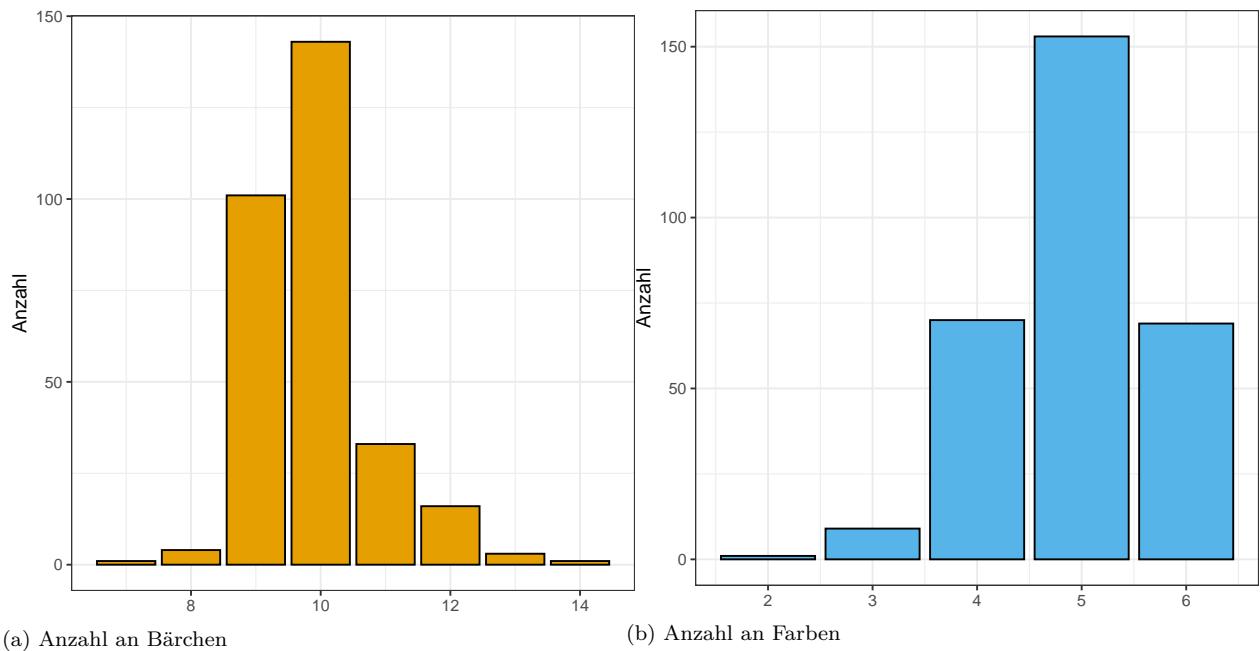


Abbildung 17.5: Histogramme der Anzahl an Gummibärchen und die Anzahl an Farben in einer Tüte. Es gibt nicht mehr als sechs Farben.

Wir können die Funktion `rpois()` nutzen um uns zufällige Zahlen aus der Poissonverteilung ziehen zu lassen. Dazu müssen wir mit `n =` spezifizieren wie viele Beobachtungen wir wollen und den Mittelwert `lambda =` angeben. Im Folgenden einmal ein Beispiel für die Nutzung der Funktion `rpois()` mit zehn Werten.

```
rpois(n = 10, lambda = 5)
```

```
[1] 3 5 4 5 3 3 9 3 5 5
```

Es gibt neben der Poissonverteilung auch die negative Binomialverteilung sowie die Quasi-Poissonverteilung. Wir können nun auch aus unseren Gummibärchendaten für die Anzahl an Bärchen in einer Tüte sowie die Anzahl an Farben in einer Tüte die theoretische Poissonverteilung berechnen. In Abbildung ?? sehen wir die Verteilung der beobachteten Werte für Anzahl an Bärchen in einer Tüte sowie die Anzahl an Farben in einer Tüte und deren theoretischen Verteilung nach dem geschätzten $\lambda = 10$ und $\lambda = 5$. Wir sehen ganz klar, dass die

17.6 Weitere Verteilungen

beide Variablen *keine* Zufallsrealisierung sind. Zum einen haben wir das auch nicht erwartet, es gibt nicht mehr als sechs Farben und zum anderen ist zu vermuten, dass Haribo technisch in den Auswahlprozess eingreift. Wir haben auf jeden Fall eine sehr viel kleinere Streuung als bei einer *klassischen* Poissonverteilung anzunehmen wäre.

17.6 Weitere Verteilungen

In der nächsten Zeit werden noch weitere gängige Verteilungen ergänzt. Bis dahin können die Basic Probability Distributions in R nochmal extern nachgeschaut werden.

Im Weiteren liefert Dormann (2013) eine gute Übersicht über verschiedene Verteilungen.

Wir besuchen gerne die R Shiny App
The distribution zoo um mehr über
die verschiedenen Verteilungen und
deren Parameter zu erfahren.

Referenzen

17 Verteilung von Daten

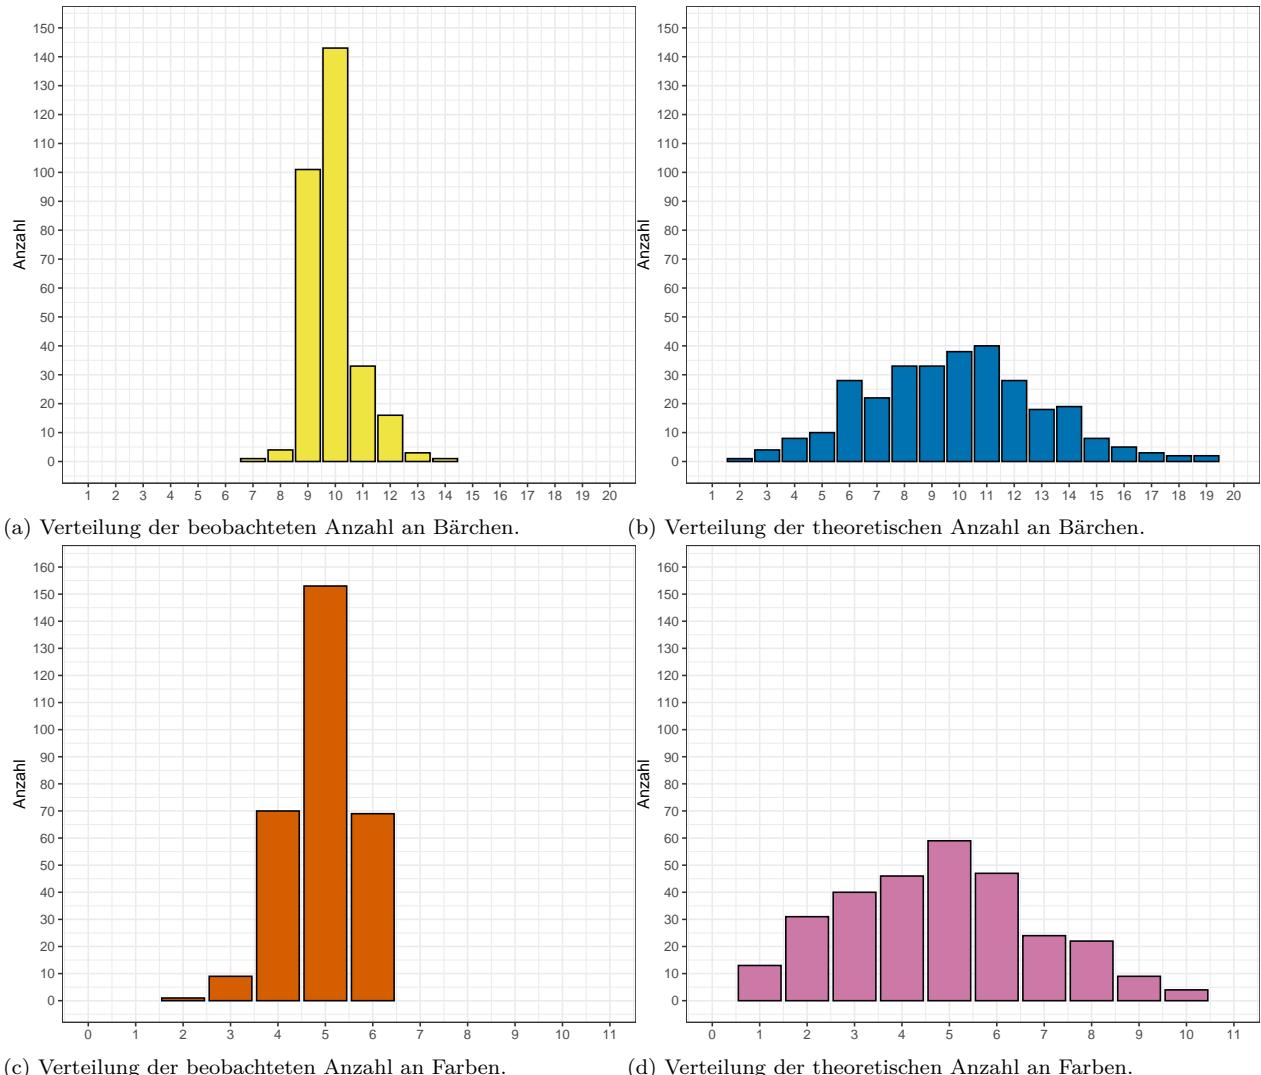


Abbildung 17.6: Darstellung Anzahl an Bärchen und Anzahl an Farben.
Es gibt nicht mehr als sechs Farben. Auf der linken Seite die beobachteten Werte und auf der rechten Seite die theoretischen Werte.



Teil IV

Frequentistische Hypothesentests

Grundlagen der Wissenschaft und Falsifikationsprinzip

Du findest auf YouTube Grundlagen der Wissenschaft und Falsifikationsprinzip als Video.

Das statistische Testen - eine Geschichte voller Missverständnisse. Wir wollen uns in den folgenden Kapiteln mit den Grundlagen des frequentistischen Hypothesentestens beschäftigen. Wenn ich hier einen Unterschied mache, dann muss es ja auch noch ein anderes Hypothesentesten geben. Ja, das nennt man dann bayesianische Statistik und kommt eventuell mal später. Wir konzentrieren uns aber zuerst auf frequentistische Hypothesentesten was seit gut hundert Jahren genutzt wird. Ich werde hier textlich nur einen kurzen Einstieg liefern. Vielleicht wird es in den folgenden Jahren länger aber aktuell (Ende 2022) bleiben wir hier bei einem kurzen Einstieg.

Beginnen wir mit der Logik der Forschung oder allgemeiner formuliert, als die Grundlage der Wissenschaft. Wir basieren all unsere Entscheidungen in der Wissenschaft auf dem Falsifikationsprinzip. Also bitte merken, wir können nur ablehnen (eng. *reject*).

Logik der Forschung

„Das ist die Logik der Forschung, die nie verifizieren, sondern immer nur jene Erklärungen beibehalten kann, die beim derzeitigen Erkenntnisstand am wenigsten falsifiziert sind.“ – Wößmann, L.

Wir ersetzen schlechte Modelle (der Wirklichkeit) durch weniger schlechte Modelle (der Wirklichkeit).

Forschung basiert auf dem Falsifikationsprinzip. Wir können **nur ablehnen** und behalten das weniger schlechte Modell bei.

Wir wollen hier auf keinen Fall die Leistungen von Altvorderen schmälern. Dennoch hatten Ronald Fischer (1890 - 1962), als der Begründer der Statistik, andere Voraussetzungen als wir heutzutage. Als wichtigster Unterschied sei natürlich das Gerät genannt, an dem du gerade diese Zeilen liest: dem Computer. Selbst die Erstellung einfacher Abbildungen war sehr, sehr zeitaufwendig. Die Berechnung von Zahlen lohnte sich mehr, als die Zahlen zu visualisieren. Insbesondere wenn wir die Explorative Datenanalyse nach John Tukey (1915 - 2000) durchführen.

Undenkbar zu den Zeiten von Ronald Fischer mehrere Abbildungen unterschiedlich nach Faktoren einzufärben und sich die Daten *anzugucken*.

Über die Nullhypothese erfährst du

mehr in dem folgenden **Kapitel**.
Der Begrenzung von moderner Rechenkapazität um 1900 gab es noch eine andere ungünstige Entwicklung. Stark vereinfacht formuliert entwickelte Ronald Fischer statistische Werkzeuge um abzuschätzen wie wahrscheinlich die Nullhypothese unter dem Auftreten der beobachteten Daten ist. Nun ist es aber so, dass wir ja auch eine Entscheidung treffen wollen. Nach der Logik der Forschung wollen wir ja eine Hypothese falsifizieren, in unserem Fall die Nullhypothese. Die Entscheidungsregeln, also die statistische Testtheorie, kommen nun von Jerzy Neyman (1894 - 1981) und Egon Pearson (1895 - 1980), beide als die Begründer der frequentistischen Hypothesentests.

Schlussendlich gibt es noch eine andere Strömung in der Statistik, die auf den mathematischen Formeln von Thomas Bayes (1701 - 1761) basieren. In sich eine geschlossene Theorie, die auf der *inversen* Wahrscheinlichkeit basiert. Das klingt jetzt etwas schräg, aber eigentlich ist die bayesianische Statistik die Statistik, die die Fragen um die Alternativehypothese beantwortet. Der Grund warum die bayesianische Statistik nicht angewendet wurde, war der Bedarf an Rechenleistung. Die bayesianische Statistik lässt sich nicht händisch in endlicher Zeit lösen. Dieses *technische* Problem haben wir aber nicht mehr. Eigentlich könnten wir also die bayesianische Statistik verwenden. Wir wollen hier aber (noch) nicht auf die bayesianische Statistik eingehen, das werden wir später tun.

Wenn du allgemein Interesse hast an der Geschichte der Statistik dann sei auf Salsburg (2001) verwiesen. Ein sehr schönes Buch, was die *geschichtlichen* Zusammenhänge nochmal aufzeigt.

Kommen wir aber nun zu den wichtigeren Punkten. Die folgenden Kapitel ist sehr umfangreich und enthalten viele Informationen, die wir teilweise später nochmal brauchen. Darüber hinaus müssen wir noch das *Lernen und Verstehen* von der *Anwendung* unterscheiden. Wir teilen dabei die *Testentscheidung* und die *Testtheorie* in zwei Kapitel auf.

Du erfährst im Kapitel ?? mehr zur Testentscheidung und welche Konzepte wir dort nutzen:

- Wir verstehen die statistischen Testentscheidung nutzen wir das Konzept der Teststatistik T (siehe Kapitel ??)
- Wir können die statistischen Testentscheidung anwenden, da wir das Konzept des p-Wertes $Pr(T|H_0)$ (siehe Kapitel ??) und das Konzept der 95% Konfidenzintervalle verstanden haben (siehe Kapitel ??)

Du erfährst im Kapitel ?? mehr zur Testtheorie und welche Konzepte wir dort nutzen:

- Wir verstehen den Unterschied zwischen dem α -Fehler und der β -Fehler (siehe Kapitel ??)
- Wir wissen um den Unterschied des einseitigen und zweiseitigen statistischen Testens (siehe Kapitel ??)
- Wir verstehen die Adjustierung für multiple Vergleiche (siehe Kapitel ??)

Referenzen

18 Die Testentscheidung

Version vom September 14, 2022 um 08:48:31

Du erfährst im diesem Kapitel mehr zur Testentscheidung und welche Konzepte wir dort nutzen:

- Wir verstehen die statistischen Testentscheidung nutzen wir das Konzept der Teststatistik T (siehe Kapitel ??)
- Wir können die statistischen Testentscheidung anwenden, da wir das Konzept des p-Wertes $Pr(T|H_0)$ (siehe Kapitel ??) und das Konzept der 95% Konfidenzintervalle verstanden haben (siehe Kapitel ??)

Forschung basiert auf dem Falsifikationsprinzip. Wir können **nur ablehnen** und behalten das weniger schlechte Modell bei.



Ein Wort zur Klausur

Abhängig von der Lernstufe - daher welche Veranstaltung du gerade bei mir besuchst - kommt nicht *alles* aus diesem Kapitel dran in der Klausur. Bitte gleiche die Inhalte, die ich in der aktuellen Vorlesung unterrichte, mit dem Material hier ab. Als Faustregel gilt, je höher die Lernstufe desto mehr musst du von dem statistischen Testen Wissen und Verstehen. Beachte auch die Probeklausur in deiner Veranstaltung und die gesammelten Klausurfragen auf GitHub.

18.1 Die Hypothesen

Wir können auf allen Daten einen statistischen Test rechnen und erhalten statistische Maßzahlen wie eine Teststatistik oder einen p-Wert. Nur leider können wir mit diesen statistischen Maßzahlen nicht viel anfangen ohne die Hypothesen zu kennen. Jeder statistische Test testet eine Nullhypothese. Ob diese Hypothese dem Anwender nun bekannt ist oder nicht, ein

Im Anhang ?? findest du verschiedene Beispiele zu Auswertungen von Datenbeispielen.

18 Die Testentscheidung

statistischer Test testet eine Nullhypothese. Daher müssen wir uns immer klar sein, was die entsprechende Nullhypothese zu unserer Fragestellung ist. Wenn du hier stockst, ist das ganz normal. Eine Fragestellung mit einer statistischen Hypothese zu verbinden ist nicht immer so einfach gemacht.

! Die Nullhypothese H_0 und die Alternativehypothese H_A

Die Nullhypothese H_0 nennen wir auch die Null oder Gleichheitshypothese. Die Nullhypothese sagt aus, dass zwei Gruppen gleich sind oder aber kein Effekt zu beobachten ist.

$$H_0 : \bar{y}_1 = \bar{y}_2$$

Die Alternativehypothese H_A oder H_1 auch Alternative genannt nennen wir auch Unterschiedshypothese. Die Alternativehypothese besagt, dass ein Unterschied vorliegt oder aber ein Effekt vorhanden ist.

$$H_A : \bar{y}_1 \neq \bar{y}_2$$

Als Veranschaulichung nehmen wir das Beispiel aus Kapitel ???. Wir formulieren als erstes die Fragestellung. Eine Fragestellung endet mit einem Fragezeichen.

Liegt ein Unterschied zwischen den Sprungweiten von Katzen und Hundeflöhern vor?

Wir können die Frage auch anders formulieren.

Springen Hunde und Katzenflöhe unterschiedlich weit?

Wichtig ist, dass wir eine primäre Fragestellung formulieren. Wir können auch mehrere Fragen an einen Datensatz haben. Das ist auch vollkommen normal. Nur hat jede Fragestellung ein eigenes Hypothesenpaar. Wir bleiben aber bei dem simplen Beispiel.

Wie sieht nun die statistische Hypothese in diesem Beispiel aus? Wir wollen uns die Sprungweite in [cm] anschauen. In diesem Fall wollen wir die *mittlere* Sprungweite der Hundeflöhe \bar{y}_{dog} mit der *mittleren* Sprungweite der Katzenflöhe \bar{y}_{cat} vergleichen. Es ergibt sich folgendes Hypothesenpaar.

$$H_0 : \bar{y}_{dog} = \bar{y}_{cat}$$

$$H_A : \bar{y}_{dog} \neq \bar{y}_{cat}$$

Es ist wichtig sich in Erinnerung zu rufen, dass wir nur und ausschließlich Aussagen über die Nullhypothese treffen werden. Das *frequentistische* Hypothesentesten kann nichts anders. Wir kriegen keine Aussage über die Alternativhypothese sondern nur eine Abschätzung der Wahrscheinlichkeit des Auftretens der Daten im durchgeführten Experiment, wenn die Nullhypothese wahr wäre.

Das **Falisifikationsprinzip** - wir können nur Ablehnen - kommt hier zusammen mit der **frequentistischen Statistik** in der wir nur eine Wahrscheinlichkeitsaussage über das Auftreten der Daten D - unter der Annahme H_0 gilt - treffen können.

18.2 Die Testentscheidung...

In den folgenden Kapiteln werden wir verschiedene statistische Tests kennenlernen. Alle statistischen Tests haben gemein, dass ein Test eine Teststatistik T_{calc} berechnet. Darüber hinaus liefert jeder Test auch einen p-Wert (eng. *p-value*). Manche statistischen Test geben auch ein 95% Konfidenzintervall wieder. Eine Testentscheidung gegen die Nullhypothese H_0 kann mit jedem der drei statistischen Maßzahlen durchgeführt werden. Die Regel für die Entscheidung, ob die Nullhypothese H_0 abgelehnt werden kann, ist nur jeweils anders. In Tabelle ?? sind die Entscheidungsregeln einmal zusammengefasst.

Wir wollen in den folgenden Abschnitten die jeweiligen Entscheidungsregeln eines statistischen Tests einmal durchgehen.

- Die Testentscheidung gegen die Nullhypothese anhand der Teststatistik in Kapitel ??
- Die Testentscheidung gegen die Nullhypothese anhand dem p-Wert in Kapitel ??
- Die Testentscheidung gegen die Nullhypothese anhand des 95% Konfidenzintervall in Kapitel ??

Streng genommen gilt die Regel $T_{calc} \geq T_{\alpha=5\%}$ nur für eine Auswahl an statistischen Tests siehe dazu auch Kapitel ???. Bei manchen statistischen Tests ist die Entscheidung gedreht. Hier lassen wir das aber mal so stehen...



Tabelle 18.1: Zusammenfassung der statistischen Testentscheidung unter der Nutzung der Teststatistik, dem p-Wert und dem 95% Konfidenzintervall. Die Entscheidung nach der Teststatistik ist veraltet und dient nur dem konventionellen Verständnisses. In der Forschung angewandt wird der p-Wert und das 95% Konfidenzintervall. Im Fall eines 95% Konfidenzintervalls müssen wir noch unterscheiden, ob wir einen Mittelwertsunterschied Δ_{A-B} oder aber einen Anteilsunterschied $\Delta_{A/B}$ betrachten.

		Teststatistik	p-Wert	95% Konfidenzintervall
H ₀ ablehnen	$T_{calc} \geq T_{\alpha=5\%}$	$Pr(\geq T_{calc} H_0)$	$Pr(\geq T_{calc} H_0) \leq \alpha$	$KI_{1-\alpha}$ Δ_{A-B} : enthält <u>nicht</u> 0
H ₀ ablehnen				$\Delta_{A/B}$: enthält <u>nicht</u> 1

18.2.1 ... anhand der Teststatistik



Prinzip des statistischen Testens I - Die Teststatistik

Du findest auf YouTube Prinzip des statistischen Testens I - Die Teststatistik als Video. Ich werde zwar alles nochmal hier als Text aufschreiben, aber manchmal ist das Sehen und Hören dann einfacher.

Wir wollen uns dem frequentistischen Hypothesentesten über die Idee der Teststatistik annähern. Im folgenden sehen wir die Formel für den t-Test. Den t-Test werden wir im Kapitel ?? uns nochmal detaillierter anschauen. Hier nutzen wir die vereinfachte Formel um das Konzept zu verstehen.

$$T_{calc} = \frac{\bar{y}_1 - \bar{y}_2}{s_p \cdot \sqrt{2/n_g}}$$

mit

- \bar{y}_1 dem Mittelwert für die erste Gruppe.

18.2 Die Testentscheidung...

- \bar{y}_2 dem Mittelwert für die zweite Gruppe.
- s_p der gepoolten Standardabweichung mit $s_p = \frac{s_A + s_B}{2}$.
- n_g der Gruppengröße der Gruppen. Wir nehmen an beide Gruppen sind gleich groß.

Wir benötigen also zwei Mittelwerte \bar{y}_1 und \bar{y}_2 und deren gepoolte Standardabweichung s_p sowie die Anzahl der Beobachtungen je Gruppe n_g . Wenden wir die Formel des t-Tests einmal auf den folgenden Beispieldatensatz an. In Tabelle ?? ist eine Datenbeispiel gegeben.

Tabelle 18.2: Beispiel für die Berechnung von einem Mittelwertseffekt an der Sprunglänge [cm] von Hunde und Katzenflöhen.

animal	jump_length
cat	8.5
cat	9.9
cat	8.9
cat	9.4
dog	8.0
dog	7.2
dog	8.4
dog	7.5

Wir berechnen nun die Mittelwerte und die Standardabweichungen aus der obigen Datentabelle. Die Werte setzen wir dann in die Formel ein.

$$T_{calc} = \frac{9.2 - 7.8}{\frac{(0.6 + 0.5)}{2} \cdot \sqrt{2/4}} = 3.6$$

mit

- $\bar{y}_{cat} = 9.2$ dem Mittelwert für die Gruppe *cat*.
- $\bar{y}_{dog} = 7.8$ dem Mittelwert für die Gruppe *dog*.
- $s_p = 0.55$ der gepoolten Standardabweichung mit $s_p = \frac{0.6 + 0.5}{2}$.

18 Die Testentscheidung

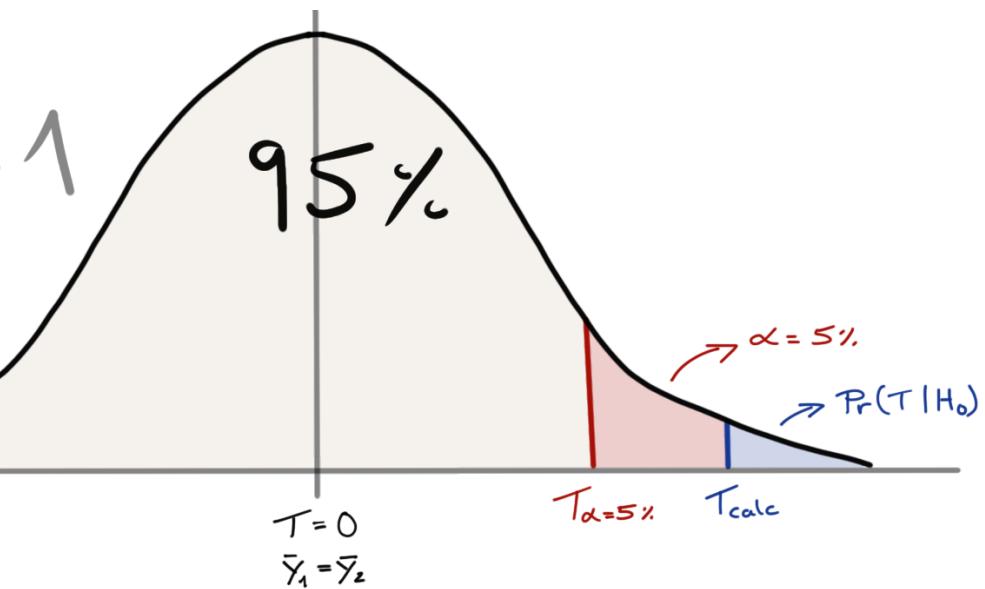
- $n_g = 4$ der Gruppengröße der Gruppe A und B. Wir nehmen an beide Gruppen sind gleich groß.

Wir haben nun die Teststatistik $T_{calc} = 3.6$ berechnet. In der ganzen Rechnererei verliert man manchmal den Überblick. Erinnern wir uns, was wir eigentlich wollten. Die Frage war, ob sich die mittleren Sprungweiten der Hunde- und Katzenflöhe unterschieden. Wenn die H_0 wahr wäre, dann wäre der Unterschied Δ der beiden Mittelwerte der Hunde- und Katzenflöhe gleich null. Oder nochmal in der Analogie der t-Test Formel, dann wäre im Zähler $\Delta = \bar{y}_{cat} - \bar{y}_{dog} = 0$. Wenn die Mittelwerte der Sprungweite [cm] der Hunde- und Katzenflöhe gleich wären, dann wäre die berechnete Teststatistik $T_{calc} = 0$, da im Zähler Null stehen würde. Die Differenz von zwei gleichen Zahlen ist Null.

Je größer die berechnete Teststatistik T_{calc} wird, desto unwahrscheinlicher ist es, dass die beiden Mittelwerte per Zufall gleich sind. Wie groß muss nun die berechnete Teststatistik T_{calc} werden damit wir die Nullhypothese ablehnen können?

In Abbildung ?? ist die Verteilung aller möglichen T_{calc} Werte unter der Annahme, dass die Nullhypothese wahr ist, dargestellt. Wir sehen, dass die t-Verteilung am höchsten bei $T_{calc} = 0$ ist und niedrigeren Werte mit steigenden t-Werten annimmt. Wenn $T = 0$ dann sind auch die Mittelwerte gleich. Je größer unsere berechnete Teststatistik T_{calc} wird, desto unwahrscheinlicher ist es, dass die Nullhypothese gilt. Die t-Verteilug ist so gebaut, dass die Fläche A unter der Kurve gleich $A = 1$ ist. Wir können nun den kritischen Wert $T_{\alpha=5\%}$ berechnen an dem rechts von dem Wert eine Fläche von 0.05 oder 5% liegt. Somit liegt dann links von dem kritischen Wert die Fläche von 0.95 oder 95%. Den kritischen Wert $T_{\alpha=5\%}$ können wir statistischen Tabellen entnehmen. Oder wir berechnen den kritischen Wert direkt in R mit $T_{\alpha=5\%} = 2.78$.

Kommen wir zurück zu unserem Beispiel. Wir haben in unserem Datenbeispiel für den Vergleich von der Sprungweite in [cm] von Hunde- und Katzenflöhen eine Teststatistik von $T_{calc} = 3.6$ berechnet. Der kritische Wert um die Nullhypothese abzulehnen liegt bei $T_{\alpha=5\%} = 2.78$. Wenn $T_{calc} \geq T_{\alpha=5\%}$ wird die Nullhypothese (H_0) abgelehnt. In unserem Fall ist $3.6 \geq 2.78$. Wir



Verteilung aller möglichen T_{calc} wenn die Nullhypothese wahr ist. Der Nullwert der t-Verteilung ist $T = 0$. Wenn wir keinen Unterschied zwischen den Mittelwerten \bar{y}_1 und \bar{y}_2 annehmen, dann wären die beiden Mittelwerte \bar{y}_1 und \bar{y}_2 gleich. Je größer der Abstand T_{calc} von $T = 0$, desto unwahrscheinlicher wird es, dass die beiden Mittelwerte gleich sind. Liegt der berechnete Wert von T_{calc} außerhalb des kritischen Wertes von $T_{\alpha=5\%}$, dann wird die Nullhypothese verworfen.



können die Nullhypothese ablehnen. Es gibt einen Unterschied zwischen der mittleren Sprungweite von Hunde- und Katzenflöhen.

Es gibt einen Unterschied zwischen der mittleren Sprungweite von Hunde- und Katzenflöhen. Die Aussage ist **statistisch falsch**. Wir können im frequentistischen Hypothesentesten keine Aussage über die H_A treffen. Im Sinne der Anwendbarkeit soll es hier so stehen bleiben.

Nun ist es leider so, dass jeder statistische Test seine eigene Teststatistik T hat. Daher ist es etwas mühselig sich immer neue und andere kritische Werte für jeden Test zu merken. Es hat sich daher eingebürgert, sich nicht die Teststatistik für die Testentscheidung gegen die Nullhypothese zu nutzen sondern den p-Wert. Den p-Wert wollen wir uns in dem folgenden Abschnitt anschauen.

! Entscheidung mit der berechneten Teststatistik

Bei der Entscheidung mit der Teststatistik müssen wir zwei Fälle unterscheiden.

- (1) Bei einem t-Test und einem χ^2 -Test gilt, wenn $T_{calc} \geq T_{\alpha=5\%}$ wird die Nullhypothese (H_0) abgelehnt.
- (2) Bei einem Wilcoxon-Mann-Whitney-Test gilt, wenn $T_{calc} < T_{\alpha=5\%}$ wird die Nullhypothese (H_0) abgelehnt.

Achtung – Wir nutzen die Entscheidung mit der Teststatistik *nur und ausschließlich* in der Klausur. In der praktischen Anwendung hat die Betrachtung der berechneten Teststatistik *keine* Verwendung mehr.

18.2.2 ... anhand dem p-Wert

💡 Prinzip des statistischen Testens II - Der p-Wert

Du findest auf YouTube Prinzip des statistischen Testens II - Der p-Wert als Video Reihe. Ich werde zwar alles nochmal hier als Text aufschreiben, aber manchmal ist das Sehen und Hören dann einfacher.

In dem vorherigen Abschnitt haben wir gelernt, wie wir zu einer Entscheidung gegen die Nullhypothese anhand der Teststatistik kommen. Wir haben einen kritischen Wert $T_{\alpha=5\%}$ definiert bei dem rechts von dem Wert 5% der Werte liegen. Anstatt nun den berechneten Wert T_{calc} mit dem kritischen Wert $T_{\alpha=5\%}$ zu vergleichen, vergleichen wir jetzt die Flächen rechts von den jeweiligen Werten.

In Abbildung ?? sind die Flächen auch eingetragen. Da die gesamte Fläche unter der t-Verteilung mit $A = 1$ ist, können wir die Flächen auch als Wahrscheinlichkeiten lesen. Die Fläche rechts von der berechneten Teststatistik T_{calc} wird $Pr(T_{calc}|H_0)$ oder p-Wert genannt. Die gesamte Fläche rechts von dem kritischen Wert $T_{\alpha=5\%}$ wird α genannt und liegt bei 5%. Wir können also die Teststatistiken oder den p-Wert mit dem α -Niveau von 5% vergleichen.

Wir schreiben Pr und meinen damit eine Wahrscheinlichkeit (eng. *probability*). Häufig wird auch nur das P verwendet, aber dann kommen wir wieder mit anderen Konzepten in die Quere.

Tabelle 18.3: Zusammenhang zwischen der Teststatistik T und der Fläche A rechts von der Teststatistik. Die Fläche rechts von der berechneten Teststatistik T_{calc} wird $Pr(T|H_0)$ oder p-Wert genannt. Die Fläche rechts von dem kritischen Wert $T_{\alpha=5\%}$ wird α genannt und liegt bei 5%.

Teststatistik T	Fläche A
T_{calc}	$Pr(T_{calc} H_0)$ oder p-Wert
$T_{\alpha=5\%}$	α

Der p-Wert oder $Pr(T|H_0)$ ist eine Wahrscheinlichkeit. Eine Wahrscheinlichkeit kann die Zahlen von 0 bis 1 annehmen. Dabei sind die Grenzen einfach zu definieren. Eine Wahrschein-

lichkeit von $Pr(A) = 0$ bedeutet, dass das Ereignis A nicht auftritt; eine Wahrscheinlichkeit von $Pr(A) = 1$ bedeutet, dass das Ereignis A eintritt. Der Zahlenraum dazwischen stellt jeden von uns schon vor große Herausforderungen. Der Unterschied zwischen 40% und 60% für den Eintritt des Ereignisses A sind nicht so klar zu definieren, wie du auf den ersten Blick meinen magst.

Ein frequentistischer Hypothesentest beantwortet die Frage, mit welcher Wahrscheinlichkeit Pr die Teststatistik T aus dem Experiment mit den Daten D zu beobachten wären, wenn es keinen Effekt gäbe (H_0 ist wahr).

Likelihood heißt Plausibilität und Im Englischen gibt es die Begrifflichkeiten einer *Likelihood* und **Probability** heißt einer *Probability* in der Statistik. Meist wird beides ins Deutsche ungenau mit Wahrscheinlichkeit übersetzt oder wir nutzen einfach *Likelihood*. Was aber auch nicht so recht weiterhilft. Es handelt sich hierbei aber um zwei unterschiedliche Konzepte. Deshalb Übersetzen wir *Likelihood* mit Plausibilität und *Probability* mit Wahrscheinlichkeit.

Im Folgenden berechnen wir den p -Wert in R mit der Funktion `t.test()`. Mehr dazu im Kapitel ??, wo wir den t-Test und deren Anwendung im Detail besprechen.

```
# A tibble: 1 x 2
  statistic p.value
  <dbl>     <dbl>
1        2.81   0.0309
```

Wir sagen, dass wir ein signifikantes Ergebnis haben, wenn der p -Wert kleiner ist als die Signifikanzschwelle α von 5%. Ist der p -Wert kleiner als der α -Wert von 5%, dann können wir die Nullhypothese ablehnen. Da 0.031 kleiner ist als 0.05 können wir die Nullhypothese und damit die Gleichheit der mittleren Sprungweiten in [cm] ablehnen. Wir sagen, dass wir ein signifikantes Ergebnis vorliegen haben.

! Entscheidung mit dem p -Wert

Wenn der p -Wert $\leq \alpha$ dann wird die Nullhypothese (H_0) abgelehnt. Das Signifikanzniveau α wird als Kulturkonstante auf 5% oder 0.05 gesetzt. Die Nullhypothese (H_0)

kann auch Gleichheitshypothese gesehen werden. Wenn die H_0 gilt, liegt kein Unterschied zwischen z.B. den Behandlungen vor.

18.2.3 ... anhand des 95% Konfidenzintervall

Ein statistischer Test der eine Teststatistik T berechnet liefert auch immer einen p -Wert. Nicht alle statistischen Tests ermöglichen es ein 95% Konfidenzintervall zu berechnen. Abbildung ?? zeigt ein 95% konfidenzintervall.



Abbildung 18.2: Ein 95% Konfidenzintervall. Der Punkt in der Mitte entspricht dem Unterschied oder Effekt Δ .

Mit der Teststatistik T und dem damit verbundenen p -Wert haben wir uns *Wahrscheinlichkeiten* angeschaut und erhalten eine *Wahrscheinlichkeitsaussage*. Eine Wahrscheinlichkeitsaussage sagt aber nichts über den Effekt Δ aus. Also wie groß ist der mittlere Sprungunterschied zwischen Hunde- und Katzenflöhen.

Die Idee von 95% Kondifenzintervallen ist es jetzt den Effekt mit der Wahrscheinlichkeitsaussage zusammenzubringen und beides in einer *Visualisierung* zu kombinieren. Im Folgenden sehen wir die vereinfachte Formel für das 95% Konfidenzintervall eines t-Tests.

$$\left[(\bar{y}_1 - \bar{y}_2) - T_{\alpha=5\%} \cdot \frac{s_p}{\sqrt{n}}; (\bar{y}_1 - \bar{y}_2) + T_{\alpha=5\%} \cdot \frac{s_p}{\sqrt{n}}; \right]$$

Die Formel ist ein wenig komplex, aber im Prinzip einfach. Der linke und der rechte Teil neben dem Semikolon sind fast gleich, bis auf das Plus- und Minuszeichen. Abbildung ?? visualisiert die Formel einmal. Wir sehen Folgendes in der Formel und dann in der entsprechenden Abbildung:

Mit **p-Werten** haben wir Wahrscheinlichkeitsaussagen und damit über die **Signifikanz**. Damit haben wir noch keine Aussage über die **Relevanz** des beobachteten Effekts.

18 Die Testentscheidung

- $(\bar{y}_1 - \bar{y}_2)$ ist der Effekt Δ . In diesem Fall der Mittelwertsunterschied. Wir finden den Effekt als Punkt in der Mitte des Intervalls.
- $T_{\alpha=5\%} \cdot \frac{s}{\sqrt{n}}$ ist der Wert, der die Arme des Intervalls bildet. Wir vereinfachen die Formel mit s_p für die gepoolte Standardabweichung und n_g für die Fallzahl der beiden Gruppen. Wir nehmen an das beide Gruppen die gleiche Fallzahl $n_1 = n_2$ haben.

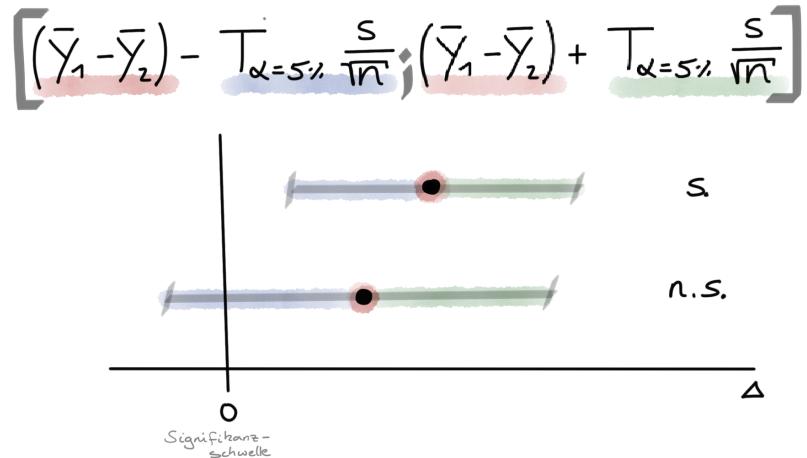


Abbildung 18.3: Zusammenhang zwischen der vereinfachten Formel für das 95% Konfidenzintervall und der Visualisierung des 95% Konfidenzintervalls. Der Effektschätzer wird als Punkt in der Mitte des Intervalls dargestellt. Der Effektschätzer Δ kann entweder ein Mittelwertsunterschied sein oder ein Anteilsunterschied. Bei einem Mittelwertsunterschied kann die Nullhypothese abgelehnt werden, wenn die 0 nicht im Konfidenzintervall ist; bei einem Anteilsunterschied wenn die 1 nicht im Konfidenzintervall ist. Die Arme werden länger oder kürzer je nachdem wie sich die statistischen Maßzahlen s und n verändern.

Die Funktion `factor()` in R erlaubt es dir die Level eines Faktors zu sortieren und so festzulegen ob Level `cat minus Level dog` oder `umgekehrt` von R gerechnet wird. Wir können eine biologische Relevanz definieren, dadurch das ein 95% Konfidenzintervall die Wahrscheinlichkeitsaussage über die Signifikanz, daher ob die Nullhypothese abgelehnt werden kann, mit dem Effekt zusammenbringt. Wo die Signifikanz-

18.2 Die Testentscheidung...

schwelle klar definiert ist, hängt die Relevanzschwelle von der wissenschaftlichen Fragestellung und weiteren externen Faktoren ab. Die Signifikanzschwelle liegt bei 0, wenn wir Mittelwerte miteinander vergleichen und bei 1, wenn wir Anteile vergleichen. Abbildung ?? zeigt fünf 95% Konfidenzintervalle (a-e), die sich anhand der Signifikanz und Relevanz unterscheiden. Bei der Relevanz ist es wichtig zu wissen in welche *Richtung* der Effekt gehen soll. Erwarten wir einen positiven Effekt wenn wir die Differenz der beiden Gruppen bilden oder einen negativen Effekt?

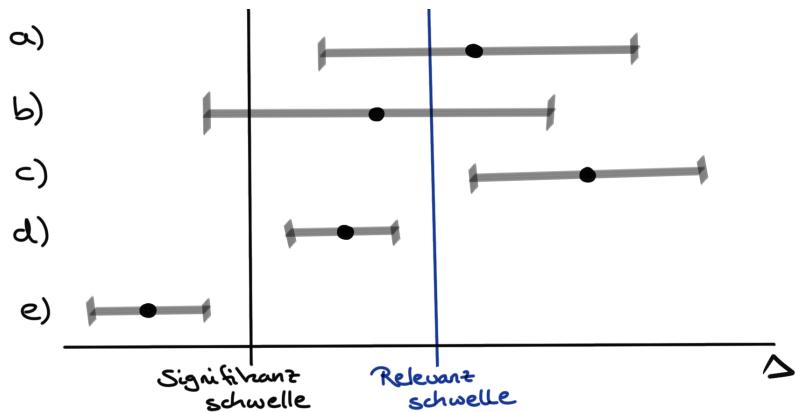


Abbildung 18.4: Verschiedene signifikante und relevante Konfidenzintervalle: (a) nicht signifikant und nicht relevant; (b) signifikant und nicht relevant; (c) signifikant und relevant; (d) signifikant und nicht relevant, der Effekt ist zu klein; (e) signifikant und potenziell relevant, Effekt zeigt in eine unerwartete Richtung gegeben der Relevanzschwelle.

Wir wollen uns nun einmal anschauen, wie sich ein 95% Konfidenzintervall berechnet. Wir nehmen dafür die vereinfachte Formel und setzen die berechneten statistischen Maßzahlen ein. In der Anwendung werden wir die Konfidenzintervalle nicht selber berechnen. Wenn ein statistisches Verfahren konfidenzintervalle berechnen kann, dann liefert die entsprechende Funktion in R das Konfidenzintervall.

Es ergibt sich Folgende ausgefüllte, vereinfachte Formel für das 95% Konfidenzintervalls eines t-Tests für das Beispiel des

18 Die Testentscheidung



Sprungweitenunterschieds [cm] zwischen Hunde- und Katzenflöhen.

Wir nutzen hier eine **vereinfachte Formel** für das Konfidenzintervall um das Konzept zu verstehen. Später berechnen wir das Konfidenzintervall in R.

$$\left[(9.2 - 7.8) - 2.78 \cdot \frac{0.55}{\sqrt{4}}; (9.2 - 7.8) + 2.78 \cdot \frac{0.55}{\sqrt{4}}; \right]$$

mit

- $\bar{y}_{cat} = 9.2$ dem Mittelwert für die Gruppe *cat*.
- $\bar{y}_{dog} = 7.8$ dem Mittelwert für die Gruppe *dog*.
- $T_{\alpha=5\%} = 2.78$ dem kritischen Wert.
- $s_p = 0.55$ der gepoolten Standardabweichung mit $s_p = \frac{0.6+0.5}{2}$.
- $n_g = 4$ der Gruppengröße der Gruppe A und B. Wir nehmen an beide Gruppen sind gleich groß.

Lösen wir die Formel auf, so ergibt sich folgendes 95% Konfidenzintervall des Mittelwertsunterschiedes der Hunde- und Katzenflöhe.

$$[0.39; 2.20]$$

Wir können sagen, dass mit 95% Wahrscheinlichkeit das Konfidenzintervall den wahren Effektunterschied Δ überdeckt. Oder etwas mehr in Prosa, dass wir eine Sprungweitenunterschied von 0.39 cm bis 2.20 cm zwischen Hunde- und Katzenflöhen erwarten würden.

Die Entscheidung gegen die Nullhypothese bei einem Mittelwertsunterschied erfolgt bei einem 95% Konfidenzintervall danach ob die Null mit im Konfidenzintervall liegt oder nicht. In dem Interval $[0.39; 2.20]$ ist die Null nicht enthalten, also können wir die Nullhypothese ablehnen. Es ist mit einem Unterschied zwischen den mittleren Sprungweiten von Hunde- und Katzenflöhen auszugehen.

18.3 Auswirkung des Effektes, der Streuung und der Fallzahl

In unserem Beispiel, könnten wir die Relevanzschwelle für den mittleren Sprungweitenunterschied zwischen Hund- und Katzenflöhen auf 2 cm setzen. In dem Fall würden wir entscheiden, dass der mittlere Sprungweitenunterschied nicht relevant ist, da die 2 cm im Konfidenzintervall enthalten sind. Was wäre wenn wir die Relevanzschwelle auf 4 cm setzen? Dann wäre zwar die Relevanzschwelle nicht mehr im Konfidenzintervall, aber wir hätten Fall (d) in der Abbildung ?? vorliegen. Der Effekt ist einfach zu klein, dass der Effekt relevant sein könnte.

! Entscheidung mit dem 95% Konfidenzintervall

Bei der Entscheidung mit dem 95% Konfidenzintervall müssen wir zwei Fälle unterscheiden.

- (1) Entweder schauen wir uns einen Mittelwertsunterschied ($\Delta_{y_1-y_2}$) an, dann können wir die Nullhypothese (H_0) *nicht* ablehnen, wenn die **0** im 95% Konfidenzintervall ist.
- (2) Oder wir schauen uns einen Anteilsunterschied (Δ_{y_1/y_2}) an, dann können wir die Nullhypothese (H_0) *nicht* ablehnen, wenn die **1** im 95% Konfidenzintervall ist.

18.3 Auswirkung des Effektes, der Streuung und der Fallzahl

Wir wollen einmal den Zusammenhang zwischen dem Effekt Δ , der Streuung als Standardabweichung s und Fallzahl n uns näher anschauen. Wir können die Formel des t-Tests wie folgt vereinfachen.

$$T_{calc} = \frac{\bar{y}_1 - \bar{y}_2}{s_p \cdot \sqrt{2/n_g}}$$

Für die Betrachtung der Zusammenhänge wandeln wir $\sqrt{2/n_g}$ in $1/n$ um. Dadurch wandert die Fallzahl n in den Zähler. Die

Standardabweichung verallgemeinern wir zu s und damit allgemein zur Streuung. Abschließend betrachten wir $\bar{y}_A - \bar{y}_B$ als den Effekt Δ . Es ergibt sich folgende vereinfachte Formel.

$$T_{calc} = \frac{\Delta \cdot n}{s}$$

Wir können uns nun die Frage stellen, wie ändert sich die Teststatistik T_{calc} in Abhängigkeit vom Effekt Δ , der Fallzahl n und der Streuung s in den Daten. Die Tabelle ?? zeigt die Zusammenhänge auf. Die Aussagen in der Tabelle lassen sich generalisieren. So bedeutet eine steigende Fallzahl meist mehr signifikante Ergebnisse. Eine stiegende Streuung reduziert die Signifikanz eines Vergleichs. Ein Ansteigen des Effektes führt zu mehr signifikanten Ergebnissen. Ebenso verschiebt eine Veränderung des Effekts das Konfidenzintervall, eine Erhöhung der Streuung macht das Konfidenzintervall breiter, eine sinkende Streuung macht das Konfidenzintervall schmäler. bei der Fallzahl verhält es sich umgekehrt. Eine Erhöhung der Fallzahl macht das Konfidenzintervall schmäler und eine sinkende Fallzahl das Konfidenzintervall breiter.

Tabelle 18.4: Zusammenhang von der Teststatistik T_{calc} und dem p-Wert $Pr(\geq T_{calc} | H_0)$ sowie dem $KI_{1-\alpha}$ Abhängigkeit vom Effekt Δ , der Fallzahl n und der Streuung s .

	T_{calc}	$Pr(\geq T_{calc} H_0)_{1-\alpha}$		T_{calc}	$Pr(\geq T_{calc} H_0)_{1-\alpha}$	
$\Delta \uparrow$	steigt	sinkt	verschoben	sinkt	steigt	verschoben
$s \uparrow$	sinkt	steigt	breiter	$s \downarrow$	sinkt	schmäler
$n \uparrow$	steigt	sinkt	schmäler	\downarrow	steigt	breiter

19 Die Testtheorie

Version vom September 14, 2022 um 08:48:39

💡 Prinzip der statistischen Testentscheidung - H_0 und H_A

Du findest auf YouTube Prinzip der statistischen Testentscheidung - H_0 und H_A als Video Reihe. Ich werde zwar alles nochmal hier als Text aufschreiben, aber manchmal ist das Sehen und Hören dann einfacher.

Wir können auf allen Daten einen statistischen Test rechnen und erhalten statistische Maßzahlen wie eine Teststatistik, einen p-Wert oder ein 95% Konfidenzintervall. Wie wir aus dem vorherigen Kapitel wissen testet jeder statistische Test eine Nullhypothese. Ob diese Hypothese dem Anwender nun bekannt ist oder nicht, ein statistischer Test testet eine Nullhypothese. Daher müssen wir uns immer klar sein, was die entsprechende Nullhypothese zu unserer Fragestellung ist.

In diesem Kapitel wollen wir uns nochmal tiefer mit der Testtheorie und dem α -Fehler und der β -Fehler beschäftigen. Was heißt eigentlich einseitig oder zweiseitig Testen? Auch müssen wir nochmal einen Blick auf das multiple Testen und die α -Adjustierung werfen.

Wir wiederholen nochmal. Die Nullhypothese H_0 nennen wir auch die Null oder Gleichheitshypothese. Die Nullhypothese sagt aus, dass zwei Gruppen gleich sind oder aber kein Effekt zu beobachten ist.

$$H_0 : \bar{y}_1 = \bar{y}_2$$

Die Alternativehypothese H_A oder H_1 auch Alternative genannt nennen wir auch Unterschiedshypothese. Die Alternati-